

TransferJudge EDA Report

Amazon Reviews 2023 탐색적 데이터 분석 보고서

TransferJudge: A Profiler-Judge LLM-Based Framework for Selective Transfer in Cross-Domain Recommendation

선택적 전이를 위한 Profiler-Judge 구조의 LLM 기반 교차 도메인 추천 프레임워크

2026.04 빅데이터학과 17기 곽민아

목차

1. 분석 목적 및 개요
2. 원본 데이터 구조 (리뷰 + 메타데이터)
3. 데이터 전처리 및 Overlapping User 추출
4. 리뷰 수 분포 분석
5. 리뷰 토큰 수 분포 및 토큰 예산 검증
6. 평점 분포 및 GT 확보율
7. 시간 분포 및 시점 타당성
8. 메타데이터 품질 분석
9. 후보 아이템 토큰 검증
10. 종합 판정 및 설계 결정
11. 추가 검증 (GAP-1, GAP-2, GAP-4)

1. 분석 목적 및 개요

1.1 목적

본 EDA는 TransferJudge 실험 설계의 핵심 가정들을 실제 데이터로 검증하기 위해 수행되었다. Pilot Study 및 본 실험 전에 데이터의 분포와 특성을 파악하여, 실험 조건의 타당성을 확인한다.

1.2 검증 대상

검증 항목	가설/기준	판단 기준
Overlapping User 규모	1,000명 이상 추출 가능	Source $\geq$ 15, Target 5~10 조건
리뷰 토큰 예산	GPT-4o-mini 128K context 내 수용	P95 worst-case 기준
GT 확보율	rating $\geq$ 4 구매가 존재하는 사용자 비율	$\geq$ 80%
시점 타당성	리뷰가 너무 오래되지 않았는지	2018년 이전 사용자 <30%
메타데이터 품질	후보 아이템 정보 구성 가능 여부	title, rating 결측률
후보 아이템 토큰	50개 후보의 총 토큰이 예산 내	<3,500 tokens

1.3 데이터 소스

Amazon Reviews 2023 (McAuley Lab, UCSD) — HuggingFace McAuley-Lab/Amazon-Reviews-2023

- 전체 571.54M 리뷰, 54.51M 사용자, 48.19M 아이템
- 본 연구 대상: **Movies & TV** (Source) + **Books** (Target)

2. 원본 데이터 구조

2.1 리뷰 데이터 스키마

HuggingFace raw_review_Movies_and_TV, raw_review_Books에서 로딩.

필드명	타입	설명	예시
user_id	string	익명화된 사용자 고유 ID. 도메인 간 동일 ID 공유 → Overlapping User 식별 가능	AGGZ357AO26RQ...
parent_asin	string	아이템 고유 ID. 메타데이터 조인 키	B013488XFS
rating	float	사용자 평점 (1.0~5.0)	5.0
text	string	리뷰 본문 텍스트. Profiler의 핵심 입력	"Amazon, please buy the show!"
title	string	리뷰 제목 (사용자가 작성)	"Five Stars"
timestamp	int64	리뷰 작성 시각 (밀리초 단위 Unix timestamp)	1440385637000

주요 특징: user_id는 모든 카테고리에서 동일한 익명화 문자열을 사용하므로, Movies & TV와 Books 양쪽에 리뷰를 남긴 사용자를 user_id 교집합으로 찾을 수 있다. text 필드는 본 연구의 핵심 입력으로, Profiler가 이 텍스트에서 선호 패턴을 추출한다.

2.2 메타데이터 스키마

HuggingFace raw_meta_Books, raw_meta_Movies_and_TV에서 로딩.

필드명	타입	설명	용도
parent_asin	string	아이템 고유 ID (리뷰와 조인 키)	리뷰-아이템 매핑
title	string	제품명 (책 제목 / 영화 제목)	후보 아이템 표시
main_category	string	최상위 카테고리	"Books", "Movies & TV"
categories	list	계층적 카테고리 (예: Books → Literature → Contemporary)	후보 아이템 장르
average_rating	float	아이템 평균 평점	후보 아이템 품질 지표
rating_number	int	총 평점 수	인기도 참고

features	list	제품 소개/줄거리 텍스트 배열	책 내용 파악 (핵심)
description	list	제품 설명 (저자 소개, 리뷰 인용 등 혼재)	품질 불균일 → 미사용
author	dict	저자 정보 (name, avatar, about)	후보 아이템 저자명
details	dict/ JSON	상세 속성 (Publisher, ISBN, Language 등)	출판 정보
subtitle	string	판형 정보 (Hardcover, Kindle Edition 등)	참고용
price	float	가격	미사용
store	string	판매처/브랜드	미사용

2.3 Movies & TV 메타데이터 — details 주요 키

키	설명	출현율 (샘플 5,000건)
Directors / Director	감독명 (리스트 또는 문자열)	~70%
Actors / Starring	출연 배우 (리스트)	~72%
Release date	개봉/출시일	~37%
Run time / Runtime	상영 시간	~37%
Genre	장르	~19%

2.4 Books 메타데이터 — details 주요 키

키	설명	출현율 (샘플 5,000건)
Language	언어	94.1%
Publisher	출판사 + 출판일	92.4%
ISBN 13 / ISBN 10	국제 표준 도서 번호	80~85%
Paperback / Hardcover / Print length	페이지 수	54~21%
Publication date	출판일 (별도 필드)	7.1%

핵심 발견 — features vs description:

description 필드는 리뷰 인용("Review ..."), 저자 소개("About the Author ...") 등 비정형 내용이 혼재되어 책의 내용을 파악하기 어렵다.

반면 features 필드에 실제 책 소개/줄거리가 저장되어 있으며, **88.3%의 아이템에 존재한다**. 후보 아이템 정보 구성 시 features를 활용한다.

3. 데이터 전처리 및 Overlapping User 추출

3.1 원본 데이터 규모

항목	Movies & TV	Books
전체 리뷰 수	17,328,314	29,475,453
고유 사용자 수	6,503,429	10,297,355
고유 아이템 수	747,764	4,446,065
평점 범위	1.0 ~ 5.0	0.0 ~ 5.0
데이터 기간	1997-08 ~ 2023-09	1996-06 ~ 2023-09
text 결측률	0.00%	0.00%

3.2 전처리

text가 null이거나 빈 문자열인 리뷰를 제거하였다.

	전처리 전	전처리 후	제거율
Movies & TV	17,328,314	17,327,095	0.01%
Books	29,475,453	29,467,817	0.03%

3.3 Overlapping User 추출

분석 목적: 양쪽 도메인에 모두 리뷰를 남긴 사용자가 실험에 필요한 1,000명 이상 확보 가능한지 확인.

전처리 후 Overlapping 사용자: **2,530,704명**

조건별 사용자 수 탐색

Source(Movies) 최소 리뷰 수와 Target(Books) 리뷰 범위를 변화시키며 조건 충족 사용자 수를 확인하였다.

Source 기준	Target 1~5	Target 3~10	Target 5~10	Target 5~15	Target 5~20
≥ 1	2,073,112	800,355	367,180	453,055	493,075
≥ 3	616,104	327,426	167,751	214,686	238,503
≥ 5	302,312	184,739	100,034	131,088	147,749
≥ 10	98,084	71,670	41,591	56,885	65,605

≥ 15	47,058	37,447	22,465	31,450	36,891
≥ 20	27,278	22,835	13,984	19,879	23,621
≥ 30	12,273	10,665	6,629	9,632	11,673

판정: 본 연구 조건 (Source ≥ 15, Target 5~10)에서 **22,465명** 확보 가능 → 목표 1,000명 대비 **22배 이상 여유**. seed=42로 1,000명 랜덤 샘플링 완료.




Figure 1. 조건별 Overlapping User 수 히트맵 (좌) 및 Source 리뷰 수 분포 (우)

1,000명 샘플링 방식 타당성 (선행연구 비교)

분석 목적: "1,000명만 뽑아도 되는가?", "무작위 샘플링(최신 순 아님)이 타당한가?"에 대한 근거를 선행연구와 비교하여 문서화.

논문	샘플 규모	샘플링 방식	시간 필터
TALLRec (RecSys 2023)	16 / 64 / 256 샘플 (few-shot)	Books: 사용자별 무작위 1건 · Movies: 최근 10K interaction	부분 (Movies만)
LLM4CDR (WWW 2025)	100명	무작위 (budget 제약)	✗ 없음
EMCDR (IJCAI 2017)	전체 overlapping user	무작위 비율 분할 (5% / 50% / 80%)	✗ 없음
CDRNP (WSDM 2024)	50% cold-start 시뮬레이션	무작위	✗ 없음
Serendipity-2018 (LLM 벤치마크)	500명 × 5 seeds	무작위 + 다중 seed	✗ 없음
본 연구 (TransferJudge)	1,000명	무작위 (seed=42)	✗ 없음

1. 샘플 규모 타당성 — 선행연구 대비 2~10배 큰 규모:

LLM4CDR 100명 대비 10배, TALLRec few-shot 256 대비 4배, Serendipity 500명 대비 2배. LLM 기반 CDR norm에

서 **상위권** 규모이며, Teacher Distillation 학습 데이터 ~50,000건(800명 × 평균 60 후보) 생성을 위한 균형점으로 설정되었다. LLM API 호출 비용 및 QLoRA 학습 시간을 고려한 결정이다.

2. 무작위 샘플링 타당성 — CDR 학계 표준 프로토콜:

비교한 주요 CDR 논문 4편(TALLRec, LLM4CDR, EMCDD, CDRNP) 모두 시간 기준 샘플링이 아닌 **무작위 샘플링**을 채택하였다. 이는 특정 시점 사용자에게 모델이 과적합되지 않도록 하는 표준 관행이다. 본 연구는 seed=42로 고정하여 재현성을 확보하였다.

3. 시점 편향 관리 — EDA로 정량 확인:

시간 필터 미적용에 따른 시점 편향을 확인한 결과: Source-Target 시점 갭 **중앙값 1.2년**, 2018년 이전 사용자 **25.8%** (30% 미만)로 허용 범위 내 (상세: 섹션 7). 선행연구는 시점 분포를 명시적으로 보고하지 않았으나, 본 연구는 EDA에서 정량화하여 투명성을 강화하였다.

Overlapping User 데이터 vs GT 데이터 — 정의와 구성

분석 목적: 두 데이터 개념의 차이와 본 연구에서의 역할을 명확히 정의.

구분	Overlapping User 데이터	GT (Ground Truth) 데이터
정의	두 도메인 모두에 리뷰를 남긴 사용자	모델 예측의 정답 아이템
단위	사용자 단위	아이템 단위 (사용자당 1건)
역할	실험 대상자 선정 기준	모델 평가의 정답 라벨
확보 방식	Movies&TV ∩ Books 의 user_id 교집합	Target(Books) 리뷰 중 rating ≥ 4인 가장 최근 1건
수량	22,465명 → 샘플 1,000명	사용자당 1건 (총 1,000건)
근거	Cross-Domain 전이가 가능한 대상 확보	LOO(Leave-One-Out) 평가 프로토콜

본 연구의 사용자별 데이터 구성

1,000명 각각에 대해 다음과 같이 데이터가 구성된다:

구성 요소	내용	사용 목적
Source Input	Movies&TV 리뷰 최근 15~30개	Profiler의 Core Pattern 추출 입력
Target Pool	Books 리뷰 5~10개 (Cold-Start)	GT 추출 대상 (입력으로 사용 안 함)
GT	Target 중 rating ≥ 4인 가장 최근 1건	Transfer Judge가 Top-K에 올려야 할 정답
Candidates		Transfer Judge의 랭킹 입력

GT 1개 + Books 도메인 무작위 Negative 49개 = 50개 (아이템 정보: 제목
+ 저자 + 카테고리 + 평점 + features 첫 50 tokens)

Leakage 방지 원칙: GT로 선정된 아이템은 Profiler·Judge 입력에서 완전히 제외된다. Target(Books) 리뷰는 전체가 입력에서 제외되며, 오직 Source(Movies&TV) 리뷰만으로 선호를 추출한다. 이는 Cold-Start의 이론적 극한(Target 리뷰 0개 가정)을 시뮬레이션하는 엄격한 평가 조건이다.

Explicit Positive의 의미: rating ≥ 4 = 명시적 선호. Transfer Gate의 BLOCK 판정이 올바른 전이 차단인지 측정하려면 GT가 "사용자가 실제로 만족한 아이템"이어야 한다. Implicit feedback(구매 자체 = positive) 방식에서는 BLOCK의 올바른 판단이 성능 하락으로 오측정되어 Transfer Gate 효과가 왜곡되므로 본 연구는 Explicit Positive를 채택하였다.

Source 리뷰 수 구간별 분포 (Overlapping User 전체)

구간	사용자 수	비율
1~2개	1,672,422	66.1%
3~5개	493,646	19.5%
6~10개	211,124	8.3%
11~15개	67,346	2.7%
16~20개	30,678	1.2%
21~30개	26,848	1.1%
31~50개	16,597	0.7%
51+개	12,043	0.5%

3.4 GT 확보율

분석 목적: GT(Ground Truth)로 사용할 rating ≥ 4 구매가 존재하는 사용자 비율을 확인.

본 연구는 Explicit Positive 방식(rating ≥ 4 중 가장 최근 구매)을 GT로 채택하였다.

GT 방식	확보 사용자	비율
방식 A: 마지막 구매 ≥ 4 점	18,898명	84.1%
방식 B: ≥ 4 점 중 가장 최근 (채택)	22,364명	99.6%

판정: 채택한 방식 B로 **99.6%** GT 확보. 방식 A 대비 **3,466명 추가 확보**. 1,000명 샘플링 후 **100% GT 확보**.

4. 리뷰 수 분포 분석

분석 목적: 최종 대상 1,000명의 도메인별 리뷰 수가 실험 설계(Source 최대 30개, Target 5~10개)와 정합하는지 확인.

4.1 대상 사용자 리뷰 수 통계

통계량	Source (Movies & TV)	Target (Books)
Mean	31.7	7.0
Median	22	7
P25	17	6
P75	33	8
P95	71	10
Min	15	5
Max	629	10

해석: Source 중앙값 22개로, "최신순 30개" 입력 시 대부분 사용자의 전체 또는 대부분의 리뷰가 활용된다. Target은 5~10개 범위(Cold-Start 조건)에 정확히 분포한다.




Figure 2. 대상 사용자의 Source/Target 리뷰 수 분포

5. 리뷰 토큰 수 분포 및 토큰 예산 검증

분석 목적: 리뷰당 토큰 수를 측정하여 Profiler 입력의 토큰 예산이 GPT-4o-mini context(128K) 내에 수용되는지 검증. 토큰라이저는 tiktoken cl100k_base 사용.

5.1 도메인별 토큰 통계

통계량	Movies & TV	Books	참조값 (Amazon 2023 역산)
Mean	80.4	67.3	~58 / ~98
Median	28	30	—
P75	73	69	—
P95	343	266	—
Max	4,749	1,872	—

발견: 평균은 참조값과 유사하나, **P95가 참조값의 4~6배**로 높다. 이는 소수의 장문 리뷰(영화 에세이, 독후감 등)가 분포의 꼬리를 끌어올리기 때문이다. 중앙값(28~30 tokens)과 평균(67~80 tokens) 사이의 큰 차이는 **right-skewed 분포**를 나타낸다.

5.2 Profiler 입력 토큰 예산 검증

시나리오	Source 30개	Target 10개	프롬프트	합계	GPT-4o-mini 128K
평균 기준	$80 \times 30 = 2,412$	$67 \times 10 = 673$	500	3,585	✅ 2.8%
P95 worst-case	$343 \times 30 = 10,290$	$266 \times 10 = 2,658$	500	13,448	✅ 10.5%

판정: P95 worst-case에서도 13,448 tokens으로 GPT-4o-mini 128K context의 **10.5%**만 사용. 리뷰 **truncation 불필요** — 전체 리뷰를 잘림 없이 입력 가능.




Figure 3. 도메인별 리뷰 토큰 수 분포 (히스토그램, 박스플롯, CDF)

6. 평점 분포 및 GT 확보율

분석 목적: 평점 분포의 편향(J-shaped skew) 정도를 확인하고, GT 조건(rating $\geq$ 4) 충족 비율을 검증.

6.1 도메인별 평점 분포

평점	Movies & TV	Books
Rating $\geq$ 4 비율	79.5%	85.0%

해석: 양쪽 도메인 모두 고평점 편향(J-shaped)을 보이며, 4점 이상이 79~85%를 차지한다. 이는 Amazon 리뷰 데이터의 일반적 특성이다. GT(rating $\geq$ 4) 확보에 유리한 분포이다.




Figure 4. 도메인별 평점 분포

6.2 GT 확보율 상세

기준	마지막 구매 기준
평점 $\geq$ 3.0	916명 (91.6%)
평점 $\geq$ 3.5	844명 (84.4%)
평점 $\geq$ 4.0	844명 (84.4%)
평점 $\geq$ 4.5	718명 (71.8%)
평점 $\geq$ 5.0	718명 (71.8%)

채택한 방식 B(rating $\geq$ 4 중 가장 최근)로 전환하면 **1,000명 전원(100%) GT 확보.**

7. 시간 분포 및 시점 타당성

분석 목적: 리뷰가 너무 오래되어 현재 선호를 반영하지 못하는 사용자가 얼마나 되는지 확인. 선행연구(TALLRec, LLM4CDR, EMCDR, TrineCDR) 4편 모두 날짜 필터를 적용하지 않았으므로, 본 연구도 동일하되 시점 분포를 보고 하여 타당성을 문서화한다.

7.1 마지막 리뷰 시점

통계량	Source (Movies)	Target (Books)	어느 도메인이든
가장 오래된	2000-05-18	2000-02-24	2000-05-18
중앙값	2019-04-14	2018-11-24	2020-08-29
가장 최근	2023-05-31	2023-05-04	2023-05-31

7.2 날짜 필터 필요 여부

기준	결과	판정
2018년 이전 사용자 비율	25.8%	30% 미만 → 필터 불필요
Source-Target 시점 갭 중앙값	1.2년	3년 미만 → 전이 타당성 유지
시점 갭 5년 이상	96명 (9.6%)	소수 → 허용 범위

7.3 최신순 30개의 시간 범위

통계량	값
평균	5.3년
중앙값	4.6년
P25	2.4년
P75	7.4년

판정: 날짜 필터 미적용. 2018년 이전 사용자 25.8%(30% 미만), Source-Target 시점 갭 중앙값 1.2년으로 전이 타당성 유지. 선행연구 4편 모두 날짜 필터를 적용하지 않았으므로 일관된 프로토콜.




Figure 5. 마지막 리뷰 연도 분포 (좌), Source-Target 시점 scatter (중), 시점 갭 분포 (우)

8. 메타데이터 품질 분석

분석 목적: 후보 아이템 정보 구성에 필요한 메타데이터 필드의 결측률과 품질을 확인.

8.1 Books 메타데이터 결측률

필드	결측률	용도
title	0.0%	후보 아이템 표시 (필수)
average_rating	0.0%	후보 아이템 품질 지표 (필수)
categories	0.0%	장르/카테고리 (필수)
features (줄거리)	11.7%	책 내용 파악 (선택적 추가)
author_name (수정 후)	27.4%	저자명 — brand_loyalty 판단 근거 (수정된 파싱으로 72.6% 추출 가능)
publisher	12.7%	출판 정보
pub_date	92.8%	출판일 — 대부분 누락
language	11.1%	언어

author_name 파싱 수정 이력:

최초 EDA에서 author 필드를 dict로 가정하고 `isinstance(author_val, dict)`로 검사하여 100% 결측으로 측정되었으나, 재검증 결과 실제 타입은 `str(dict를 문자열로 직렬화한 형태)`임이 확인되었다. 예: `"{'avatar': '...', 'name': 'Peter Ackroyd', 'about': [...]}"`

수정된 파싱 로직(`ast.literal_eval`을 통한 dict 복원 후 name 키 추출):

- NULL(저자 정보 없음): 27.4%
- 정상 추출: 72.6%
- 파싱 실패: 0.0%

→ 후보 아이템 정보에 저자명 포함 가능. brand_loyalty Core Pattern 판단 근거로 활용.

8.2 Movies & TV 메타데이터 결측률

필드	결측률	비고
title	42.0%	높은 결측 — 본 연구에서는 Books 후보만 사용
average_rating	0.0%	—
director	29.6%	—

actors	27.6%	—
release_date	63.4%	—
runtime	63.5%	—
description	42.0%	—

해석: Books의 핵심 필드(title, average_rating, categories)는 결측률 0%. features(줄거리)도 88.3% 존재. 후보 아이템 정보 구성에 충분하다.

author_name 100% 결측은 author dict 구조의 파싱 문제로 추정 — 별도 확인 필요.

8.3 description vs features 품질 비교

EDA에서 description과 features 필드의 내용을 샘플링하여 비교한 결과:

필드	실제 내용	품질
description	"Review ...", "About the Author ...", 빈 값	부적합
features	책 소개, 줄거리 요약, 핵심 내용	적합

description 예시: "Review 'This uplifting story will have you cheering...'" (리뷰 인용)

features 예시: "In the year 2032, eighty-year-old Moira Burke watches as life on Earth becomes a series of natural disasters..." (실제 줄거리)

8.4 features 토큰 통계

통계량	값
존재율	88.3%
Mean	183.0 tokens
Median	155 tokens
P95	455 tokens




Figure 6. Books 도메인 상위 카테고리 분포

9. 후보 아이템 토큰 검증

분석 목적: Transfer Judge에 입력되는 50개 후보 아이템의 총 토큰이 예산 내인지 확인.

9.1 후보 아이템 텍스트 형식

현재 형식: 제목 | 카테고리 | Rating: X.X

통계량	값
아이템당 Mean	20.0 tokens
아이템당 Median	18 tokens
아이템당 P95	37 tokens
50개 총 토큰 (평균)	998 tokens
50개 총 토큰 (P95)	1,850 tokens

판정: 후보 50개 토큰 **~1,000 tokens**으로 실험 설계 예상치(~2,500) 이하. features(줄거리) 첫 50 tokens를 추가해도 ~3,500 tokens으로 예산 내.

9.2 features 추가 시 토큰 예산

구성	아이템당	50개 합계
(A) 제목 + 카테고리 + 평점	~20	~1,000
(B) + features 첫 50 tokens	~70	~3,500




Figure 7. 후보 아이템 1개당 토큰 수 분포

10. 종합 판정 및 설계 결정

10.1 EDA 체크리스트

판정	검증 항목	결과
✓	Overlapping User $\geq 1,000$ 명	22,465명 (22배 여유)
✓	GT 확보율 (rating ≥ 4 중 최근)	99.6% (1,000명 샘플 후 100%)
✓	Profiler 토큰 P95 worst-case	13,448 tokens (128K의 10.5%)
✓	리뷰 truncation 불필요	GPT-4o-mini 128K context 충분
✓	날짜 필터 불필요	2018년 이전 25.8% (30% 미만)
✓	Source-Target 시점 갭	중앙값 1.2년 (3년 미만)
✓	메타 title+rating 사용 가능	결측률 0%
✓	features(줄거리) 존재율	88.3%
✓	후보 50개 토큰	~1,000 tokens (예산 내)
✓	author_name 추출	72.6% 존재 (str 파싱 수정 후 재측정). NULL 27.4%는 원본 데이터에 저자 정보 없음

10.2 주요 설계 결정

결정 사항	선택	근거
GT 선정 방식	rating ≥ 4 중 가장 최근 (Explicit Positive)	Transfer Gate BLOCK 효과 정확 측정. 기존 방식 대비 +3,466명 확보
날짜 필터	미적용	선행연구 4편 동일. 2018년 이전 25.8%로 허용 범위
리뷰 truncation	미적용 (전체 사용)	P95 worst-case 13,448 tokens $\rightarrow$ GPT-4o-mini 128K의 10.5%
후보 아이템 정보	제목 + 저자 + 카테고리 + 평점 + features 50 tokens	features(줄거리 88.3%) + author_name(72.6%, str 파싱 수정 후) 포함. description은 품질 부적합으로 제외
description 제외	미사용	리뷰 인용, 저자 소개 등 비정형 내용 혼재. EDA에서 확인

10.3 논문용 Dataset Statistics

항목	Movies & TV	Books
Total Reviews	17,327,095	29,467,817
Unique Users	6,502,818	10,292,988
Unique Items	747,764	4,446,065
Overlapping Users (sampled)		1,000
Reviews per User (mean)	31.7	7.0
Tokens per Review (mean)	80.4	67.3
Tokens per Review (P95)	343	266
Input Reviews (max)	30	10
Rating ≥ 4 (%)	79.5%	85.0%
Data Period	1997-08 ~ 2023-09	1996-06 ~ 2023-09
Last Review Median Year		2020
Features (synopsis) Rate	N/A	88.3%

11. 추가 검증 (GAP-1, GAP-2, GAP-4)

본 섹션은 실험 계획서와 EDA 보고서의 격차 분석에서 식별된 3가지 검증 항목을 추가로 다룬다. 계획서의 핵심 가정과 자기 설계의 데이터 근거, 평가 공정성을 정량적으로 확인한다.

GAP	검증 대상	왜 중요한가
GAP-2	사용자별 Source 평점 다양성	Profiler가 polarity=negative 패턴을 추출할 수 있는지 데이터로 검증 (계획서 §5.5 설계 근거)
GAP-1	Source-Target Top-Genre 매핑	Cross-Domain 전이의 데이터 근거. CDR의 핵심 가정을 시각적으로 증명
GAP-4	GT vs Negative 후보 분포 비교	평가 공정성. 단순 카테고리/평점 정렬로 GT가 풀리지 않는지 확인

11.1 GAP-2 — 사용자별 Source 평점 다양성

분석 목적: Profiler 설계에 따르면 낮은 평점(rating ≤ 2) 리뷰도 polarity=negative 패턴 추출에 활용된다. 실제 데이터에서 이러한 비선호 신호가 충분히 존재하는지 검증한다.

지표	값	의미
사용자별 Source 평점 표준편차 (mean)	0.90 (P25 0.54 / P75 1.25)	대부분 사용자가 평점을 다양하게 매김 (단일 평점만 주는 경우 드뭄)
rating ≤ 2 리뷰를 1개 이상 보유한 사용자 비율	64.2%	강한 비선호 신호(2점 이하) 보유 사용자가 다수
rating ≤ 3 리뷰를 1개 이상 보유한 사용자 비율	81.6%	거의 모든 사용자가 mild negative 신호 보유
평균 사용자의 rating ≤ 2 리뷰 비중	11.1%	평균적으로 리뷰의 약 1/10이 강한 negative
평균 사용자의 rating ≤ 3 리뷰 비중	19.9%	평균적으로 리뷰의 약 1/5이 비선호 신호




Figure 8. (a) 사용자별 Source 평점 표준편차 / (b) 비선호 신호 보유 사용자 수 / (c) ≤3점 비중 분포

판정: Profiler의 polarity=negative 추출 가능성 충분히 입증. 사용자의 64%가 강한 negative(≤2점) 신호를, 82%가 mild negative(≤3점) 신호를 보유. Profiler는 이러한 비선호 신호를 통해 "사용자가 무엇을 싫어하는지"까지 패턴화할 수 있으며, 이는 Judge의 BLOCK/PARTIAL 판정에 활용된다 (계획서 §5.5).

11.2 GAP-1 — Source(Movies) ↔ Target(Books) Top-Genre 매핑

분석 목적: Cross-Domain Recommendation의 핵심 가정인 "도메인 간 선호 패턴이 부분 전이됨"을 데이터로 확인한다. 각 사용자의 Source/Target 도메인에서 가장 많이 본 장르(top-1) 쌍을 추출하여 매핑 패턴을 분석한다.

지표	값
Source/Target 모두에서 top-genre 추출 가능한 사용자	983 / 1,000명 (98.3%)
Top-10 × Top-10 매핑된 사용자 쌍	707쌍
동일 명칭 직접 매칭 (예: Sci-Fi 영화 → Sci-Fi 책)	0건

핵심 발견: Movies와 Books의 카테고리 분류 체계가 서로 달라 동일 명칭으로 직접 매칭되는 경우는 0건이다. 예를 들어 Movies는 "Science Fiction", "Drama", "Comedy"로 분류되지만, Books는 "Literature & Fiction", "Mystery, Thriller & Suspense", "Children's Books" 등으로 분류된다.

이는 본 연구의 **PARTIAL 판정의 필요성을 데이터로 직접 증명**한다. "동일 장르 직접 전이"는 데이터상 불가능하며, 의미적 연관성을 가진 PARTIAL 매핑이 본질적으로 요구된다.

주요 매핑 패턴 (Movies 장르 → 가장 많이 매핑된 Books 장르 Top 1)

Movies 장르	가장 많이 매핑된 Books 장르	비율 (n / 매핑 사용자 수)	의미
Suspense	Literature & Fiction	33.3% (13/39)	스릴러 영화 → 문학 소설
Comedy	Children's Books	28.0% (21/75)	코미디 영화 → 아동 도서 (가족 단위 사용자 추정)

Genre for Featured Categories	Literature & Fiction	25.9% (29/112)	일반 영화 → 일반 문학
Science Fiction	Literature & Fiction	25.0% (4/16)	SF 영화 → 문학 (SF 책이 Lit&Fic 산하 분류)
Drama	Mystery, Thriller & Suspense	22.8% (18/79)	드라마 영화 → 스릴러 책 (서사 선호 매핑)
Documentary	Literature & Fiction	23.1% (3/13)	다큐멘터리 → 문학
Action	Children's Books	36.4% (4/11)	액션 영화 → 아동 도서 (가족 단위)




Figure 9. (a) Movies × Books Top-10 장르 cross-tabulation 절대값 / (b) 행 정규화 (Movies 장르 → Books 장르 조건부 확률)

판정: CDR의 데이터 근거 확보. 98.3% 사용자가 양 도메인에서 top-genre 추출 가능하며, 도메인 간 비자명한 매핑 패턴이 관찰된다 (Drama→Mystery·Thriller, Suspense→Literature, Comedy→Children's 등). 다만 동일 명칭 직접 매칭이 0건이라는 사실은 **Transfer Gate의 PARTIAL 판정이 단순 옵션이 아니라 데이터상 필수임을 증명한다.**

11.3 GAP-4 — GT vs Negative 후보 분포 비교 (평가 공정성)

분석 목적: 평가 시 GT가 단순 카테고리·평점 정렬로 식별되지 않는지 확인하여 평가의 공정성을 검증한다. 1,000명의 GT 1개씩 (총 1,000건) vs Negative 후보 49개씩 (총 ~49,000건)의 분포를 비교한다.

비교 항목	GT (n=931)	Negative (n=42,999)	차이/검정
평균 평점	4.55	4.40	+0.15 (작은 차이)
KS Test (분포 차이)	statistic = 0.158		p-value = 3.2e-20
GT 카테고리 분포 vs Neg 카테고리 분포	Top-10 장르가 거의 동일		Figure 10 참조




Figure 10. (a) Top-10 Books 장르 비율 비교 (GT vs Negative) / (b) 아이템 평균 평점 분포 비교 (KS=0.158)

판정: 평가 공정성 확보.

- **평점 차이 0.15**는 통계적으로 유의($p < 0.001$)하나 절대값이 작아 단순 평점 정렬로 GT 식별 불가. GT 평점 분포의 P25-P75가 Negative 분포와 크게 겹침.
- **카테고리 분포는 GT와 Negative가 거의 동일** (Top-10 장르 비율이 유사). 단순 카테고리 빈도 기반 추천으로는 GT를 우선순위화 불가.
- **KS statistic 0.158**은 분포 차이가 작음을 시사. 큰 차이가 있다면 0.3+ 수준이어야 함.

→ Top-K 추천 정확도(HR@K, NDCG@K)는 **패턴 매칭 능력**에서 의미 있게 측정되며, 단순 baseline(평점 정렬, 카테고리 매칭)이 우연히 좋은 성능을 내는 leakage는 차단된다.

11.4 추가 검증 종합

GAP	검증 결과	설계상 함의
GAP-2 (평점 다양성)	≤2점 보유 64.2%, ≤3점 보유 81.6%	Profiler의 polarity=negative 패턴 추출 가능. 계획서 §5.5의 "낮은 평점 리뷰도 활용" 정당화
GAP-1 (도메인 매핑)	98.3% 매핑 가능 / 동일 명칭 매칭 0건	CDR 가능성 확인 + PARTIAL 판정 필수성 데이터 증명. 계획서 §8 Transfer Gate 3단계 정당화 강화
GAP-4 (평가 공정성)	평점 차이 0.15, 카테고리 분포 유사	단순 baseline으로 GT 식별 불가. HR@K/NDCG@K가 진짜 모델 성능을 측정