

TransferJudge

Preventing Negative Transfer in LLM-based Cross-Domain Recommendation via 2-Agent Pipeline

2-Agent LLM 파이프라인을 활용한 Negative Transfer 방지 기반 Cross-Domain 추천

2026.02 빅데이터학과 17기 곽민아

1. 핵심 문제 정의

1.1 연구 정의 (Objective)

구분	내용
연구 배경	추천 시스템은 과거 행동 데이터가 충분해야 개인화 추천이 가능. 특정 도메인에서 데이터가 부족한 상황을 Cold-Start 문제라 함.
접근 방식	데이터가 풍부한 영화 도메인의 리뷰를 활용하여 부족한 도서 도메인의 추천에 활용하는 Cross-Domain Recommendation.
핵심 문제	영화 취향이 모두 도서 추천에 유용하지 않음. "놀란 감독 팬" 같은 정보는 관련 없는 도서 추천을 유발. 이를 Negative Transfer 라 함.
해결 방법	Agent 1 (Profiler) : 리뷰에서 구조화된 선호 패턴 추출. Agent 2 (Transfer Judge) : 패턴별 전이 가능 여부 판별(TRANSFER/PARTIAL/BLOCK) 후 추천 생성.
연구 목표	Transfer Gate로 Negative Transfer를 방지하여 Cross-Domain Cold-Start 추천 품질 향상.

1.2 Research Questions

RQ	연구 질문	쉽게 말하면	비교
RQ1	LLM 기반 구조화된 프로파일링이 원본 리뷰 직접 입력 대비 추천 품질을 개선하는가?	영화 리뷰를 "SF 좋아함" 식으로 정리해서 넣는 게, 원문을 그대로 넣는 것보다 나은가?	(c) vs (f)
RQ2	Transfer Gate를 통한 선호 패턴 자동 필터링이 추천 성능에 유의미한 영향을 미치는가?	책에 써먹을 수 없는 취향 (예: "놀란 감독 팬")을 걸러내면 추천이 더 정확해지는가?	(c) vs (d)
RQ3	분석과 판단을 별도 에이전트로 분리하고, 판단만 파인튜닝하는 전략이 단일 LLM보다 우수한가?	AI 1명이 혼자 하는 것보다 분석+판단 담당 으로 나누고 판단만 훈련 시키면 더 잘하는가?	(a)vs(b)vs(c)

1.3 개념 정의

Cross-Domain Recommendation (CDR) — 한 분야의 데이터를 다른 분야 추천에 활용.

Source / Target 도메인 — Source: 데이터 풍부(영화), Target: 데이터 부족(책).

Cold-Start — 이력 부족으로 취향 파악 불가.

Negative Transfer — Source 정보가 Target에서 오히려 방해되는 현상.

Agent — 특정 역할을 맡은 LLM 단위.

2. Cold-Start 문제란?

시나리오 예시

Movies & TV: 45편 시청, 상세 리뷰. **Books:** 3권 구매, "재미있었어요" 1개뿐.

우리의 접근: 영화 리뷰에서 패턴 추출 → 책에 전이 가능한 것만 선별 → 추천.

2.1 Cold-Start 기준 정당화: 왜 리뷰 5~10개인가?

구간	리뷰 수	상태	처리
Zero-Shot	0개	Target 정보 전무 → 전이 효과 측정 불가	제외
Cold-Start	5~10개	Target 단독으로는 부족, CDR 효과 검증 가능한 최적 구간	대상
Warm-Start	10개 초과	Target 단독 추천 가능 → CDR 필요성 희석	제외


선행연구 기준: 대부분의 CDR 논문(EMCDR, LLM4CDR 등)은 Target < 20개를 Cold-Start로 정의. 본 연구는 이 범위 내에서 구체화.

하한(5개): 5개 미만이면 Target 선호 파악 불가, 전이 효과 분리 어려움.

상한(10개): 10개 초과 시 Target 단독으로도 충분, Source 전이의 marginal effect 감소.

Source >= 15개: Profiler가 의미 있는 패턴을 추출하기 위한 최소 리뷰 수 (Pilot Study에서 검증).

3. 전체 프로세스 플로우차트



단계	처리 내용	결과물
Step 1	Source/Target 리뷰 수집 및 전처리	Source 최대 30개 + Target 최대 10개
Step 2	Agent 1이 선호 패턴을 JSON으로 추출	6~9개 선호 패턴
Step 3	Agent 2가 TRANSFER/PARTIAL/BLOCK 판정	전이 결정 결과
Step 4	전이 가능 패턴만으로 Top-10 추천 생성	추천 리스트 + rationale

4. 데이터셋 설명 및 구성

4.1 데이터 소스

Amazon Review 2023 (McAuley Lab). 도메인 간 공통 사용자 존재.

4.2 도메인 구성

구분	Source: Movies & TV	Target: Books
사용자 조건	리뷰 15개 이상	리뷰 5~10개
입력 리뷰 수	최대 30개 (최신순)	전체 (최대 10개)

4.3 실험 데이터 규모

- Overlapping User 1,000명 / Train 800 / Val 100 / Test 100
- 후보 아이템: 사용자당 50개 (GT 1 + Negative 49)

데이터 규모 근거

1,000명: TALLRec ~600명, LLM4CDR ~1,000명 수준. API 비용 ~\$5 내 현실적 규모.

8:1:1 분할: 추천 시스템 연구 표준 비율. Test 100명에서 Bootstrap CI로 95% 신뢰구간 확보 가능.

5. 에이전트별 Input / Output 및 LLM 선정 근거

5.1 Agent 1: Profiler

구분	상세 내용
LLM	GPT-4o-mini API (프롬프트 기반, 파인튜닝 없음)
Input	Source 리뷰 최대 30개 + Target 리뷰 전체 (~4,100 tokens)
Output	JSON: 5~8개 선호 패턴 (~800 tokens)

왜 GPT-4o-mini인가?

태스크: 텍스트 분석(Analytical) — 범용 LLM 능력 범위 내, 파인튜닝 불필요.

API 효율: 파인튜닝 불필요 → API 호출이 인프라 없이 최적. \$0.15/1M tokens, 1,000명 ~\$1~2.
재현성: 상용 API는 동일 프롬프트에 일관된 출력 보장.

5.2 Agent 2: Transfer Judge

구분	상세 내용
LLM	Qwen2.5-14B-Instruct (QLoRA 파인튜닝)
Input	Profiler Output + 후보 50개 (~3,800 tokens)
Output	transfer_decisions + recommendations Top-10 (~1,500 tokens)

왜 Qwen2.5-Instruct인가?

오픈소스 필수: QLoRA를 위해 가중치 접근 필요 → GPT 계열 사용 불가.

Instruct 완료: JSON 출력 + 복잡한 지시문 이해 필요 → Instruct 모델이어야 추가 FT 효율적.

벤치마크 최상위: 7B/14B급 오픈소스 중 MMLU, MT-Bench 최상위 (2024~2025).

대안 비교: LLaMA-3는 다국어에서 열위, Mistral은 7B만 존재하여 스케일업 비교 불가.

6. Agent 1이 추출하는 선호 패턴 정의

6.1 반정형(Semi-Structured) 접근

6개 Core Pattern 필수 분석 + 추가 패턴 자유 추출.

6.2 Core Patterns

Pattern	설명	예시
genre_preference	선호 장르	"Sci-Fi, Thriller"
narrative_complexity	서사 복잡도	"Multi-layered, nonlinear"
pacing_preference	전개 속도	"Fast-paced"
quality_sensitivity	품질 민감도	"Highly critical"
brand_loyalty	브랜드 충성도	"Nolan fan"
sensory_preference	감각적 경험	"Values cinematography"

6.3 패턴 선정 근거: Pilot Study

Pilot Study 설계

100명 샘플: Train 800명의 12.5%. 빈도 순위 안정성 확보를 위한 최소 규모.

6개 컷오프: Top-6 이후 빈도 급감(long-tail)을 확인하여 컷오프 타당성 검증. 빈도 그래프로 시각화.

비구조화 추출: "자유롭게 추출하라"는 지시로 LLM 편향 최소화, 데이터에서 자연스럽게 드러나는 패턴 발견.

7. Agent 2가 필요한 이유

✓ **genre_preference:** "SF, Thriller" → 그대로 전이 가능.

⚠ **sensory_preference:** "영상미 중시" → "묘사력 중시"로 변환 가능.

✗ **brand_loyalty:** "놀란 감독 팬" → 전이 불가. 차단 필요.

왜 분리? 패턴 추출(Analytical)과 전이 판단(Judgmental)은 인지적으로 다른 태스크. 단일 LLM에 맡기면 Task Interference로 품질 저하.

8. Transfer Gate: 전이 판정 3단계 정의

판정	정의	예시
TRANSFER	양쪽 도메인에 공통 존재. 변환 없이 적용.	"SF 장르 선호"
PARTIAL	의미적 변환으로 활용 가능.	"영상미" → "묘사력"
BLOCK	대응 개념 없음. 완전 배제.	"놀란 감독 팬"

왜 3단계인가? — 선행연구 근거

기존 연구에서 negative transfer의 원인과 강도가 다층적임은 이미 인식되어 왔다 (Zhang et al. 2023; TrineCDR 2024). 그러나 이를 실제 전이 판정에 반영하여 이산적 multi-level decision으로 구현한 연구는 본 연구가 최초이다.

이론적 근거:

- Zhang & Wu (IEEE/CAA JAS 2023) — NT 완화 접근을 Domain/Instance/Feature 3단계로 분류. Transferability를 계층적으로 판단해야 한다는 이론적 토대.
- TrineCDR (KDD 2024) — NT 원인을 Feature/Interaction/Domain 3 level로 분류. Multi-level 원인 → multi-level 판정 필요라는 직접적 동기.
- Wang et al. (CVPR 2019) — NT의 3가지 요인 식별 + gate 기반 filtering. 방법론적 선례.

기존 접근의 한계:

- Binary 판정 (SAN, CVPR 2018): transfer/block만으로는 변환 가능한 패턴까지 버리는 정보 손실.
- 연속 가중치 (Park et al., CIKM 2023): Shapley 기반 0~1 스코어는 해석 어렵고, 추천 rationale에 반영 불가.

3단계의 자연스러움: "그대로 쓴다 / 변환해서 쓴다 / 안 쓴다"는 의사결정의 자연스러운 최소 분류 체계.

검증 계획: 2단계(PARTIAL→TRANSFER 통합) vs 3단계 비교로 PARTIAL 등급의 독립적 기여도를 정량 검증.

핵심 설계 원칙: Transfer Judge의 추천 rationale에는 BLOCK 판정된 패턴이 절대 등장해서는 안 된다.

9. 최종 추천 생성 방식

9.1 평가 프로토콜: Leave-One-Out

구분	내용
Ground Truth	Target 마지막 구매 1개 (4점 이상)
후보 구성	GT 1 + Random Negative 49 = 50개
평가 지표	HR@1, HR@5, HR@10, NDCG@10, MRR

10. Research Question별 검증 방법

10.1 Ablation Study 전체 설계

조건	구성	검증 목적
(a) Single LLM	단일 프롬프트로 전체 수행	베이스라인 (LLM4CDR 재현)
(b) 2-Agent (Prompt)	Profiler(P) + Judge(P) 프롬프트	구조 분리 효과
(c) Ours ★	Profiler(P) + Judge(QLoRA)	파인튜닝 효과
(d) w/o Gate	Judge(FT), 모든 패턴 TRANSFER 강제	Transfer Gate 효과
(e) 전통 CDR	비LLM 임베딩 기반	LLM 접근 우위
(f) Raw Review	Profiler 생략, raw review 직접 입력	구조화 프로파일 효과

11. 사전연구 논문 정리

11.1 핵심 인용 논문 (3편)

- (1) TALLRec (RecSys 2023) — LoRA로 LLM을 추천에 정렬. QLoRA 전략의 이론적 근거.
- (2) TrineCDR (KDD 2024) — NT 3가지 원인 식별/완화. Transfer Gate 컨셉의 근거.
- (3) LLM4CDR (WWW 2025) — Single LLM + 프롬프트 CDR. 가장 직접적인 비교 대상.

11.2 Transfer Gate 3단계 근거 논문

논문	학회	관련성
Zhang & Wu, "Survey on NT"	IEEE/CAA JAS 2023	Domain/Instance/Feature 3단계 분류 — 이론적 근거
Wang et al.	CVPR 2019	NT 3요인 + gate filtering — 방법론적 선례
SAN (Cao et al.)	CVPR 2018	Binary selective transfer — PARTIAL 확장 필요성
FedGCDR	NeurIPS 2024	Soft/Hard NT 구분 — NT 강도 차이 근거
Park et al.	CIKM 2023	Shapley 연속 가중치 — 이산 판정 발전 선례

11.3 추가 참고 논문

논문	학회	관련성
AgentCF++	SIGIR 2025	LLM Agent CDR
LLMCDSR	TOIS 2025	LLM CDR Sequential Rec

12. 파인튜닝 전략: QLoRA + Teacher Distillation

12.1 QLoRA

Step 1: 4-bit NF4 양자화 (14B: ~28GB→~8GB). Step 2: Low-Rank Adapter만 학습 (수십 MB).

항목	설정값
Base Model / 양자화	Qwen2.5-14B-Instruct / 4-bit NF4
LoRA Rank / Alpha / Dropout	64 / 128 / 0.05
학습률 / 배치 / Epoch	2e-5 (cosine) / effective=16 / 3~5 (early stopping)
하드웨어 / 시간	A100 80GB x 1 / 4~8시간

12.2 Teacher Distillation

GPT-4o-mini Teacher로 학습 데이터 생성. Train 700건 / Val 100건. 비용 ~\$2~3.

GT 힌트 방어 논리: Teacher에게 GT를 제공하는 것은 정답 암기가 아니라 **올바른 판정 과정 (rationale)** 시연을 위함. Student는 "패턴을 어떻게 판정하는지"를 학습하며, 추론 시에는 GT 없이 수행.

13. 연구의 차별점

Gap Statement: LLM4CDR은 Negative Transfer에 취약하고, TrineCDR은 LLM을 활용하지 못한다. 본 연구는 이 두 한계를 동시에 해결한다.

비교	LLM4CDR	TrineCDR	TALLRec	Ours
입력	구매 제목	임베딩	상호작용	리뷰 전문
LLM	Single	미사용	LoRA	2-Agent+QLoRA
Neg. Transfer	미고려	✓	미고려	✓ Gate