

TransferJudge

A Profiler-Judge LLM Framework for Gated Cross-Domain Recommendation

Profiler-Judge LLM 프레임워크를 활용한 Negative Transfer 방지 기반 Cross-Domain 추천

2026.02 빅데이터학과 17기 곽민아

1. 핵심 문제 정의

1.1 연구 정의 (Objective)

구분	내용
연구 배경	추천 시스템은 과거 행동 데이터가 충분해야 개인화 추천이 가능. 특정 도메인에서 데이터가 부족한 상황을 Cold-Start 문제라 함.
접근 방식	데이터가 풍부한 영화 도메인의 리뷰를 활용하여 부족한 도서 도메인의 추천에 활용하는 Cross-Domain Recommendation.
핵심 문제	영화 취향이 모두 도서 추천에 유용하지 않음. "놀란 감독 팬" 같은 정보는 관련 없는 도서 추천을 유발. 이를 Negative Transfer 라 함.
해결 방법	Profiler (GPT-4o-mini): 리뷰에서 구조화된 선호 패턴 추출. Transfer Judge (Qwen3-14B, QLoRA): 패턴별 전이 가능 여부 판별(TRANSFER/PARTIAL/BLOCK) 후 추천 생성.
연구 목표	Transfer Gate로 Negative Transfer를 방지하여 Cross-Domain Cold-Start 추천 품질 향상.

1.2 Research Questions

RQ	연구 질문	쉽게 말하면	비교
RQ1	LLM 기반 구조화된 프로파일링이 원본 리뷰 직접 입력 대비 추천 품질을 개선하는가?	영화 리뷰를 "SF 좋아함" 식으로 정리해서 넣는 게, 원문을 그대로 넣는 것보다 나은가?	(c) vs (f)
RQ2	Transfer Gate를 통한 선호 패턴 자동 필터링이 추천 성능에 유의한 영향을 미치는가?	책에 써먹을 수 없는 취향 (예: "놀란 감독 팬")을 걸러내면 추천이 더 정확해지는가?	(c) vs (d)
RQ3	분석과 판단을 별도 에이전트로 분리하고, 판단만 파인튜닝하는 전략이 단일 LLM보다 우수한가?		(a)vs(b)vs(c)

AI 1명이 혼자 하는 것보다 **분석+판단 담당**으로 나누고 판단만 훈련시키면 더 잘하는가?

1.3 개념 정의

Cross-Domain Recommendation (CDR) — 한 분야의 데이터를 다른 분야 추천에 활용.

Source / Target 도메인 — Source: 데이터 풍부(영화), Target: 데이터 부족(책).

Cold-Start — 이력 부족으로 취향 파악 불가.

Negative Transfer — Source 정보가 Target에서 오히려 방해되는 현상.

Profiler / Transfer Judge — 본 프레임워크를 구성하는 두 개의 LLM 컴포넌트.

2. Cold-Start 문제란?

시나리오 예시

Movies & TV: 45편 시청, 상세 리뷰. **Books:** 3권 구매, "재미있었어요" 1개뿐.

우리의 접근: 영화 리뷰에서 패턴 추출 → 책에 전이 가능한 것만 선별 → 추천.

2.1 Cold-Start 기준 정당화: 왜 리뷰 5~10개인가?

구간	리뷰 수	상태	처리
Zero-Shot	0개	Target 정보 전무 → 전이 효과 측정 불가	제외
Cold-Start	5~10개	Target 단독으로는 부족, CDR 효과 검증 가능한 최적 구간	대상
Warm-Start	10개 초과	Target 단독 추천 가능 → CDR 필요성 희석	제외

선행연구 기준: 대부분의 CDR 논문(EMCDR, LLM4CDR 등)은 Target < 20개를 Cold-Start로 정의. 본 연구는 이 범위 내에서 구체화.

하한(5개): 5개 미만이면 Target 선호 파악 불가, 전이 효과 분리 어려움.

상한(10개): 10개 초과 시 Target 단독으로도 충분, Source 전이의 marginal effect 감소.

Source >= 15개: Profiler가 의미 있는 패턴을 추출하기 위한 최소 리뷰 수 (Pilot Study에서 검증).

3. 전체 프로세스 플로우차트

단계	처리 내용	결과물
Step 1	Source/Target 리뷰 수집 및 전처리	Source 최대 30개 + Target 최대 10개
Step 2	Profiler가 선호 패턴을 JSON으로 추출	6~9개 선호 패턴
Step 3	Transfer Judge가 TRANSFER/PARTIAL/BLOCK 판정	전이 결정 결과
Step 4	전이 가능 패턴만으로 Top-10 추천 생성	추천 리스트 + rationale

4. 데이터셋 설명 및 구성

4.1 데이터 소스

Amazon Review 2023 (McAuley Lab). 도메인 간 공통 사용자 존재.

4.2 도메인 구성

구분	Source: Movies & TV	Target: Books
사용자 조건	리뷰 15개 이상	리뷰 5~10개
입력 리뷰 수	최대 30개 (최신순)	전체 (최대 10개)
리뷰당 평균 토큰	~58 tokens/건	~98 tokens/건
토큰 예산	$30 \times 58 = \sim 1,740$ tokens	$10 \times 98 = \sim 980$ tokens

사용자 조건 및 입력 리뷰 수 근거

Source ≥ 15 개: Profiler가 6개 Core Pattern을 안정적으로 추출하기 위한 최소 요건. EMCDR(IJCAI 2019)은 Source 최소 10개, LLM4CDR(WWW 2025)은 5개 사용. 본 연구는 텍스트 리뷰에서 패턴 다양성 확보를 위해 15개로 상향. Pilot Study에서 15개 미만 시 패턴 누락을 검증 예정.

입력 최대 30개: Movies & TV 리뷰 평균 ~58 tokens/건(Amazon Reviews 2023 공식 통계 역산: 1.0B tokens $\div$ 17.3M ratings). $30 \times 58 = \sim 1,740$ tokens + Target ~980 + 프롬프트 ~500 = **총 ~3,220 tokens**으로 GPT-4o-mini context 내 충분. 30개 이상은 새 패턴 발견 확률이 감소(수확 체감).

토큰 통계 출처: Amazon Reviews 2023 공식 페이지 전체 통계 역산; arXiv 2503.07761(CDR + LLM)의 카테고리 별 리뷰 길이 보고(Movies & TV 평균 38.18 words $\approx$ 50 tokens). **EDA에서 실제 P95 토큰 분포 확인 후 입력 수 조정 예정.**

4.3 실험 데이터 규모

- Overlapping User 1,000명 / Train 800 / Val 100 / Test 100
- 후보 아이템: 사용자당 50개 (GT 1 + Negative 49)

데이터 규모 근거

1,000명: TALLRec $\sim$ 600명, LLM4CDR $\sim$ 1,000명 수준. API 비용 $\sim$ \$5 내 현실적 규모.

8:1:1 분할: 추천 시스템 연구 표준 비율. Test 100명에서 Bootstrap CI로 95% 신뢰구간 확보 가능.

4.4 후보 50개 선정 방법

선정 절차:

1. 사용자의 Books 도메인 마지막 구매 아이템(4점 이상)을 GT로 설정
2. 해당 사용자가 구매하지 않은 Books 도메인 아이템 중 49개를 균일 랜덤 샘플링
3. GT 1개 + Negative 49개 = 50개를 섞어 후보 리스트 구성
4. 후보 아이템 정보: 제목 + 카테고리 + 평균 평점을 텍스트로 제공

근거	설명
선행연구 표준	LLM4CDR(WWW 2025)은 후보 20개, He et al.(WWW 2017)은 100개 사용. 50개는 LLM 토큰 한도 내에서 충분한 난이도를 제공
LLM 토큰 제약	후보 1개당 $\sim$ 50 tokens $\times$ 50개 = $\sim$ 2,500 tokens. Profiler Output $\sim$ 800 + 시스템 프롬프트 $\sim$ 500 = 총 $\sim$ 3,800 tokens으로 4,096 시퀀스 길이 내 수용
랜덤 확률 보정	후보 50개 중 랜덤 추천 시 HR@1 기대값 = 2%, HR@10 기대값 = 20% $\rightarrow$ 실질적 성능 측정에 적절한 난이도
균일 랜덤 샘플링	TALLRec, LLM4CDR 등 선행연구와 동일한 프로토콜로 결과 비교 공정. 랜덤 시드 고정(seed=42)으로 모든 Ablation 조건이 동일 후보 셋 공유

5. 컴포넌트별 Input / Output 및 LLM 선정 근거

5.1 Profiler (GPT-4o-mini)

구분	상세 내용
LLM	GPT-4o-mini API (프롬프트 기반, 파인튜닝 없음)
Input	Source 리뷰 최대 30개(~1,740 tokens) + Target 리뷰 전체(~980 tokens) + 프롬프트(~500) ≈ ~3,220 tokens
Output	JSON: 5~8개 선호 패턴 (~800 tokens)

왜 GPT-4o-mini인가?

태스크: 텍스트 분석(Analytical) — 범용 LLM 능력 범위 내, 파인튜닝 불필요.

API 효율: 파인튜닝 불필요 → API 호출이 인프라 없이 최적. \$0.15/1M tokens, 1,000명 ~\$1~2.

재현성: 상용 API는 동일 프롬프트에 일관된 출력 보장.

5.2 Transfer Judge (Qwen3-14B, QLoRA)

구분	상세 내용
LLM	Qwen3-14B-Instruct (QLoRA 파인튜닝)
Input	Profiler Output + 후보 50개 (~3,800 tokens)
Output	transfer_decisions + recommendations Top-10 (~1,500 tokens)

왜 Qwen3-14B-Instruct인가?

오픈소스 필수: QLoRA를 위해 가중치 접근 필요 → GPT 계열 사용 불가.

Instruct 완료: JSON 출력 + 복잡한 지시문 이해 필요 → Instruct 모델이어야 추가 FT 효율적.

벤치마크 최상위: 14B급 오픈소스 중 MMLU 81.05, MMLU-Pro 61.03, BBH 81.07 (Qwen3 Technical Report, 2025).

복잡 추론 능력: MMLU-Pro 61.03 — TRANSFER/PARTIAL/BLOCK 3단계 판정에 요구되는 복잡 추론에 직접적 이점.

대안 비교: LLaMA-3는 8B→70B 점프로 14B급 비교 불가. Gemma-3-12B는 MMLU-Pro 44.91로 열위.

6. Profiler가 추출하는 선호 패턴 정의

6.1 반정형(Semi-Structured) 접근

6개 Core Pattern 필수 분석 + 추가 패턴 자유 추출.

6.2 Core Patterns

Pattern	설명	예시
genre_preference	선호 장르	"Sci-Fi, Thriller"
narrative_complexity	서사 복잡도	"Multi-layered, nonlinear"
pacing_preference	전개 속도	"Fast-paced"
quality_sensitivity	품질 민감도	"Highly critical"
brand_loyalty	브랜드 충성도	"Nolan fan"
sensory_preference	감각적 경험	"Values cinematography"

6.3 패턴 선정 근거: Pilot Study

Pilot Study 설계

100명 샘플: Train 800명의 12.5%. 빈도 순위 안정성 확보를 위한 최소 규모.

6개 컷오프: Top-6 이후 빈도 급감(long-tail)을 확인하여 컷오프 타당성 검증. 빈도 그래프로 시각화.

비구조화 추출: "자유롭게 추출하라"는 지시로 LLM 편향 최소화, 데이터에서 자연스럽게 드러나는 패턴 발견.

7. Transfer Judge가 필요한 이유

✓ **genre_preference:** "SF, Thriller" → 그대로 전이 가능.

△ **sensory_preference:** "영상미 중시" → "묘사력 중시"로 변환 가능.

✗ **brand_loyalty:** "놀란 감독 팬" → 전이 불가. 차단 필요.

왜 분리? 패턴 추출(Analytical)과 전이 판단(Judgmental)은 인지적으로 다른 태스크. 두 역할을 분리하면 각 LLM이 자신의 태스크에 특화되어 품질이 향상된다.

8. Transfer Gate: 전이 판정 3단계 정의

판정	정의	예시
TRANSFER	양쪽 도메인에 공통 존재. 변환 없이 적용.	"SF 장르 선호"
PARTIAL	의미적 변환으로 활용 가능.	"영상미" → "묘사력"
BLOCK	대응 개념 없음. 완전 배제.	"놀란 감독 팬"

왜 3단계인가? — 선행연구 근거

기존 연구에서 negative transfer의 원인과 강도가 다층적임은 이미 인식되어 왔다 (Zhang et al. 2023; TrineCDR 2024). 그러나 이를 실제 전이 판정에 반영하여 이산적 multi-level decision으로 구현한 연구는 본 연구가 최초이다.

논문	학회	관련성
Zhang & Wu, "Survey on NT"	IEEE/CAA JAS 2023	NT 완화 접근을 Domain/Instance/Feature 3단계로 분류 — 이론적 근거
TrineCDR	KDD 2024	NT 원인을 Feature/Interaction/Domain 3 level로 분류 — 직접적 동기
Wang et al.	CVPR 2019	NT의 3가지 요인 식별 + gate 기반 filtering — 방법론적 선례
SAN (Cao et al.)	CVPR 2018	Binary selective transfer — PARTIAL 확장 필요성의 근거
FedGCDR	NeurIPS 2024	Soft/Hard NT 구분 — NT 강도 차이 근거
Park et al.	CIKM 2023	Shapley 연속 가중치 — 이산 판정 발전 선례

핵심 설계 원칙: Transfer Judge의 추천 rationale에는 BLOCK 판정된 패턴이 절대 등장해서는 안 된다.

9. Teacher Distillation: 학습 데이터 생성

9.1 왜 Teacher Distillation인가?

Transfer Gate의 3단계 판정은 본 연구가 새롭게 정의한 태스크이므로, 기존에 레이블링된 데이터셋이 존재하지 않는다.

대안	장점	한계	적합성
(A) 수동 레이블링	정확도 최고	800건 × 6~9패턴 = 5,000건+ 판정 필요, 비현실적 비용	✗
(B) Teacher Distillation	비용 효율적, 일관성 높음	Teacher 품질에 의존	✓ 채택
(C) Self-Training	Teacher 불필요	초기 품질 매우 낮음, 수렴 불안정	✗

9.2 선행연구 근거

Knowledge Distillation: 대형 Teacher LLM이 생성한 합성 데이터로 소형 Student 모델을 학습시키는 것은 NLP에서 확립된 방법론 (Hinton et al. 2015).

TALLRec (RecSys 2023): 50건 미만의 학습 데이터만으로도 추천 능력 달성 보고 → 본 연구의 700건은 충분한 규모.

Chain-of-Thought Distillation: Teacher가 rationale을 포함한 출력을 생성하고 Student가 학습하면, 단순 레이블만 학습하는 것보다 일반화 성능 향상 (Wei et al. 2022).

9.3 Teacher에게 GT를 제공하는 이유

GT를 제공하는 것은 **정답 암기가 아니라 올바른 판정 과정(rationale) 시연을 위함**이다. GT를 알려주면 Teacher는 "이 아이템이 추천되어야 하는 이유"를 역추론하여, 어떤 패턴이 TRANSFER이고 어떤 것이 BLOCK인지를 일관성 있게 판정할 수 있다. Student는 **과정(process)**을 학습하며, 추론 시에는 GT 없이 수행된다.

9.4 품질 필터링 (4단계)

단계	검증 항목	기준
1. 형식 검증	JSON 파싱 성공 여부	파싱 실패 시 재시도 (최대 3회)

2. 완전성 검증	transfer_decisions에 모든 패턴 판정 포함	누락 시 제외
3. 정확성 검증	GT가 Top-10 내 포함	미포함 시 Teacher 판정 실패로 제외
4. BLOCK 누출 검사	rationale에 BLOCK 판정 패턴 미등장	누출 시 핵심 설계 원칙 위반으로 제외

일관성 검사: Pilot 10명 대상 Teacher를 2회 실행(temperature=0)하여 판정 일치율 확인 (90% 이상 시 진행).

필터링 통과율 목표: 80% 이상 (800명 → 700건 이상 확보).

10. 평가 프로토콜: Leave-One-Out

10.1 개요

Leave-One-Out(LOO)은 추천 시스템 평가에서 가장 널리 사용되는 프로토콜로, 각 사용자의 마지막 상호작용 1개를 테스트용으로 분리하고 나머지로 모델을 추론한다.

10.2 LOO 적용 절차

각 Test 사용자 u 에 대해:

1. Target(Books) 도메인의 마지막 구매 아이템 중 평점 4점 이상인 것을 GT로 설정
2. GT를 제외한 나머지 Target 리뷰(최대 9개)를 Profiler 입력으로 사용
3. Source(Movies & TV) 리뷰 최대 30개를 Profiler 입력으로 사용
4. Profiler → Transfer Judge → Top-10 추천 생성
5. GT가 Top-K에 포함되는지로 HR@K, NDCG@K, MRR 계산

10.3 핵심 설계 결정

결정	선택	근거
GT 선정	마지막 구매 + 4점 이상	시간순으로 가장 최근의 긍정적 상호작용이 현재 선호를 가장 잘 반영
GT 평점 제한	4점 이상만	3점 이하는 부정/중립 평가로, GT로 삼으면 "추천 성공"의 정의가 모호
후보 구성	GT 1 + Negative 49 = 50	섹션 4.4의 후보 선정 근거 참조
GT 제외	Target 리뷰에서 GT 제거 후 입력	정보 누출(data leakage) 방지
LOO 단위	사용자당 1개	Cold-Start 사용자의 Target 리뷰를 더 줄이면 Profiler 입력 품질 저하

10.4 왜 LOO인가?

프로토콜	설명	한계	선택
Leave-One-Out	마지막 아이템 1개 평가	사용자당 1회 → Bootstrap CI로 보완	✓ 채택
K-fold	상호작용 K개 분할 교차 평가	Cold-Start(5~10개) 더 분할 시 입력 부족	✗

선행연구 일치: TALLRec, LLM4CDR, TrineCDR, He et al.(2017) 모두 LOO 프로토콜 사용 → 결과 비교 가능.

10.5 평가 흐름 요약

Input: Source 리뷰 30개 + Target 리뷰 최대 9개 (GT 제외)

↓ Profiler: 선호 패턴 JSON 추출

↓ Transfer Judge: 패턴별 TRANSFER/PARTIAL/BLOCK 판정

↓ Output: Top-10 추천 리스트 (후보 50개 중 순위화)

↓ 평가: GT의 순위 확인 → HR@1, HR@5, HR@10, NDCG@10, MRR 계산

11. Research Question별 검증 방법

11.1 Ablation Study 전체 설계

조건	구성	검증 목적
(a) Single LLM	단일 프롬프트로 전체 수행	베이스라인 (LLM4CDR 재현)
(b) Profiler-Judge (Prompt)	Profiler(P) + Judge(P), 프롬프트 기반	Profiler-Judge 분리 효과
(c) Ours ★	Profiler(P) + Judge(QLoRA)	파인튜닝 효과
(d) P-J w/o Gate	Judge(FT), 모든 패턴 TRANSFER 강제	Transfer Gate 효과
(e) 전통 CDR	비LLM 임베딩 기반	LLM 접근 우위
(f) Raw Review	Profiler 생략, raw review 직접 입력	구조화 프로파일 효과

11.2 평가 지표

지표	설명
HR@1	1위 추천이 정답인 비율
HR@5	Top-5에 정답 포함 비율
HR@10	Top-10에 정답 포함 비율
NDCG@10	정답의 순위를 고려한 점수
MRR	정답 순위 역수의 평균

11.3 통계적 유의성: Bootstrap Confidence Interval

Test 100명에서 1,000회 부트스트랩으로 95% 신뢰구간 산출.

논문 표기: $HR@10 = 0.72$ (95% CI: 0.64-0.79)

12. 참고문헌

12.1 핵심 인용 논문

#	논문	학회	인용 맥락
1	Bao et al., "TALLRec"	RecSys 2023	QLoRA 기반 LLM 추천 파인튜닝의 이론적 근거. 50건 미만 학습 데이터로도 추천 능력 달성 → Teacher Distillation 데이터 규모 (700건) 충분성 근거
2	TrineCDR (Chen et al.)	KDD 2024	NT 원인을 Feature/Interaction/Domain 3 level로 분류 → Transfer Gate 3단계의 개념적 근거
3	LLM4CDR (Zhao et al.)	WWW 2025	Single LLM + 프롬프트 CDR. 가장 직접적인 비교 대상(베이스라인)
4	Zhang & Wu, "Survey on NT"	IEEE/CAA JAS 2023	NT 완화 접근을 Domain/Instance/Feature 3단계로 분류한 서베이 — 이론적 토대
5	Wang et al.	CVPR 2019	NT의 3가지 요인 식별 + gate 기반 filtering — Transfer Gate 방법론적 선례
6	Cao et al. (SAN)	CVPR 2018	Binary selective transfer의 한계 → PARTIAL 등급 확장 필요성 근거
7	FedGCDR (Liu et al.)	NeurIPS 2024	Soft/Hard NT 구분 — NT 강도 차이의 실증적 근거
8	Park et al.	CIKM 2023	Shapley 연속 가중치 기반 전이 조절 — 이산 판정 발전 동기
9	McAuley Lab, Amazon Review 2023	Dataset	실험 데이터셋 소스

12.2 방법론 근거 논문

#	논문	학회	인용 맥락
10	Hinton et al., "Distilling the Knowledge in a Neural Network"	NeurIPS WS 2015	Knowledge Distillation 원론적 근거. Teacher-

			Student 패러다임의 이론적 토대
11	Wei et al., "Chain-of-Thought Prompting"	NeurIPS 2022	CoT rationale 포함 학습이 일반화 성능 향상 → Teacher rationale 포함 출력 설계 정당화
12	Hu et al., "LoRA"	ICLR 2022	LoRA/QLoRA 파인튜닝 방법론의 원론적 근거
13	Dettmers et al., "QLoRA"	NeurIPS 2023	4-bit 양자화 + LoRA 효율성 검증. 제한된 GPU에서 14B 파인튜닝 가능성 근거
14	Qwen Team, "Qwen3 Technical Report"	arXiv 2025	Qwen3-14B 벤치마크 성능 데이터. Transfer Judge LLM 선정 근거

12.3 평가 방법론 근거 논문

#	논문	학회	인용 맥락
15	He et al., "Neural Collaborative Filtering"	WWW 2017	LOO + Random Negative Sampling 평가 프로토콜의 표준 정립
16	Krichene & Rendle, "On Sampled Metrics"	KDD 2020	샘플링 기반 평가(50개 후보)의 이론적 정당성 — 전체 아이템 대비 순위 상관성 유지 증명