

TransferJudge

A Profiler-Judge LLM-Based Framework for Selective Transfer in Cross-Domain Recommendation

선택적 전이를 위한 Profiler-Judge 구조의 LLM 기반 교차 도메인 추천 프레임워크

Pilot Study 완료 · 7개 Core Pattern 확정 (4가지 측면 종합 검토)

2026.05 빅데이터학과 17기 광민아 · Overview v6

1. 핵심 문제 정의

1.1 연구 정의 (Objective)

구분	내용
연구 배경	추천 시스템은 과거 행동 데이터가 충분해야 개인화 추천이 가능. 특정 도메인에서 데이터가 부족한 상황을 Cold-Start 문제라 함.
접근 방식	데이터가 풍부한 영화 도메인의 리뷰를 활용하여 부족한 도서 도메인의 추천에 활용하는 Cross-Domain Recommendation.
핵심 문제	영화 취향이 모두 도서 추천에 유용하지 않음. "놀란 감독 팬" 같은 정보는 관련 없는 도서 추천을 유발. 이를 Negative Transfer 라 함.
해결 방법	Profiler (GPT-4o-mini): 리뷰에서 구조화된 선호 패턴 추출. Transfer Judge (Qwen3-14B, QLoRA): 패턴별 전이 가능 여부 판별(TRANSFER/PARTIAL/BLOCK) 후 추천 생성.
연구 목표	Transfer Gate로 Negative Transfer를 방지하여 Cross-Domain Cold-Start 추천 품질 향상.

1.2 Research Questions

RQ	연구 질문	쉽게 말하면	비교
RQ1	LLM 기반 구조화된 프로파일링이 원본 리뷰 직접 입력 대비 추천 품질을 개선하는가?	영화 리뷰를 "SF 좋아함" 식으로 정리해서 넣는 게, 원문을 그대로 넣는 것보다 나은가?	(c) vs (f)
RQ2	Transfer Gate를 통한 선호 패턴 자동 필터링이 추천 성능에 유의한 영향을 미치는가?	책에 써먹을 수 없는 취향(예: "놀란 감독 팬")을 걸러내면 추천이 더 정확해지는가?	(c) vs (d)

RQ3	분석과 판단을 별도 에이전트로 분리하고, 판단만 파인튜닝하는 전략이 단일 LLM보다 우수한가?	AI 1명이 혼자 하는 것보다 분석+판단 담당 으로 나누고 판단만 훈련시키면 더 잘하는가?	(a)vs(b)vs(c)
------------	--	---	---------------

1.3 핵심 개념

추천 시스템과 Cold-Start 문제

추천 시스템은 사용자의 과거 행동 데이터(구매, 평점, 리뷰 등)를 분석하여 개인화된 아이템을 제안한다. 그러나 이 접근은 **충분한 데이터가 있을 때만 작동**한다. 새로운 서비스에 가입하거나, 기존 사용자가 새로운 카테고리 탐색할 때처럼 행동 이력이 부족한 상황에서는 취향을 파악할 수 없어 추천 품질이 크게 저하된다. 이를 **Cold-Start 문제**라 한다.

Cold-Start의 실제 영향

예를 들어, 영화 스트리밍 서비스에서 45편의 영화를 시청하고 상세 리뷰를 남긴 사용자가 전자책 서비스를 새로 시작했다고 하자. 책은 3권만 구매했고, 리뷰는 "재미있었어요" 1건뿐이다. 이 사용자에게 어떤 책을 추천해야 할까? — 책 구매 이력만으로는 취향을 파악할 수 없다.

Cross-Domain Recommendation (CDR)

CDR은 Cold-Start 문제의 해결책 중 하나로, **데이터가 풍부한 도메인(Source)의 정보를 활용하여 데이터가 부족한 도메인(Target)의 추천을 보완**하는 접근법이다. 핵심 가정은 "한 도메인에서의 선호가 다른 도메인의 선호를 예측하는 데 도움이 된다"는 것이다.

개념	설명	본 연구에서
Source 도메인	사용자 데이터가 풍부한 도메인	Movies & TV (리뷰 15개 이상)
Target 도메인	사용자 데이터가 부족한 도메인 (Cold-Start)	Books (리뷰 5~10개)
전이(Transfer)	Source에서 추출한 선호 패턴을 Target 추천에 활용	"SF 장르 선호" → SF 소설 추천

Negative Transfer — CDR의 핵심 리스크

그러나 Source의 모든 정보가 Target에 유용한 것은 아니다. 영화 도메인에서 추출한 선호 중 일부는 책 추천과 무관하거나 오히려 해로울 수 있다. 이처럼 Source 정보가 Target 추천 품질을 오히려 저하시키는 현상을 **Negative Transfer**라 한다.

Negative Transfer 예시

✓ "SF 장르 선호" → SF 소설 추천에 유용 (**Positive Transfer**)

△ "영상미 중시" → "묘사력 중시"로 변환하면 활용 가능 (**Partial Transfer**)

✕ "놀란 감독 팬" → 책에는 영화 감독이 없음. 이 패턴을 그대로 전이하면 무관한 책이 추천됨 (**Negative Transfer**)

TransferJudge의 핵심 아이디어: 이 문제를 해결하기 위해 본 연구는 Transfer Gate를 도입하여 각 선호 패턴을 TRANSFER / PARTIAL / BLOCK으로 판정하고, Negative Transfer를 사전에 차단한 뒤 추천을 생성한다.

컴포넌트	역할	구현
Profiler	Source/Target 리뷰에서 구조화된 선호 패턴 추출	GPT-4o-mini (프롬프트 기반)
Transfer Judge	패턴별 전이 가능 여부를 3단계로 판정 + 추천 생성	Qwen3-14B (QLoRA 파인튜닝)

2. Cold-Start 문제와 CDR의 필요성

2.0 왜 Cold-Start가 중요한가?

현대 추천 시스템은 사용자 행동 데이터에 기반하므로, 데이터가 부족한 상황에서는 구조적으로 성능이 저하된다. Cold-Start는 다음과 같은 실제 시나리오에서 발생한다:

- **신규 사용자**: 서비스에 처음 가입한 사용자는 행동 이력이 없음
- **도메인 확장**: 기존 사용자가 새로운 카테고리(예: 영화→책)를 탐색할 때
- **장기 미활동 후 복귀**: 과거 이력이 현재 취향을 반영하지 못함

기존 해결 방법(인기 아이템 추천, 인구통계 기반)은 **개인화가 불가능**하다는 한계가 있다. CDR은 "다른 도메인의 풍부한 데이터"를 활용하여 이 문제를 개인화된 방식으로 해결한다.

2.1 본 연구의 시나리오

구체적 시나리오

Movies & TV: 45편 시청, 상세 리뷰 (Source — 데이터 풍부).

Books: 3권 구매, "재미있었어요" 1건뿐 (Target — Cold-Start).

기존 방식: 책 3권의 이력만으로 추천 → 취향 파악 불가, 베스트셀러 추천에 그침.

CDR 방식: 영화 45편의 리뷰에서 선호 패턴 추출 → 책에 전이 가능한 것만 선별 → **개인화된** 추천.

TransferJudge: 여기에 Transfer Gate를 추가하여 전이 불가능한 패턴을 자동 차단 → Negative Transfer 방지.

2.2 Cold-Start 기준 정당화: 왜 리뷰 5~10개인가?

구간	리뷰 수	상태	처리
Zero-Shot	0개	Target 정보 전무 → 전이 효과 측정 불가	제외
Cold-Start	5~10개	Target 단독으로는 부족, CDR 효과 검증 가능한 최적 구간	대상
Warm-Start	10개 초과	Target 단독 추천 가능 → CDR 필요성 희석	제외

선행연구 기준: 대부분의 CDR 논문(EMCDR, LLM4CDR 등)은 Target < 20개를 Cold-Start로 정의. 본 연구는 이 범위 내에서 구체화.

하한(5개): 5개 미만이면 Target 선호 파악 불가, 전이 효과 분리 어려움.

상한(10개): 10개 초과 시 Target 단독으로도 충분, Source 전이의 marginal effect 감소.

Source >= 15개: Profiler가 의미 있는 패턴을 추출하기 위한 최소 리뷰 수 (Pilot Study에서 검증).

3. 전체 프로세스 플로우차트

단계	처리 내용	결과물
Step 1	Source/Target 리뷰 수집 및 전처리	Source 최대 30개 + Target 최대 10개
Step 2	Profiler가 선호 패턴을 JSON으로 추출	6~9개 선호 패턴
Step 3	Transfer Judge가 TRANSFER/PARTIAL/BLOCK 판정	전이 결정 결과
Step 4	전이 가능 패턴만으로 Top-10 추천 생성	추천 리스트 + rationale

4. 데이터셋 설명 및 구성

4.1 데이터 소스

Amazon Review 2023 (McAuley Lab). 도메인 간 공통 사용자 존재.

4.2 도메인 구성

구분	Source: Movies & TV	Target: Books
사용자 조건	리뷰 15개 이상	리뷰 5~10개
입력 리뷰 수	최대 30개 (최신순)	전체 (최대 10개)
리뷰당 평균 토큰	~58 tokens/건	~98 tokens/건
토큰 예산	$30 \times 58 = \sim 1,740$ tokens	$10 \times 98 = \sim 980$ tokens

사용자 조건 및 입력 리뷰 수 근거

Source ≥ 15 개: Profiler가 7개 Core Pattern을 안정적으로 추출하기 위한 최소 요건. EMCDR(IJCAI 2019)은 Source 최소 10개, LLM4CDR(WWW 2025)은 5개 사용. 본 연구는 텍스트 리뷰에서 패턴 다양성 확보를 위해 15개로 상향. Pilot Study에서 15개 미만 시 패턴 누락을 검증 예정.

입력 최대 30개: Movies & TV 리뷰 평균 ~58 tokens/건(Amazon Reviews 2023 공식 통계 역산: 1.0B tokens $\div$ 17.3M ratings). $30 \times 58 = \sim 1,740$ tokens + Target ~980 + 프롬프트 ~500 = **총 ~3,220 tokens**으로 GPT-4o-mini context 내 충분. 30개 이상은 새 패턴 발견 확률이 감소(수확 체감).

토큰 통계 출처: Amazon Reviews 2023 공식 페이지 전체 통계 역산; arXiv 2503.07761(CDR + LLM)의 카테고리 별 리뷰 길이 보고(Movies & TV 평균 38.18 words $\approx$ 50 tokens). **EDA에서 실제 P95 토큰 분포 확인 후 입력 수 조정 예정.**

4.3 실험 데이터 규모

- Overlapping User 1,000명 / Train 800 / Val 100 / Test 100
- 후보 아이템: 사용자당 50개 (GT 1 + Negative 49)

데이터 규모 근거

1,000명: TALLRec $\sim$ 600명, LLM4CDR $\sim$ 1,000명 수준. API 비용 $\sim$ \$5 내 현실적 규모.

8:1:1 분할: 추천 시스템 연구 표준 비율. Test 100명에서 Bootstrap CI로 95% 신뢰구간 확보 가능.

4.4 선행연구 데이터 구성 비교

항목	TALLRec (RecSys 2023)	LLM4CDR (WWW 2025)	EMCDR (IJCAI 2017)	TrineCDR (KDD 2024)	본 연구
데이터셋	MovieLens + Amazon	Amazon 2018 (5-core)	Amazon (5-core)	Amazon + Douban	Amazon 2023
사용자 필터	Few-shot (16~256건)	Rating=5.0 구매>20	5-core	10-core	Source $\geq$ 15 Target 5~10
날짜 필터	없음	없음	없음	없음	없음 (EDA 보고)
리뷰 텍스트	미사용	미사용	미사용	미사용	사용 (핵심 입력)
후보 수	없음 (binary)	20개	없음 (RMSE)	100개	50개
GT 방식	Implicit	5점만	Implicit	Implicit	Explicit ($\geq$ 4)

리뷰 텍스트 활용: 조사한 CDR 선행연구 4편 모두 리뷰 텍스트를 사용하지 않고 평점/상호작용만 활용. 본 연구는 리뷰 텍스트에서 선호 패턴을 추출하는 최초의 LLM 기반 CDR 프레임워크로, 이것이 핵심 차별점이다.

날짜 필터: 선행연구 4편 모두 시간 필터 미적용. 본 연구도 동일하되, EDA에서 시점 분포를 보고하여 타당성 문서화.

4.5 Ground Truth 선정 및 근거

GT 선정: 각 사용자의 Books 도메인에서 rating $\geq$ 4인 구매 중 가장 최근 아이템 1개

논문	GT 방식	평점 처리
NCF (He et al., WWW 2017)	마지막 상호작용	모든 평점 → implicit(1) 변환
TALLRec (RecSys 2023)	마지막 상호작용	4점 이상=Yes, 미만=No
LLM4CDR (WWW 2025)	마지막 상호작용	5점만 남기고 전처리
TrineCDR (KDD 2024)	마지막 상호작용	implicit 변환
본 연구	4점 이상 중 가장 최근	Explicit positive (≥4)

왜 Implicit이 아닌 Explicit Positive인가?

Transfer Gate는 Negative Transfer를 방지하여 **사용자가 만족할 아이템**을 추천하는 것이 목표이다. Implicit 방식 (구매=positive)에서는 2점짜리 GT를 "맞혀야 할 정답"으로 취급하게 되어, Transfer Gate가 올바르게 BLOCK한 판단이 오히려 **성능 하락**으로 측정되는 문제가 발생한다.

연구 목적 정합성: Transfer Gate → "좋은 추천" 필터링 → GT도 "만족한 아이템"이어야 효과 정확 측정

Negative Transfer 증명: GT가 positive여야 "TRANSFER해서 맞힌 것" vs "BLOCK해서 놓친 것" 구분 가능

LLM4CDR 비교: LLM4CDR은 5점만 사용 — 본 연구는 4점 이상으로 더 현실적

입력 리뷰: Profiler 입력은 1~5점 전체 사용 (낮은 평점도 "무엇을 싫어하는지" 패턴 추출에 기여)

한눈에 보는 Implicit vs Explicit Positive

방식	정답(GT)으로 인정하는 기준	비유
Implicit (구매 =positive)	"구매했다" → 무조건 좋아한 것으로 간주 (평점 1점도 정답으로 취급)	장바구니에 담은 모든 책을 "이 사람이 좋아하는 책"이라고 가정. 환불·후회한 책도 포함됨.
Explicit Positive ★ (rating ≥ 4)	"4점 이상 평점을 줬다" → 명시적으로 만족한 것만 정답	실제로 별점 4~5점을 준 책만 "정말 좋아하는 책"으로 인정. 후회한 구매는 제외.

구체 시나리오	Implicit이라면	Explicit Positive라면
사용자가 영화 "놀란 감독 팬"이라 책 분야에서 도 "놀란 자서전(2점)"을 구매 (Negative Transfer 사례)	"놀란 자서전 = 정답" → Transfer Gate가 brand_loyalty를 BLOCK해서 추천 안 함 → 성능 하락 으로 측정 → Gate의 올바른 판단이 왜곡 평가	"놀란 자서전(2점) = 정 답 아님" → Gate가 올바르게 BLOCK → Gate 효과 정확 반영

사용자가 "복잡한 서사 선호" 패턴이 있고 "Cloud Atlas(5점)"를 구매	"Cloud Atlas = 정답" → TRANSFER로 추천 시 점수 ↑ → 정상 측정	"Cloud Atlas = 정답" → TRANSFER로 추천 시 점수 ↑ → 정상 측정
--	--	---

핵심 정리: Implicit 방식에서는 "사용자가 후회한 구매(낮은 평점)"까지 정답 취급하므로, Transfer Gate가 그것을 BLOCK한 **올바른 판정**이 평가에서 "맞히지 못한 것"으로 잘못 측정된다. Explicit Positive는 "사용자가 진짜 만족한 것"만 정답으로 두어, BLOCK의 가치를 정확히 측정 가능하게 한다.

즉, 본 연구의 핵심 가설(Transfer Gate가 부정 전이를 막아 추천 품질을 높인다)을 검증하려면 GT가 Explicit Positive여야 한다.

4.5 후보 50개 선정 방법

선정 절차:

1. 사용자의 Books 도메인에서 rating ≥ 4 인 구매 중 **가장 최근 아이템**을 GT로 설정
2. 해당 사용자가 구매하지 않은 Books 도메인 아이템 중 49개를 균일 랜덤 샘플링
3. GT 1개 + Negative 49개 = 50개를 섞어 후보 리스트 구성
4. 후보 아이템 정보: 제목 + 저자 + 카테고리 + 평균 평점을 텍스트로 제공

근거	설명
선행연구 표준	LLM4CDR(WWW 2025)은 후보 20개, He et al.(WWW 2017)은 100개 사용. 50개는 LLM 토큰 한도 내에서 충분한 난이도를 제공
LLM 토큰 제약	후보 1개당 ~50 tokens $\times$ 50개 = ~2,500 tokens. Profiler Output ~800 + 시스템 프롬프트 ~500 = 총 ~3,800 tokens으로 4,096 시퀀스 길이 내 수용
랜덤 확률 보정	후보 50개 중 랜덤 추천 시 HR@1 기대값 = 2%, HR@10 기대값 = 20% → 실질적 성능 측정에 적절한 난이도
균일 랜덤 샘플링	TALLRec, LLM4CDR 등 선행연구와 동일한 프로토콜로 결과 비교 공정. 랜덤 시드 고정(seed=42)으로 모든 Ablation 조건이 동일 후보 셋 공유

5. 컴포넌트별 Input / Output 및 LLM 선정 근거

5.1 Profiler (GPT-4o-mini)

구분	상세 내용
LLM	GPT-4o-mini API (프롬프트 기반, 파인튜닝 없음)
Input	Source 리뷰 최대 30개(~1,740 tokens) + Target 리뷰 전체(~980 tokens) + 프롬프트(~500) ≈ ~3,220 tokens
Output	JSON: 5~8개 선호 패턴 (~800 tokens)

왜 GPT-4o-mini인가?

태스크: 텍스트 분석(Analytical) — 범용 LLM 능력 범위 내, 파인튜닝 불필요.

API 효율: 파인튜닝 불필요 → API 호출이 인프라 없이 최적. \$0.15/1M tokens, 1,000명 ~\$1~2.

재현성: 상용 API는 동일 프롬프트에 일관된 출력 보장.

5.2 Transfer Judge (Qwen3-14B, QLoRA)

구분	상세 내용
LLM	Qwen3-14B-Instruct (QLoRA 파인튜닝)
Input	Profiler Output + 후보 50개 (~3,800 tokens)
Output	transfer_decisions + recommendations Top-10 (~1,500 tokens)

왜 Qwen3-14B-Instruct인가?

오픈소스 필수: QLoRA를 위해 가중치 접근 필요 → GPT 계열 사용 불가.

Instruct 완료: JSON 출력 + 복잡한 지시문 이해 필요 → Instruct 모델이어야 추가 FT 효율적.

벤치마크 최상위: 14B급 오픈소스 중 MMLU 81.05, MMLU-Pro 61.03, BBH 81.07 (Qwen3 Technical Report, 2025).

복잡 추론 능력: MMLU-Pro 61.03 — TRANSFER/PARTIAL/BLOCK 3단계 판정에 요구되는 복잡 추론에 직접적 이점.

대안 비교: LLaMA-3는 8B→70B 점프로 14B급 비교 불가. Gemma-3-12B는 MMLU-Pro 44.91로 열위.

6. Profiler가 추출하는 선호 패턴 정의

6.1 반정형(Semi-Structured) 접근

7개 Core Pattern 필수 분석 + 추가 패턴 자유 추출.

6.2 Core Patterns (Pilot Study 검증 결과)

Pattern	설명	예시	Transfer Gate	Pilot sim
genre_preference	선호 장르	"Sci-Fi, Thriller"	TRANSFER	0.70
narrative_complexity	서사 복잡도	"Multi-layered, nonlinear"	TRANSFER	0.80 (직접)
pacing_preference	전개 속도	"Fast-paced"	TRANSFER	0.81
quality_sensitivity	품질 민감도	"Highly critical"	PARTIAL	0.55
brand_loyalty	브랜드 충성도	"Nolan fan"	BLOCK 후보	0.70
sensory_preference	감각적 경험	"Values cinematography"	BLOCK 후보	0.59
emotional_resonance ★	감정적 울림	"Stayed with me for days"	TRANSFER	0.82 (직접)

★ = Pilot Study에서 emerge한 패턴 (14% 빈도, 직접 매칭)

6.3 패턴 선정 근거: Pilot Study (실행 완료, 2026-04)

항목	값
샘플 규모	100명 (Train 800 中, seed=42)
비용	\$0.081 (GPT-4o-mini)
이론 anchor	Thet et al. (2010) 영화 리뷰 aspect mining + Liu (2012) ABSA
검토 측면	이론 정합성 · Pilot 발현 · Cross-Domain 적합성 · 직교성 (4가지 종합)
사전 검토 결과	5/5 통과 (7/7 패턴 sim ≥ 0.5 , 직교성 max $0.669 \leq 0.7$, BLOCK 후보 자동 식별)
자유 추출 한계	391 canonical 中 90.8%가 비-CDR-적합 → 명시 prompt 설계 데이터 정당화
채택 결정	7/7 ACCEPT (REJECT 0): 4 일반 + 1 조건부 + 1 BLOCK 후보 + 1 보완 필요

자기참조 회피 메커니즘

패턴 정의는 외부 학술(Thet 2010, Liu 2012)에서 도출, 검증은 본 연구가 직접 매칭하지 않고 sentence-transformers cosine similarity 자동 매칭이 수행. 사전 검토 5항목을 Pilot 결과 분석 전에 정해두어 짜맞춤을 방지.

관련 산출 문서

- docs/Pilot_Study_Report.md — Pilot Study 보고서 (전체 결과)
- docs/TransferJudge_Pilot_Report_v3.pdf — 시각화된 Pilot 보고서 (9p, 본인 검토용)
- prompts/core_patterns_definition.md — 7개 패턴 정의서 + 5단계 선정 절차

6.4 Profiler Input / Output 예시

Input (Source 리뷰 — 최신순 15~30개 발췌):

```
[Review 1] Rating: 5/5 | "Another brilliant Nolan epic, the time-loop structure was genius"
  ↑      ↑      ↑      ↑
리뷰 번호 별점(5점=강한 긍정) 감독 충성도 신호 복잡한 서사 선호 신호

[Review 2] Rating: 5/5 | "Cinematography alone makes this a masterpiece"
                ↑
            영상미 중시 → sensory_preference 신호 (영화 매체 한정)

[Review 3] Rating: 2/5 | "Generic rom-com, predictable and boring"
  ↑      ↑      ↑
낮은 점수도 사용 (싫어하는 장르 신호) rom-com 비선호 단순한 서사 비선호

[Review 4] Rating: 4/5 | "Slow-burn but rewarding character study"
                ↑
            느린 전개 선호 → pacing_preference 신호

... (총 15~30개, 토큰 예산 ~2,400 tokens)
```

Input 핵심 포인트:

- 최신순 정렬 — 최근 취향이 더 정확. Review 10이 가장 최근.
- 전체 평점 사용 (1~5점) — 낮은 평점도 "싫어하는 것"의 정보. GT만 4점 이상 제한.
- 제목 + 본문 모두 포함 — 짧은 제목에도 강한 감정 신호 ("masterpiece", "boring") 존재.

Output (Profiler가 추출한 JSON 일부):

```
{
  "core_patterns": {
    "narrative_complexity": {
      // ← 7개 패턴 중 하나
```

```

    "value": "Strongly prefers complex, multi-layered narratives",
    "evidence": ["Review 1: 'time-loop structure was genius'"],
    // ↑ 원문 인용 — 패턴이 데이터에 근거함을 증명 (hallucination 방지)
    "confidence": 0.85, // ← 0~1, 값이 클수록 강한 신호
    "polarity": "positive", // ← 좋아함/싫어함/혼합
    "transferability_hint": "high" // ← Books 도메인으로 전이 쉬움 힌트
  },
  "brand_loyalty": {
    "value": "Strong loyalty to Christopher Nolan",
    "confidence": 0.80,
    "polarity": "positive",
    "transferability_hint": "low" // ← ★ 영화감독은 책에 매핑 어려움
    // → Judge에게 "BLOCK 후보" 신호
  }
  // genre_preference, pacing_preference, quality_sensitivity, sensory_preference, emotional_re
  // (총 7개 Core + 추가 패턴 최대 3개)
},
"summary": "Sophisticated viewer preferring complex, slow-burn narratives..."
// ↑ 사람이 한눈에 이해 가능한 2~3문장 요약 (Judge의 추가 컨텍스트)
}

```

Output 핵심 포인트:

- **evidence (원문 인용)**: Profiler가 "왜 이 패턴이라 판단했는지" 증거. Judge·심사위원 검증 가능.
- **confidence (신뢰도 0~1)**: 약한 신호 패턴은 Judge가 필터링하거나 비중 낮춤.
- **polarity (극성)**: positive(선호) / negative(비선호) / mixed. "싫어하는 장르"도 추천 회피에 활용.
- **transferability_hint**: Profiler가 주는 초기 힌트일 뿐, 최종 TRANSFER/PARTIAL/BLOCK 판정은 Judge가 결정.

7. Transfer Judge가 필요한 이유

- ✓ **genre_preference**: "SF, Thriller" → 그대로 전이 가능.
- △ **sensory_preference**: "영상미 중시" → "묘사력 중시"로 변환 가능.
- ✗ **brand_loyalty**: "놀란 감독 팬" → 전이 불가. 차단 필요.

왜 분리? 패턴 추출(Analytical)과 전이 판단(Judgmental)은 인지적으로 다른 태스크. 두 역할을 분리하면 각 LLM이 자신의 태스크에 특화되어 품질이 향상된다.

7.1 Transfer Judge Input / Output 예시

Input (Profiler Output + 후보 50개 일부):

```
{
  "user_profile": { "core_patterns": { ...섹션 6.4의 Profiler 출력 그대로... } },
  // ↑ Profiler가 추출한 7개 패턴 JSON을 통째로 입력 (구조화된 사용자 프로파일)

  "candidates": [
    { "id": "B002", "title": "Cloud Atlas", "author": "David Mitchell",
      "categories": "Literary Fiction", "rating": 4.0,
      "synopsis": "Six nested timelines spanning centuries..." },
    // ↑ 후보 1개 정보: 제목 + 저자 + 카테고리 + 평균평점 + 줄거리 첫 50 토큰
    //   Judge가 패턴 매칭 판단할 수 있도록 충분한 정보 제공

    { "id": "B045", "title": "Nolan biography", "author": "T. Shone",
      "categories": "Biography", "rating": 4.2, "synopsis": "..."},
    // ↑ ★ 함정 케이스: "Nolan"이라는 이름이 들어 있지만 저자는 다름
    //   사용자가 영화감독 Nolan의 팬이라고 해서 이 책을 추천하면 Negative Transfer

    ... (총 50개: GT 1개 + 사용자가 구매하지 않은 Books 무작위 49개 shuffle)
  ]
}
```

Input 핵심 포인트:

- Profiler 출력을 그대로 입력 — 두 LLM이 JSON 스키마를 공유하여 정보 손실 없음.
- 후보당 5개 필드 — 제목·저자·카테고리·평점·줄거리. Judge의 패턴별 매칭 근거.
- shuffle 후 입력 — GT 위치 노출 방지 (LOO 평가 시에도 동일).

Output (transfer_decisions + Top-10):

```
{
  "transfer_decisions": {
    "narrative_complexity": { "decision": "TRANSFER",
      // ↑ 패턴이 책에도 그대로 적용 가능
      "rationale": "Multi-layered storytelling is medium-agnostic.",
      // ↑ 왜 TRANSFER인지 설명 (Chain-of-Thought 학습용)
      "confidence": 0.90 },

    "brand_loyalty": { "decision": "BLOCK",
      // ↑ ★ 핵심 — 영화감독 충성도는 책에 전이 불가
      "rationale": "Nolan is a film director, not an author.",
      // ↑ "Nolan biography"를 추천에서 제외할 이유
      "confidence": 0.95 },

    "sensory_preference": { "decision": "BLOCK",
      "rationale": "IMAX cinematography is film-specific.",
      // ↑ 영상미는 책에 존재하지 않음 → 매체 특화 패턴
      "confidence": 0.95 },

    "emotional_resonance": { "decision": "TRANSFER",
```

```

    "rationale": "Emotional impact is medium-agnostic, applies to literary fiction.",
    // ↑ 감정적 울림은 책에도 그대로 적용 (Pilot 도출 패턴)
    "confidence": 0.85}
// genre_preference: PARTIAL (장르 매핑 필요), pacing_preference: TRANSFER (페이싱은 책에도 존재) ...
},

"recommendations": [
  {"rank": 1, "item_id": "B002", "title": "Cloud Atlas", "score": 0.92,
    // ↑ 후보 50개 중 1위로 추천 (점수 0~1)
    "applied_patterns": ["narrative_complexity", "pacing_preference"],
    // ↑ ★ 이 책을 추천한 근거 패턴들 — BLOCK 패턴은 절대 들어가지 않음
    // (만약 brand_loyalty가 여기 있으면 학습 데이터에서 자동 배제: 섹션 9 5단계 필터)

    "reasoning": "Six nested timelines match preference for complex narratives."}
    // ↑ 사람이 읽을 수 있는 추천 근거 (rationale의 추천 버전)

    // rank 2~10 (총 10개 추천)
    // 주의: "Nolan biography(B045)"는 평점 4.2로 높지만 BLOCK 판정으로 Top-10 진입 못함
  ]
}

```

Output 핵심 포인트 — 왜 이게 Transfer Gate의 가치인가?

- "Nolan biography"는 **평점 4.2 (높음)**이지만 BLOCK 판정으로 추천에서 **자동 제외**.
- 단순 평점·인기도 기반 추천이라면 이 책이 추천될 가능성이 있음 → Negative Transfer 발생.
- Transfer Judge는 사용자의 "Nolan 충성도"가 **영화 한정**임을 인식하고 책에는 적용 안 함.
- 이것이 본 연구의 핵심 가설: **BLOCK이 추천 품질을 높인다**.

학습 데이터 품질 자동 검증: applied_patterns 에 BLOCK된 패턴이 들어가면 학습 데이터에서 자동 배제 (섹션 9.4의 5단계 필터 中 ③).

8. Transfer Gate: 전이 판정 3단계 정의

판정	정의	예시
TRANSFER	양쪽 도메인에 공통 존재. 변환 없이 적용.	"SF 장르 선호"
PARTIAL	의미적 변환으로 활용 가능.	"영상미" → "묘사력"
BLOCK	대응 개념 없음. 완전 배제.	"놀란 감독 팬"

왜 3단계인가? — 선행연구 근거

기존 연구에서 negative transfer의 원인과 강도가 다층적임은 이미 인식되어 왔다 (Zhang et al. 2023; TrineCDR 2024). 그러나 이를 실제 전이 판정에 반영하여 이산적 multi-level decision으로 구현한 연구는 본 연구가 최초이다.

논문	학회	관련성
Zhang & Wu, "Survey on NT"	IEEE/CAA JAS 2023	NT 완화 접근을 Domain/Instance/Feature 3단계 로 분류 — 이론적 근거
TrineCDR	KDD 2024	NT 원인을 Feature/Interaction/Domain 3 level 로 분류 — 직접적 동기
Wang et al.	CVPR 2019	NT의 3가지 요인 식별 + gate 기반 filtering — 방법론적 선례
SAN (Cao et al.)	CVPR 2018	Binary selective transfer — PARTIAL 확장 필요성의 근거
FedGCDR	NeurIPS 2024	Soft/Hard NT 구분 — NT 강도 차이 근거
Park et al.	CIKM 2023	Shapley 연속 가중치 — 이산 판정 발전 선례

핵심 설계 원칙: Transfer Judge의 추천 rationale에는 BLOCK 판정된 패턴이 절대 등장해서는 안 된다.

9. Teacher Distillation: 학습 데이터 생성

9.1 왜 Teacher Distillation인가?

Transfer Gate의 3단계 판정은 본 연구가 새롭게 정의한 태스크이므로, 기존에 레이블링된 데이터셋이 존재하지 않는다.

대안	장점	한계	적합성
(A) 수동 레이블링	정확도 최고	800건 × 6~9패턴 = 5,000건+ 판정 필요, 비현실적 비용	✗
(B) Teacher Distillation	비용 효율적, 일관성 높음	Teacher 품질에 의존	✓ 채택
(C) Self-Training	Teacher 불필요	초기 품질 매우 낮음, 수렴 불안정	✗

9.2 선행연구 근거

Knowledge Distillation: 대형 Teacher LLM이 생성한 합성 데이터로 소형 Student 모델을 학습시키는 것은 NLP에서 확립된 방법론 (Hinton et al. 2015).

TALLRec (RecSys 2023): 50건 미만의 학습 데이터만으로도 추천 능력 달성 보고 → 본 연구의 700건은 충분한 규모.

Chain-of-Thought Distillation: Teacher가 rationale을 포함한 출력을 생성하고 Student가 학습하면, 단순 레이블만 학습하는 것보다 일반화 성능 향상 (Wei et al. 2022).

9.3 Teacher에게 GT를 제공하는 이유

GT를 제공하는 것은 **정답 암기가 아니라 올바른 판정 과정(rationale) 시연을 위함**이다. GT를 알려주면 Teacher는 "이 아이템이 추천되어야 하는 이유"를 역추론하여, 어떤 패턴이 TRANSFER이고 어떤 것이 BLOCK인지를 일관성 있게 판정할 수 있다. Student는 **과정(process)**을 학습하며, 추론 시에는 GT 없이 수행된다.

9.4 품질 필터링 (4단계)

단계	검증 항목	기준
1. 형식 검증	JSON 파싱 성공 여부	파싱 실패 시 재시도 (최대 3회)


2. 완전성 검증	transfer_decisions에 모든 패턴 판정 포함	누락 시 제외
3. 정확성 검증	GT가 Top-10 내 포함	미포함 시 Teacher 판정 실패로 제외
4. BLOCK 누출 검사	rationale에 BLOCK 판정 패턴 미등장	누출 시 핵심 설계 원칙 위반으로 제외

일관성 검사: Pilot 10명 대상 Teacher를 2회 실행(temperature=0)하여 판정 일치율 확인 (90% 이상 시 진행).

필터링 통과율 목표: 80% 이상 (800명 → 700건 이상 확보).

9.5 학습 데이터 구축 프로세스 — 가상 사용자 A를 따라가며 이해하기

아래 다이어그램은 **Train 사용자 1명("사용자 A")**의 데이터가 어떻게 학습 데이터 1건으로 만들어지는지 실제 데이터 흐름을 단계별로 추적한다. 이 과정을 800명 모두에 반복하여 ~700건의 train.jsonl을 구축한다.



③ Profiler 실행 (GPT-4o-mini API)

입력: Movies&TV 리뷰 22개 텍스트 전체 (Books 리뷰는 ✖ 제외 — Cold-Start 시뮬레이션)

출력 (요약):

```
{
  "narrative_complexity": {value: "complex multi-layered", confidence: 0.85},
  "brand_loyalty": {value: "Christopher Nolan", confidence: 0.80},
  "sensory_preference": {value: "IMAX cinematography", confidence: 0.70},
  "emotional_resonance": {value: "deep lasting impact", confidence: 0.75},
  // genre_preference, pacing_preference, quality_sensitivity ...
}
```

왜: Source 리뷰의 다양한 신호를 7개 구조화 패턴으로 추출 → Judge가 후보별 판단할 근거



④ Teacher 실행 (GPT-4o-mini API, GT 힌트 포함)

입력: Profile(③의 출력) + 후보 50개(②) + GT 힌트: "Cloud Atlas" (B002)

출력 (요약):

```
{
  "transfer_decisions": {
    "narrative_complexity": "TRANSFER", // 책에 그대로 적용 가능
    "brand_loyalty": "BLOCK", // Nolan은 영화감독, 책엔 안 맞음
    "sensory_preference": "BLOCK", // IMAX는 책에 없음
    "emotional_resonance": "TRANSFER", // 감정적 울림은 책에도 적용
    ...
  },
  "recommendations": [
    {rank: 1, item_id: "B002", title: "Cloud Atlas",
     applied_patterns: ["narrative_complexity", "pacing_preference"]}
    // rank 2~10 (B045 Nolan biography는 BLOCK 때문에 추천에서 제외)
  ]
}
```

왜 GT 힌트? Teacher가 "이 책이 추천되어야 한다"는 결과를 알고, 거기에 도달하는 올바른 판정 과정을 시연하기 위함. Student는 이 과정을 학습.



⑤ 5단계 품질 필터 (자동 검증)

- ① 형식: JSON 파싱 OK ✔
 - ② 완전성: 7개 패턴 + 10개 추천 모두 존재 ✔
 - ③ BLOCK 누출: recommendations의 applied_patterns에 brand_loyalty/sensory_preference가 등장? ✖ → 통과 ✔
 - ④ GT 텍스트 누출: rationale-reasoning에 "Cloud Atlas" 직접 언급? ✖ → 통과 ✔
 - ⑤ GT Top-10 포함: "Cloud Atlas"가 rank 1 → 통과 ✔
- 5/5 통과 → 학습 데이터로 채택



⑥ SFT 형식 변환 (GT 정보 완전 제거 후 train.jsonl에 1줄 append)

```
{ "messages": [
  { "role": "system",      "content": "You are a Cross-Domain Transfer Judge..."},
  // ↑ system 프롬프트에서 "GT 힌트" 관련 문구 모두 삭제

  { "role": "user",        "content": "Profile: {...} + Candidates: [...]" },
  // ↑ 사용자 입력에서도 GT 힌트 라인 삭제 (Student는 GT를 평생 모름)

  { "role": "assistant", "content": "{transfer_decisions, recommendations}" },
  // ↑ Teacher가 만든 정답 JSON 그대로 (Student가 모방할 목표)
}]
```

왜 GT 제거? Student(QLoRA Qwen3-14B)는 추론 시 GT를 절대 보지 않는다. 학습 시에도 같은 조건이어야 일관성 확보.

Figure: 가상 사용자 A 1명 → train.jsonl 1줄. 이 과정을 800명 모두 반복 → ~700건 (87.5%+ 통과율)

□ 데이터 처리 (①②) □ API LLM 호출 (③④) □ 품질 필터 (⑤) □ 최종 산출물 (⑥)

이 다이어그램에서 꼭 이해해야 할 3가지:

- (1) GT의 두 가지 역할 — Teacher의 "정답 시연용" (④) + 품질 필터의 "검증용" (⑤). 둘 다 학습 데이터에는 들어가지 않음.
- (2) BLOCK이 가치 있는 이유 — "Nolan biography"가 평점 4.2로 높지만 brand_loyalty BLOCK으로 추천에서 제외 (④). 이것이 Negative Transfer 방지.
- (3) Student의 학습 목표 — Student는 ⑥의 user입력만 보고 ⑥의 assistant출력을 만들어내야 함. GT 힌트 없이도 동일한 추론을 하도록 학습.

9.6 800명 → train.jsonl 전체 통계 흐름

단계	800명 적용 결과
0. 입력	Train 800명 (각자 Source 15~30개 + Target 5~10개 리뷰)
① GT 분리	800명 모두 rating ≥ 4 보유 (EDA 99.6% + 샘플링 후 100%) → 800건
② 후보 50개	800명 × 50개 = 40,000개 후보 (각자 다른 후보 셋, seed=42)
③ Profiler	800회 API 호출, ~\$0.7
④ Teacher	800회 API 호출, ~\$2.0
⑤ 5단계 필터	예상 통과율 87.5%+ → ~700건

⑥ ~700줄의 SFT 학습 데이터 → Qwen3-14B QLoRA 파인튜닝 입력
train.jsonl

10. 평가 프로토콜: Leave-One-Out

10.1 개요

Leave-One-Out(LOO)은 추천 시스템 평가에서 가장 널리 사용되는 프로토콜로, 각 사용자의 마지막 상호작용 1개를 테스트용으로 분리하고 나머지로 모델을 추론한다.

10.2 LOO 적용 절차

각 Test 사용자 u 에 대해:

1. Target(Books) 도메인에서 $\text{rating} \geq 4$ 인 구매 중 가장 최근 아이템을 GT로 설정
2. GT를 제외한 나머지 Target 리뷰(최대 9개)를 Profiler 입력으로 사용
3. Source(Movies & TV) 리뷰 최대 30개를 Profiler 입력으로 사용
4. Profiler $\rightarrow$ Transfer Judge $\rightarrow$ Top-10 추천 생성
5. GT가 Top-K에 포함되는지로 HR@K, NDCG@K, MRR 계산

10.3 핵심 설계 결정

결정	선택	근거
GT 선정	$\text{rating} \geq 4$ 중 가장 최근	Transfer Gate 효과를 정확히 측정하기 위해 사용자가 만족한 아이템만 GT로 사용 (섹션 4.4 근거 참조)
GT 평점 제한	Explicit positive (≥ 4)	Implicit 방식은 BLOCK의 올바른 판단을 성능 하락으로 왜곡할 수 있음
후보 구성	GT 1 + Negative 49 = 50	섹션 4.4의 후보 선정 근거 참조
GT 제외	Target 리뷰에서 GT 제거 후 입력	정보 누출(data leakage) 방지
LOO 단위	사용자당 1개	Cold-Start 사용자의 Target 리뷰를 더 줄이면 Profiler 입력 품질 저하

10.4 왜 LOO인가?


프로토콜	설명	한계	선택
Leave-One-Out	마지막 아이템 1개 평가	사용자당 1회 $\rightarrow$ Bootstrap CI로 보완	✓ 채택
K-fold	상호작용 K개 분할 교차 평가	Cold-Start(5~10개) 더 분할 시 입력 부족	✗
Temporal Split	시간 기준 분리	LOO의 특수 형태 — 본 연구에서는 동일	—

선행연구 일치: TALLRec, LLM4CDR, TrineCDR, He et al.(2017) 모두 LOO 프로토콜 사용 → 결과 비교 가능.

10.5 평가 흐름 요약

Input: Source 리뷰 30개 + Target 리뷰 최대 9개 (GT 제외)
↓ Profiler: 선호 패턴 JSON 추출
↓ Transfer Judge: 패턴별 TRANSFER/PARTIAL/BLOCK 판정
↓ Output: Top-10 추천 리스트 (후보 50개 중 순위화)
↓ 평가: GT의 순위 확인 → HR@1, HR@5, HR@10, NDCG@10, MRR 계산

10.6 평가 프로세스 (한눈에)



학습-평가의 핵심 차이:

학습 시(섹션 9.5): Teacher는 GT를 알고 시연 → Student가 판정 과정을 학습

평가 시(본 섹션): Student(Transfer Judge)는 **GT를 모르는 상태로** 추론 → 실전 추천 시나리오 그대로 시뮬레이션
→ 모든 6개 Ablation 조건은 이 동일한 평가 절차로 측정되며, 차이는 ④⑤ 단계의 모델 구성에서만 발생한다.

11. Research Question별 검증 방법

11.1 Ablation Study 전체 설계

조건	구성	검증 목적
(a) Single LLM	단일 프롬프트로 전체 수행	베이스라인 (LLM4CDR 재현)
(b) Profiler-Judge (Prompt)	Profiler(P) + Judge(P), 프롬프트 기반	Profiler-Judge 분리 효과
(c) Ours ★	Profiler(P) + Judge(QLoRA)	파인튜닝 효과
(d) P-J w/o Gate	Judge(FT), 모든 패턴 TRANSFER 강제	Transfer Gate 효과
(e) 전통 CDR	비LLM 임베딩 기반	LLM 접근 우위
(f) Raw Review	Profiler 생략, raw review 직접 입력	구조화 프로파일 효과

각 조건의 구체적 설계 방법

조건	구현 방식	차별 변인 (다른 조건 대비)
(a) Single LLM	GPT-4o-mini 1회 호출. 입력: Source 리뷰 + 후보 50개 + "Top-10을 추천하라" 프롬프트. 별도 패턴 추출/판정 단계 없음.	Profiler-Judge 분리 없음 . 단일 LLM이 모든 작업 수행 (LLM4CDR 방식 재현).
(b) Profiler-Judge (Prompt)	Profiler: (c)와 동일 GPT-4o-mini API. Judge: Qwen3-14B-Instruct를 파인튜닝 없이 프롬프트만으로 사용 (Few-shot 3예시 포함).	(a) 대비 역할 분리 추가 , (c) 대비 QLoRA 파인튜닝 제외 .
(c) Ours ★	Profiler: GPT-4o-mini API. Judge: Qwen3-14B + QLoRA 파인튜닝 (Teacher Distillation 700건으로 학습). Section 9의 학습 데이터 사용.	본 연구의 완전한 구성. (b) 대비 파인튜닝 추가 .
(d) P-J w/o Gate	Profiler-Judge 구조는 (c)와 동일. 단, Judge 추론 시 모든 패턴을 TRANSFER로 강제 (BLOCK/PARTIAL 출력을 후처리로 TRANSFER 변환).	(c) 대비 Transfer Gate 비활성화 . 패턴별 차단 효과만 분리 검증.
(e) 전통 CDR	비LLM 베이스라인. EMCDR(IJCAI 2017) 또는 CATN(SIGIR 2020) 재현 —	LLM 접근 자체의 우위 검증. LLM 미사용 .

	사용자/아이템 임베딩 학습 후 cross-domain mapping. 동일 1,000명 데이터 사용.	
(f) Raw Review	Profiler 단계 생략. Source 리뷰 텍스트를 그대로 Judge(QLoRA)에 입력. Judge는 (c)와 동일하게 학습된 모델 사용.	(c) 대비 구조화된 Profile 입력 제거 — 패턴 JSON vs raw text 효과 분리.

RQ별 비교 매핑 (어떤 조건끼리 비교하면 어떤 RQ를 검증하는가)

RQ	비교	분리되는 효과
RQ1	(c) vs (a) · (c) vs (e)	본 연구 프레임워크의 전반적 우위 (단일 LLM·전통 CDR 대비)
RQ2	(c) vs (d)	Transfer Gate(BLOCK·PARTIAL 차단)의 순효과
RQ3	(b) vs (c)	QLoRA 파인튜닝의 순효과 (구조 분리는 동일하게 유지)
보조	(c) vs (f)	Profiler 구조화 출력의 가치 (Profile JSON vs Raw Review)
보조	(a) vs (b)	역할 분리 자체의 효과 (파인튜닝 없이도 우위인지)

변인 통제 원칙: 모든 조건은 동일한 1,000명 데이터·동일 후보 50개(seed=42)·동일 평가 프로토콜(LOO, HR@K/NDCG@K)을 공유한다. 조건 간 차이는 표의 "차별 변인"으로만 발생하므로, 두 조건의 성능 차이는 해당 변인의 순효과로 해석 가능.

11.2 평가 지표

지표	설명
HR@1	1위 추천이 정답인 비율
HR@5	Top-5에 정답 포함 비율
HR@10	Top-10에 정답 포함 비율
NDCG@10	정답의 순위를 고려한 점수
MRR	정답 순위 역수의 평균

각 지표가 무엇을 의미하는가 (직관적 설명)

지표	의미와 계산 예시	왜 이 지표를 보는가
----	-----------	-------------

HR@1 (Hit Rate)	"1번 추천했을 때 적중한 비율" 예: 100명 중 25명이 1위 추천이 정답 → $HR@1 = 0.25$ 값 범위: 0~1 (높을수록 좋음)	가장 엄격한 정확도. 단 1개만 추천 하는 시나리오의 품질을 본다. 추천 시스템의 "최상위 정확도"를 의미.
HR@5	"Top-5 안에 정답이 포함된 비율" 예: GT가 rank 4 → Hit / GT가 rank 7 → Miss 100명 중 60명 적중 → $HR@5 = 0.60$	현실적 추천 UI(상위 5개 노출)의 품질. HR@1보다 후하지만 여전히 엄격.
HR@10	"Top-10 안에 정답이 포함된 비율" 후보 50개 중 랜덤 추천 시 기댓값 = 20% 모델이 그 이상이어야 의미 있음	전체 추천 리스트 도달률. 본 연구의 주요 보고 지표.
NDCG@10 (Normalized DCG)	"정답이 몇 위에 있는지를 가중치로 점수화" GT가 rank 1 → 1.00 / rank 3 → 0.50 / rank 10 → 0.29 / Top-10 밖 → 0 로그 감쇠로 상위 순위에 더 큰 가중	HR은 Top-K 안/밖만 보지만, NDCG는 " 몇 위인지 "까지 본다. rank 1 추천과 rank 10 추천을 다르게 평가.
MRR (Mean Reciprocal Rank)	"정답 순위의 역수 평균" GT가 rank 1 → 1/1 / rank 2 → 1/2 / rank 5 → 1/5 100명의 1/rank 평균값	"평균적으로 정답이 몇 위쯤에 있는가"의 직관적 표현. $1/MRR \approx$ 정답의 평균 순위.

왜 5개 지표를 함께 보는가?

HR@1은 너무 엄격해서 모델 차이가 잘 안 보일 수 있고, HR@10은 너무 후해서 천장 효과 위험. NDCG@10은 순위 품질을 정량화하지만 직관적 해석이 어렵고, HR은 Top-K 안/밖만 본다. 다섯 지표를 함께 보면 "**정확도 + 순위 품질 + 도달률**"의 다면적 평가가 가능하다.

선행연구 일치: TALLRec, LLM4CDR, NCF 등 추천시스템 표준 보고 지표 그대로 사용 → 결과 비교 가능.

11.3 통계적 유의성: Bootstrap Confidence Interval

Test 100명에서 1,000회 부트스트랩으로 95% 신뢰구간 산출.

논문 표기: $HR@10 = 0.72$ (95% CI: 0.64-0.79)

왜 Bootstrap CI가 필요한가?

문제	설명
① 단일 점수 보고의 한계	"HR@10 = 0.72"만 보고하면 그 값이 우연인지 진짜 모델 성능인지 알 수 없다. Test 100명이 다른 100명이었다면 0.65 또는 0.78이 나올 수도 있다.

② 조건 비교의 신뢰성	(c) HR@10=0.72 vs (a) HR@10=0.68 — 0.04 차이가 통계적으로 유의한가? 우연일 수도 있다. CI 겹침 여부로 판단.
③ Test 샘플 크기 100명의 특성	샘플이 작을수록 단일 점수의 변동성이 커진다. 100명에서 측정한 값이 "모집단 전체에서도 비슷한지" 추정 필요.
④ 정규성 가정 회피	HR/NDCG는 정규분포를 따르지 않는다(이진/비대칭). Bootstrap은 분포 가정 없이 신뢰구간을 만들 수 있는 비모수적 방법.

Bootstrap CI 계산 절차

단계	내용
①	Test 100명 각각의 HR@10 값을 계산 (각 사용자: 0 또는 1)
②	이 100명에서 복원 추출(with replacement) 로 100명을 재표본 → 평균 계산 (1개 부트스트랩 표본)
③	②를 1,000회 반복 → 1,000개의 평균값 분포 확보
④	1,000개 값의 2.5 percentile ~ 97.5 percentile 이 95% 신뢰구간
⑤	모든 지표(HR@1/5/10, NDCG@10, MRR)와 모든 조건(a~f)에 대해 동일 절차 적용

해석 예시 — 두 조건 비교

조건	HR@10	95% CI	유의성 판단
(c) Ours ★	0.72	[0.64, 0.79]	CI가 겹치지 않음 → (c)가 (a)보다 통계적으로 유의하게 우수 ($p < 0.05$)
(a) Single LLM	0.55	[0.48, 0.62]	
(c) Ours ★	0.72	[0.64, 0.79]	CI가 겹침 → 차이가 통계적 유의성 미달. 더 많은 Test 데이터 필요할 수 있음
(b) P-J Prompt	0.69	[0.61, 0.76]	

왜 1,000회인가? 추천시스템 논문 표준 (NCF, TALLRec 등). 100~500회는 신뢰구간이 불안정하고, 5,000회 이상은 계산 비용 대비 추가 정확도 미미. 1,000회가 정확도와 비용의 균형점.

왜 95% CI인가? 통계학 표준 ($\alpha=0.05$). 99% CI는 너무 보수적이어서 작은 차이를 검출 못하고, 90% CI는 1종 오류 위험 증가. 95%가 표준.

이 분석으로 강화되는 RQ 결론: 단순히 "(c) $HR@10 = 0.72 > (a) HR@10 = 0.55$ "라고 하지 않고, "(c)가 (a)보다 95% 신뢰수준에서 통계적으로 유의하게 우수 (CI 비겹침)"라고 보고 → **심사 대응력 ↑**.

12. 참고문헌

12.1 핵심 인용 논문

#	논문	학회	인용 맥락
1	Bao et al., "TALLRec"	RecSys 2023	QLoRA 기반 LLM 추천 파인튜닝의 이론적 근거. 50건 미만 학습 데이터로도 추천 능력 달성 → Teacher Distillation 데이터 규모 (700건) 충분성 근거
2	TrineCDR (Chen et al.)	KDD 2024	NT 원인을 Feature/Interaction/Domain 3 level로 분류 → Transfer Gate 3단계의 개념적 근거
3	LLM4CDR (Zhao et al.)	WWW 2025	Single LLM + 프롬프트 CDR. 가장 직접적인 비교 대상(베이스라인)
4	Zhang & Wu, "Survey on NT"	IEEE/CAA JAS 2023	NT 완화 접근을 Domain/Instance/Feature 3단계로 분류한 서베이 — 이론적 토대
5	Wang et al.	CVPR 2019	NT의 3가지 요인 식별 + gate 기반 filtering — Transfer Gate 방법론적 선례
6	Cao et al. (SAN)	CVPR 2018	Binary selective transfer의 한계 → PARTIAL 등급 확장 필요성 근거
7	FedGCDR (Liu et al.)	NeurIPS 2024	Soft/Hard NT 구분 — NT 강도 차이의 실증적 근거
8	Park et al.	CIKM 2023	Shapley 연속 가중치 기반 전이 조절 — 이산 판정 발전 동기
9	McAuley Lab, Amazon Review 2023	Dataset	실험 데이터셋 소스

12.2 방법론 근거 논문

#	논문	학회	인용 맥락
10	Hinton et al., "Distilling the Knowledge in a Neural Network"	NeurIPS WS 2015	Knowledge Distillation 원론적 근거. Teacher-

			Student 패러다임의 이론적 토대
11	Wei et al., "Chain-of-Thought Prompting"	NeurIPS 2022	CoT rationale 포함 학습이 일반화 성능 향상 → Teacher rationale 포함 출력 설계 정당화
12	Hu et al., "LoRA"	ICLR 2022	LoRA/QLoRA 파인튜닝 방법론의 원론적 근거
13	Dettmers et al., "QLoRA"	NeurIPS 2023	4-bit 양자화 + LoRA 효율성 검증. 제한된 GPU에서 14B 파인튜닝 가능성 근거
14	Qwen Team, "Qwen3 Technical Report"	arXiv 2025	Qwen3-14B 벤치마크 성능 데이터. Transfer Judge LLM 선정 근거

12.3 평가 방법론 근거 논문

#	논문	학회	인용 맥락
15	He et al., "Neural Collaborative Filtering"	WWW 2017	LOO + Random Negative Sampling 평가 프로토콜의 표준 정립
16	Krichene & Rendle, "On Sampled Metrics"	KDD 2020	샘플링 기반 평가(50개 후보)의 이론적 정당성 — 전체 아이템 대비 순위 상관성 유지 증명