

Phase 2 결함 심층 분석 보고서

TransferJudge · Codex 외부 리뷰 기반 5개 결함 실측 검증

2026.05.13 · 빅데이터학과 17기 박민아

경고: 본 보고서는 Phase 2 본 실행(900명) 진입 전 발견된 결함을 정리한 문서다. 모든 결함은 외부 LLM(Codex) 검토에서 지적되어 실측으로 재확인됨. **현재 50명 trial 데이터는 학습용으로 부적합하며, 수정 없이 본 실행 진행 불가.**

0. 결함 요약

결함 1 64.2% 사용자가 GT 이후 영화 리뷰 보유 (1,000명 기준)	결함 2 86% Teacher 학습 레코드에 candidate 위반 존재	결함 3 0% author_name 비어있음 (EDA는 72.6% 주장)	결함 4 없음 GT hint blind audit (설계 위험 미검증)	결함 5 66% → 97% sensory_preference Profile high → Teacher BLOCK
---	--	--	---	--

#	결함	심각도	본 실행 차단
1	Temporal Leakage — Profiler·Teacher 둘 다 GT 이후 정보 사용	CRITICAL	YES
2	Teacher 라벨 corruption — 후보 밖 추천·중복·title 불일치	CRITICAL	YES
3	author_name 100% 결측, EDA 보고서 수치 거짓	MEDIUM	PARTIAL
4	GT hint label leakage 위험 미검증	MEDIUM	NO (논문 방어용)
5	sensory_preference 과고정 — Profile·Teacher 신호 모순	MEDIUM	NO (개선)

1. 결함 1 — Temporal Leakage (시간 누수)

1.1 문제 정의

본 연구는 "책 도메인 cold-start 추천"을 시뮬레이션함. 사용자가 GT 책(rating ≥ 4 중 가장 최근)을 구매·평가하기 **이전** 시점에 모델이 그 책을 추천할 수 있는가를 평가하는 게 본 실험의 본질.

따라서 **GT timestamp 이후**에 작성된 어떤 사용자 행동·메타데이터도 입력에 들어가는 안 됨. 들어간다면 "미래 정보로 과거 추천"이라는 fundamental violation.

1.2 실측 결과

구분	대상	누수 사용자	누수 영화 리뷰	비율
Trial 50명	50	23 (46%)	148 / 1,187	12.5%
1,000명 전체 (Phase 1)	1000	642 (64.2%)	5,170 / 23,067	22.4%

1.3 누수 시간 갭 분포 (영화 리뷰가 GT보다 얼마나 미래인가)

분위수	일수	해석
P25	52일 (~1.7개월)	일부는 짧은 미래
중앙값	202일 (~6.7개월)	절반이 6~7개월 미래의 영화 리뷰를 보고 추천
P75	518일 (~1.4년)	1/4은 1.5년 이상 미래
최대	1439일 (~3.9년)	최대 4년 미래의 정보 사용

1.4 영향 범위 — Profiler 1,000명 전부 영향

Profile 재생성 불가피

`run_profiler.py:326` 은 사용자의 영화 리뷰 전체(`head(max_reviews)`)를 입력으로 사용. GT timestamp cutoff 로직 없음. 결과적으로 Phase 1에서 만든 1,000개 Profile 중 **642명(64.2%)이 미래 정보로 추출된 패턴 포함**.
→ 코드 수정 후 1,000명 Profile 전체 재생성 필요 (\$0.83 / 4시간).

1.5 수정 방향

1. **GT timestamp 사전 계산**: 각 사용자별 books 도메인의 rating ≥ 4 최신 timestamp를 미리 계산해 별도 컬럼/파일로 저장
2. **Profiler input cutoff**: `user_reviews[user_reviews['timestamp'] < gt_ts]`
3. **Teacher input cutoff**: target domain books도 GT 제외 + GT 이전 리뷰만
4. **Negative 후보 도서**: pub_date 있으면 GT 이전 출간만 사용 (단, pub_date 결측 93%로 실용성 낮음 → 별도 결정 필요)

2. 결함 2 — Teacher 라벨 Corruption

2.1 문제 정의

Teacher의 임무는 50개 후보 도서 중에서 Top-10을 추천하는 것. 그러나 실제로는 50개 밖의 도서를 추천하거나, 같은 책을 두 번 추천하거나, 잘못된 title을 붙이는 사례가 광범위.

`run_teacher.py`의 `is_valid` 검증 함수가 "JSON 파싱 + GT Top-10 포함 + BLOCK leakage 없음" 3가지만 보고, 후보 membership·중복·title 일치를 체크하지 않음.

2.2 실측 결과 — 학습 데이터 37건 검증

지표	건수	비율	심각도
완전 클린 (어떤 결함도 없음)	4 / 37	11%	기준
최소 1개 이상 결함	33 / 37	89%	CRITICAL
후보 밖 item_id 포함	30 / 37	81%	CRITICAL
평균 후보 밖 추천 수	3.6 / 10	36%	36% 환각
중복 추천 (같은 책 2회 이상)	16 / 37	43%	CRITICAL
title 불일치 (id와 다른 책 이름)	15 / 37	41%	CRITICAL
"C3" 같은 후보 번호를 id로 사용	3 / 37	8%	format violation

2.3 후보 밖 추천 개수 분포

후보 밖 개수 / 10	레코드 수	분포
0건	7	
1건	12	
2건	5	
7건	2	
8건	1	
9건	10	

충격적 사실: 10개 추천 중 9개가 후보 밖인 레코드가 10개(27%). 즉 Teacher가 실질적으로 candidate set을 무시하고 books_meta 전체(4.4M)에서 환각 추천.

2.4 구체 사례 (record idx=2, 후보 밖 9개)

상태	item_id	title
IN	0670026263	"The Party Is Over: How Republicans Went Crazy, Democrats Bec"
OUT	0329780001	"The Nightingale"

OUT	1501110365	"All the Light We Cannot See"
OUT	0062358130	"The Book Thief"
OUT	0452290591	"The Tattooist of Auschwitz"

2.5 수정 방향

1. `validate_output` 에 **candidate membership** 체크 추가 (`recommendations[i].item_id ∈ 후보 50개`)
2. **중복 추천 검증** (`rec_ids = set(rec_ids)` 동일)
3. **title 일치 검증** (`books_meta` lookup 결과와 비교)
4. **rank 1~10 범위·score 0~1 범위** 체크
5. 위반 시 **재시도** (max 2회) 또는 **학습 데이터에서 제외**
6. System prompt에 "You MUST select ONLY from the 50 candidates listed. Do NOT invent item_ids." 명시

3. 결함 3 — author_name 100% 결측

3.1 EDA 보고서와 실제 데이터의 불일치

출처	author_name 존재율
EDA Report (TransferJudge_EDA_Report.pdf)	72.6%
실제 books_meta_filtered.parquet	0 / 4,448,181 = 0.0000%
차이	EDA 거짓

3.2 원인 추정

Amazon Reviews 2023 books_meta의 원본은 `author` 키에 `dict` 형태로 저장 (예: `{'name': 'J.K. Rowling', 'url': '...'}`). 전처리 단계에서 `author.get('name')` 로 추출했어야 하는데 `str(author)` 또는 다른 키로 시도해 빈 문자열로 저장된 것으로 추정.

3.3 영향

- **본 실험 영향:** 현재 Teacher 프롬프트의 후보 도서에 `author: (unknown)` 으로 표시됨. 저자 정보를 활용한 추천 신호(예: "이 저자 시리즈" 인지) 학습 불가
- **EDA 신뢰도:** 보고서의 다른 수치도 재검증 필요. 특히 GAP-4의 "1,000명 GT" 표 vs "n=931" 본문 모순도 같이 확인

3.4 수정 방향

1. 원본 메타데이터 raw 파일에서 `author` 키 구조 재확인
2. 전처리 스크립트 수정 후 `books_meta_filtered.parquet` 재생성
3. EDA 노트북·EDA Report PDF의 `author` 관련 모든 수치 재계산
4. EDA Report v2 발행

4. 결함 4 — GT hint leakage 위험 미검증

4.1 설계 vs 우려

본 연구 설계 주장	심사자 우려 (Codex 지적)
"Teacher만 GT를 본다. Student(Judge)는 보지 않음."	Oracle teacher가 부여한 라벨은 Student가 진짜로 학습할 수 있는 신호인가?
"Teacher는 SFT용 synthetic label 생성기일 뿐."	Teacher decision은 실증 결과가 아니라 설계 라벨임을 명시했는가?
"GT hint는 Teacher가 더 좋은 라벨을 만들도록 유도하는 supervision."	GT hint 없는 Teacher와 비교한 적이 있는가? 없으면 hint의 효과·왜곡 unknown.

4.2 수정 방향 — Blind Audit 추가

1. 별도 trial 20~30명: 동일 사용자에게 대해 GT hint 없이 Teacher 실행
2. 두 결과 비교:
 - decision 분포 차이 (특히 TRANSFER/PARTIAL/BLOCK 비율)
 - rationale 품질 차이
 - GT가 Top-10에 들어간 비율 (with vs without)
3. 본 논문 Methodology 절에 결과 표 첨부. "GT hint가 X% decision을 바꾸지만, BLOCK 분포는 일치 → 패턴 가설은 hint와 독립적"식의 방어 가능

5. 결함 5 — sensory_preference 과고정

5.1 Profile vs Teacher 신호 모순

단계	sensory_preference 신호	의미
Phase 1 (Profile, n=1,000)	high 632 (63%) / medium 264 (26%) / low 104 (10%)	Profiler는 sensory가 책에 충분히 전이 가능하다고 판정
Phase 2 (Teacher, n=37)	BLOCK 97%	Teacher는 일괄 BLOCK
모순도	완전 반대	같은 패턴을 두 단계에서 정반대로 판정

5.2 Profile의 sensory 사례 (high transferability)

value: "atmospheric, uplifting"

evidence: "I walk away feeling uplifted."; "This one has a special meaning to me because Miss Clara's character was inspired by Molly"

value: "visual and emotional engagement"

evidence: "Felt so real and alive ---all the way around."; "It delivers the real deal. Tells it like it is, thus very interesting."

value: "visual spectacle, immersive experience"

evidence: "The sets are beautiful and seem authentic, although I did not experience the 1920s first ; "Watching this, I got caught up in the excitement that evidently ran through the crowd in

5.3 Teacher의 sensory decision 사례 (BLOCK)

decision: **BLOCK**

insight: "None"

rationale: "Sensory preferences related to emotional and heartwarming experiences in film do not translate directly to books, as the sensory experience is fundamentally dif..."

decision: **BLOCK**

insight: "None"

rationale: "Visual storytelling preferences in film do not apply to books, as the sensory experience is fundamentally different. This pattern is medium-specific and should ..."

decision: **BLOCK**

insight: "None"

rationale: "High sensory preference for film does not translate to books, as the sensory experience of reading is fundamentally different from visual media. This pattern sh..."

5.4 진단 — "sensory" 단일 라벨이 너무 광범위

sensory_preference는 영화에서 두 가지 다른 신호를 포함:

하위 유형	예시	책 전이 가능성
Visual/Action Spectacle	"animation ahead of its time", "special effects", "explosions"	BLOCK — 책에는 영상이 없음
Atmosphere / Imagery / Tone	"atmospheric, uplifting", "felt so real", "immersive"	TRANSFER — 책에서 묘사·분위기로 직접 전이

현재 Teacher 프롬프트는 두 유형을 구분 안 함. "sensory_preference = visual"로 보고 일괄 BLOCK. 결과적으로 책에 전이 가능한 atmosphere 신호도 BLOCK당해 학습 신호 손실.

5.5 수정 방향 — 옵션 A 우선 권장

옵션	내용	장단점	채택 여부
A (보수) — 프롬프트 보강	sensory_preference 정의에 두 하위 유형 명시. "visual/sound/action spectacle → BLOCK / atmosphere/imagery/toner → consider TRANSFER"	Phase 1 통계·overview·논문 구조 변경 없음. 검증 비용 낮음.	✓ 1차 채택
B (적극) — 패턴 분리	sensory_preference 를 visual_spectacle 과 atmosphere_preference 두 패턴으로 분리	Phase 1 Profile 재생성 외에 overview v6, 학습 가설·EDA·논문 contribution 절 등 다수 문서 동시 수정. 리스크 큼.	1차에서 보류

의사결정: 본 실험 안정성을 위해 **옵션 A**를 우선 적용. A1~B2 수정 후 trial v2에서 sensory의 BLOCK 비율이 여전히 95% 이상이라면 옵션 B 검토 또는 "sensory의 단일 패턴 한계"를 논문의 Limitation 절에 명시.

6. 종합 수정 계획

6.1 단계별 일정

단계	작업	비용	시간	차단성
A1	run_profiler.py에 GT timestamp cutoff 추가	-	0.5일	본 실행 필수
A2	run_teacher.py에 후보 membership·중복·title 검증 추가	-	0.5일	본 실행 필수
A3	books_meta author_name 파싱 재실행 + EDA 수치 재계산	-	0.5일	EDA 수정
A4	sensory_preference 프롬프트 분리 또는 sub-type 명시	-	0.3일	품질 개선
B1	Profile 1,000명 재생성 (temporal cutoff 적용)	\$0.83	4h	본 실행 필수
B2	Teacher 50명 trial v2 (수정된 파이프라인)	\$0.11	1.5h	검증
B3	GT hint blind audit (20~30명)	\$0.05	30분	논문 방어
B4	trial v1 vs v2 비교 보고서 작성	-	0.5일	품질 보증
C1	Teacher 900명 본 실행 (검증 완료 후)	\$2.0	~10h	다음 단계

6.2 데이터 보존 정책

현재 산출물 (v1)	처리
profiler_outputs/ (1,000개)	보존 → profiler_outputs_v1/ 로 이름 변경 후 v2 새로 생성
teacher_outputs/ (50개)	보존 → teacher_outputs_v1/ 로 이름 변경 후 v2 새로 생성
data/teacher_train_50.jsonl	보존 → teacher_train_50_v1.jsonl 로 이름 변경
Phase 1 Report PDF	v2 발행 시 본 결함 분석을 §11로 추가, 학습용 부적합 명시

6.3 우선순위 — A1·A2가 최상위 (외부 리뷰 확정)

순위	작업	이유
⚡ Tier 0 (최상위)	A1 (Profiler temporal cutoff), A2 (Teacher 검증 강화)	두 결함이 막히지 않으면 이후 모든 실험 결과의 의미가 흔들림. "실험 자체가 유효한가"의 전제조건.
Tier 1	B1 (Profile 1,000명 재생성)	A1 적용 후 즉시 필요. v1 보존 + v2 새로 생성.
Tier 2	A3 (author 파싱), A4 (sensory 프롬프트 옵션 A)	품질 개선이지만 본 실험 차단은 아님. B1과 병렬 가능.
Tier 3	B2~B4 (trial v2·blind audit·비교 보고서)	검증 단계. 통과 기준(§7) 충족 여부가 본 실행 결정.
Tier 4	C1 (900명 본 실행)	§7 통과 기준 모두 충족 후에만 진행.

6.4 데이터 보존 정책

현재 산출물 (v1)	처리
profiler_outputs/ (1,000개)	보존 → profiler_outputs_v1/ 로 이름 변경 후 v2 새로 생성
teacher_outputs/ (50개)	보존 → teacher_outputs_v1/ 로 이름 변경 후 v2 새로 생성
data/teacher_train_50.jsonl	보존 → teacher_train_50_v1.jsonl 로 이름 변경
Phase 1 Report PDF	v2 발행 시 본 결함 분석을 §11로 추가, 학습용 부적합 명시

7. Trial v2 통과 기준 (Acceptance Criteria)

Trial v2(B2 단계) 결과가 다음 8개 정량 기준을 **전부 만족**해야 본 실행(C1) 진입. 기준 미달 시 코드·프롬프트 추가 수정 후 trial v3 재실행.

7.1 절대 기준 — 0이 아니면 실패 (Hard Constraints)

#	지표	v1 (현재)	v2 통과 기준	검증 방법
1	후보 밖 추천 (out-of-candidate)	30/37 (134건)	0건	recommendations[i].item_id ∈ 후보 50개
2	중복 추천 (duplicate item_id)	16/37	0건	len(rec_ids) == len(set(rec_ids))
3	title mismatch (id-title 불일치)	15/37	0건	books_meta lookup 결과와 title 일치
4	BLOCK leakage (BLOCK 패턴이 recommendations 사용)	0건 (v1도 통과)	0건	blocked_patterns_summary 검증 (기준)
5	GT leakage text (rationale에 GT title 노출)	0건 (v1도 통과)	0건	rationale-insight 텍스트에 GT title 부분문자열 검색

7.2 분포 기준 — 범위 충족 (Soft Constraints)

#	지표	v1 (현재)	v2 통과 기준	실패 시 조치
6	학습 데이터 채택율 (valid training acceptance rate)	37/50 = 74%	≥ 60~70%	이하 시 GT Top-10 필터 완화 또는 candidate pool 확장 검토
7	temporal cutoff 후 Source 리뷰 ≥ 15개 사용자 비율	미측정 (cutoff 없음)	50명 중 일부 누락 허용, 다만 누락 사용자는 segment로 분리·기록	1,000명 본 실행 시 cutoff 후 <15 리뷰 사용자 별도 트래킹
8	7-pattern 완전성	37/37 (100%)	100%	JSON 검증 단계에서 즉시 fail

7.3 검증 자동화

위 8개 기준을 trial 실행 직후 자동 측정하는 `scripts/validate_teacher_trial.py` 를 작성. 출력 예시:

```

=== Trial v2 Acceptance Check (n=50) ===
[1] out-of-candidate ..... 0 / 50    ✓ PASS
[2] duplicate recommendations .. 0 / 50    ✓ PASS
[3] title mismatch ..... 0 / 50    ✓ PASS
[4] BLOCK leakage ..... 0 / 50    ✓ PASS
[5] GT title leakage in text ... 0 / 50    ✓ PASS
[6] training acceptance rate ... 34/50 = 68%    ✓ PASS (>=60%)
[7] cutoff_short_reviews_users . 4 / 50 → segmented separately
[8] 7-pattern completeness ..... 50/50    ✓ PASS
  
```

ALL CRITERIA PASS → C1 (900명 본 실행) 진입 가능

7.4 통과 시 다음 단계 (C1)

v2 trial이 8개 기준 모두 통과한 경우에만 900명 본 실행 진입.

하나라도 실패 시 원인 분석 → A1~A4 또는 프롬프트 재조정 → trial v3 재실행. "검증된 파이프라인 → 큰 실행"의 순서를 절대 어기지 않음.

6.5 최종 결정

본 보고서로 결함 5개 모두 파악·우선순위 확정 + v2 통과 기준 정량화 완료.

다음 단계: 수정 계획 A1→A4 코드 작업 → B1~B4 재실행 → §7 통과 기준 검증 → C1 본 실행.

v1 데이터는 보존하여 v2와 비교 가능한 형태로 활용.