

Phase 2 Trial (Teacher 50명) 보고서

TransferJudge · GPT-4o-mini Teacher Distillation 시험 실행

2026.05.13 · 빅데이터학과 17기 박민아

한 줄 요약

본 실행 전 파이프라인 검증 목적으로 50명 trial 실행. 결과: **37/50 (74%) 학습 데이터 확보**, 패턴 완전성 100%, Pilot에서 세운 모든 가설(brand_loyalty 100% BLOCK 등) 재검증. 중간 발견한 Connection error 23건 → 재실행으로 전부 복구. 900명 본 실행 GO 판정.

0. Phase 2가 무엇이며 왜 중요한가

0.1 전체 실험 파이프라인 (Phase 2 위치)



0.2 Phase 2(Teacher Distillation)의 역할

핵심 정의: 고가의 대형 LLM(GPT-4o-mini)을 "정답 가르치는 교사"로 활용해 소형 모델(Qwen3-14B Judge)이 학습할 **고품질 라벨 데이터를 자동 생성**하는 단계.

구체적으로: Profiler가 뽑은 7개 패턴마다 Teacher가 "이 패턴은 책 추천에 그대로 써도 되나(TRANSFER) / 일부만 써야 하나(PARTIAL) / 쓰면 안 되나(BLOCK)"를 GT(정답 책)를 힌트로 받은 상태에서 판단. 이때 생성된 (Profile, decision) 쌍이 Judge의 학습 데이터가 됨.

0.3 후속 Phase와의 연결

Phase	Phase 2 산출물 사용 방식	의존도
Phase 3 (QLoRA 파인튜닝)	data/teacher_train_900.jsonl 을 Judge(Qwen3-14B) SFT 학습 데이터로 직접 투입	필수 — 데이터 없으면 학습 불가
Phase 4 (Ablation 6 conditions)	학습된 Judge로 Test 사용자 추천 → Teacher 라벨 분포와 비교해 성능 검증	간접 — 학습된 Judge가 필요
Phase 5 (Per-Pattern Ablation)	특정 패턴(예: brand_loyalty)만 제외/포함하며 영향 측정 — Teacher decision 분포가 기준선	간접
Phase 6~7 (분석·논문)	Teacher decision의 패턴 가설 검증 결과가 본 논문의 핵심 주장 중 하나	간접

0.4 왜 이 단계가 결정적으로 중요한가

"Teacher 데이터 품질 = Judge 성능 상한"

지식 증류(Knowledge Distillation)에서 학생 모델(Judge)은 절대로 교사(Teacher)보다 잘하지 못함. 따라서 Teacher가 잘 못된 decision을 라벨로 주면 Judge는 그 오류를 그대로 학습. **Phase 2 데이터 한 줄의 품질이 Phase 3 이후 전체 결과를 결정.**

본 연구가 주장하는 "Selective Transfer Gate"(TRANSFER/PARTIAL/BLOCK)가 실증적으로 의미 있으려면, Teacher가 패턴별로 일관된 BLOCK·TRANSFER 신호를 만들어야 함. Pilot에서 세운 가설 ("brand_loyalty는 BLOCK 후보")이 Teacher 단에서 재현되지 않으면 논문의 핵심 주장이 무너짐. 50명 trial은 이 위험을 사전에 차단하는 안전장치.

1. 왜 50명 Trial을 진행했나

1. 왜 50명 Trial을 진행했나

Phase 2 본 실행(Train 800 + Valid 100 = **900명**)을 바로 시작하지 않고 50명 trial을 먼저 진행한 이유는 다음 4가지:

#	검증 목표	구체적 질문
1	파이프라인 무결성	Profiler 출력 → Teacher 프롬프트 → 7-pattern transfer_decisions JSON 생성 → SFT chat 포맷 변환의 end-to-end가 에러 없이 동작하는가?
2	비용·시간 예측	900명 본 실행 비용이 예산(\$5 이내) 안에 들어오는가? 소요 시간은 현실적인가?
3	Pilot 가설 재검증	Pilot에서 도출한 "brand_loyalty·sensory_preference는 거의 BLOCK" 가설이 Teacher 단에서도 재현되는가?
4	품질 필터 효과	"GT가 Top-10에 없으면 학습 제외" 로직이 실제로 얼마나 데이터를 걸러내는가? 잔존 데이터가 충분한가?

왜 50명인가: 너무 작으면 통계적 의미 없음 (≤ 20 명), 너무 크면 검증 코스트 과다 (≥ 200 명). 50명은 Pilot Study 100명 절반 규모로, Phase 1에서 brand_loyalty가 50.3%의 약한 신호로 일관됨을 확인한 패턴이라면 50명에서도 충분히 재현되리라 판단.

2. 실험 설계

항목	값
모델	GPT-4o-mini (Profiler·Teacher 동일, Teacher는 GT hint 받음)
샘플	Train 50명 (data/train_users_50.parquet , seed=42 고정)
입력	Profile JSON (7개 core_patterns) + 후보 도서 50권 + GT title 힌트
출력	transfer_decisions (7개 패턴 × {decision, rationale, transferred_insight, confidence}) + recommendations Top-10
학습 데이터 필터	GT가 Teacher 추천 Top-10 안에 있을 때만 학습 데이터로 채택 (= Teacher가 GT를 식별 못한 사용자는 잡음으로 보고 제외)
출력 위치	teacher_outputs/user_{id}.json · data/teacher_train_50.jsonl

3. 핵심 지표

37 학습 데이터 (lines)	74% acceptance rate	\$0.113 총 비용	107분 총 소요 시간
-----------------------------	-------------------------------	------------------------	------------------------

항목	값	평가
처리 사용자	50 / 50	✅ 100%
API 성공 (teacher_outputs)	50 / 50	✅ 100%
학습 데이터 채택	37 / 50 (74%)	✅ 본 실행 충분
GT not in Top-10 제외	13 / 50 (26%)	⚠️ 정상 범위
7-pattern 완전성	min=7 · max=8 (max=8은 additional_pattern 추가 1건)	✅
1차 실행 (50명)	\$0.077 · 99분 · success=27 fail=23	⚠️ Connection error
재실행 (실패 23명 + 신규)	\$0.036 · 8분 · 추가 success=10	✅ 모두 복구
900명 본 실행 비용 추정	\$0.113 × 18 = ~\$2.0	✅ 예산 내
900명 본 실행 시간 추정	네트워크 안정 시 ~10시간	✅

4. 발견된 문제: API Connection Error 23건

현상: 1차 실행 중 19:30 이후 23건의 Connection error 발생. OpenAI 서버 일시 장애 또는 로컬 네트워크 불안정 추정. 재시도 3회로도 복구 안 됨.

4.1 영향

- 50명 중 23명 (46%) 처리 실패
- 1차 실행 종료 시점: success=27, fail=23
- 실패 사용자는 teacher_outputs/ 에 JSON 생성 안 됨 → 다음 실행에서 재처리 가능 상태

4.2 발견한 부수 문제: 학습 데이터 덮어쓰기 위험

run_teacher.py 가 training_data 파일을 "w" (write) 모드로 열어, 재실행 시 기존 27줄이 모두 사라지는 위험. scripts/run_teacher.py:517에서 "w" → "a" (append)로 수정해 안전한 resume 보장.

4.3 재실행 결과

지표	1차	재실행	합계
처리 대상	50명 (전체)	16명 (실패 + 신규)	50명
API 성공	34건	16건	50건 (100%)
학습 데이터 추가	27	+10	37
GT not in Top-10	7	3	10
Connection error	23	0	0 (잔존)
비용	\$0.077	\$0.036	\$0.113
시간	99분	8분	107분

교훈 (본 실행 적용)

- ① Resume 로직 검증 완료 — `teacher_outputs/` 에 있으면 자동 skip
- ② append 모드로 학습 데이터 보존 안전
- ③ Connection error 시 즉시 동일 명령으로 재실행하면 처리 안 된 사용자만 재시도됨

5. 데이터 품질 검증

5.1 패턴별 Decision 분포 (261 decisions)

Pattern	TRANSFER	PARTIAL	BLOCK
genre_preference	19 (51%)	18 (49%)	0 (0%)
narrative_complexity	16 (43%)	18 (49%)	3 (8%)
pacing_preference	14 (38%)	21 (57%)	2 (5%)
quality_sensitivity	16 (43%)	18 (49%)	3 (8%)
brand_loyalty	0 (0%)	1 (3%)	36 (97%)
sensory_preference	0 (0%)	1 (3%)	36 (97%)
emotional_resonance	27 (73%)	6 (16%)	4 (11%)

5.2 가설 재검증

Pilot 가설	Trial 결과	판정
brand_loyalty는 영화 특정적, 책으로 거의 전이 안 됨	36/37 = 97% BLOCK	✅ 검증
sensory_preference (영상미 등)도 책에 부적합	36/37 = 97% BLOCK	✅ 검증
genre·narrative·pacing·quality는 cross-domain 전이 가능	이 4개 모두 TRANSFER+PARTIAL 합 92~100%	✅ 검증
emotional_resonance는 강한 전이 신호	27/37 = 73% TRANSFER	✅ 검증

5.3 균형성

Decision	개수	비율	학습 신호 균형도
TRANSFER	93	35.6%	3개 클래스 모두 30%대로 거의 완벽한 균형. Judge 학습 시 한 클래스로 편향될 위험 적음.
PARTIAL	84	32.2%	
BLOCK	84	32.2%	

6. 샘플 학습 레코드 검토

학습 데이터 1건의 transfer_decisions 7개 패턴 전체. 각 decision의 rationale·transferred_insight가 의미 있게 작성되는지 정성 확인.

샘플 사용자: (첫 학습 레코드)
전체 패턴 수: 7 개
recommendations: 10 권

genre_preference **PARTIAL** conf 0.75

insight: "Prefer family-oriented and holiday-themed novels with spiritual undertones."

rationale: "The user's preference for family, holiday, and spiritual themes suggests a liking for books that explore similar themes,..."

narrative_complexity **TRANSFER** conf 0.85

insight: "Prefer straightforward, uncomplicated narratives in books."

rationale: "A preference for simple narratives directly applies to books, indicating a desire for straightforward storytelling witho..."

pacing_preference **PARTIAL** conf 0.65

insight: "Prefer moderately paced narratives that allow for character development."

rationale: "The user's slow pacing preference suggests they enjoy books that allow for reflection and character development, but thi..."

quality_sensitivity **PARTIAL** conf 0.7

insight: "Prefer highly-rated and well-reviewed books."

rationale: "High sensitivity to quality in film suggests a preference for well-crafted books, but the specific aspects of quality ma..."

brand_loyalty **BLOCK** conf 0.9

insight: "None"

rationale: "Low brand loyalty indicates that the user does not have a strong attachment to specific authors or creators, making this..."

sensory_preference **BLOCK** conf 0.95

insight: "None"

rationale: "Sensory preferences related to emotional and heartwarming experiences in film do not translate directly to books, as the..."

emotional_resonance **TRANSFER** conf 0.8

insight: "Prefer emotionally impactful and inspiring literature."

rationale: "A high value on emotional resonance suggests a preference for books that evoke strong feelings and inspire, which is app..."

정성 평가: 모든 패턴에서 rationale이 추상적 nonsense가 아니라 사용자의 영화 선호를 책 도메인에 맞게 구체적으로 변환. transferred_insight도 책 추천에 즉시 활용 가능한 형태로 추출됨. brand_loyalty BLOCK의 rationale도 "감독 충성도는 저자 충성도로 1:1 매핑되지 않음"식의 명시적 근거 포함.

7. 결론 및 본 실행 결정

검증 항목 (1절)	결과
① 파이프라인 무결성	✅ end-to-end 100% 동작 (resume 포함)
② 비용·시간 예측	✅ ~\$2.0, ~10시간 — 예산·일정 모두 충족
③ Pilot 가설 재검증	✅ 4개 가설 모두 검증 (brand·sensory BLOCK 97% 등)
④ 품질 필터 효과	✅ 26% 제외 후 잔존 74% — Phase 3 학습에 충분

판정: 900명 본 실행 GO

모든 검증 항목 통과. 잔존 위험은 네트워크 안정성뿐이며, resume 로직으로 완화됨. 50명 trial로 얻은 37개 학습 데이터는 본 실행 데이터에 병합 가능.

7.1 본 실행 시 적용할 개선사항

1. **append 모드 적용 완료** — 학습 데이터 덮어쓰기 위험 제거
2. **중간 중단 대비** — `teacher_outputs/` 백업 자동화 권장
3. **Connection error 대비** — 동일 명령 재실행으로 자동 복구 (검증됨)

7.2 다음 단계

단계	내용	예상 비용·시간
Phase 2 본 실행	Train 800 + Valid 100 = 900명 Teacher Distillation	~\$2.0, ~10시간
Phase 2.5	학습 데이터 검증 + GitHub Push + RunPod Sync	~30분
Phase 3	RunPod에서 Qwen3-14B QLoRA 파인튜닝	\$3~5, 6~8시간