

# Phase 4 평가 계획

TransferJudge · 6 conditions Ablation + 평가 지표

2026.05.14 · 빅데이터학과 17기 박민아

## 한 줄 요약

학습된 Judge(Qwen3-14B QLoRA)와 5개 baseline을 Test set 100명에 대해 동일 조건으로 평가. HR@k·NDCG@k·MRR + Pattern Decision Accuracy 등 11개 지표로 본 연구의 3가지 핵심 가설을 검증.

## 0. 핵심 가설 (Research Questions)

| RQ  | 가설                                                                 | 검증 조건                                         |
|-----|--------------------------------------------------------------------|-----------------------------------------------|
| RQ1 | 구조화된 Profile이 raw review와 전통 CDR보다 cross-domain 추천을 개선했다           | (c) vs (f) Raw Review, (c) vs (e1)(e2) 전통 CDR |
| RQ2 | Transfer Gate (TRANSFER/PARTIAL/BLOCK)가 성능에 기여한다                   | (c) vs (d) w/o Gate                           |
| RQ3 | Profiler-Judge 분리 + Judge 파인튜닝이 단일 LLM·prompt-only·기존 LLM CDR보다 낫다 | (c) vs (a), (b), (g) TALLRec                  |

## 1. 8개 평가 조건 (Conditions) — Codex 권장 baseline 확장

| 조건                  | 모델·방식                                                        | Profile | Gate | 학습                   | 환경           |
|---------------------|--------------------------------------------------------------|---------|------|----------------------|--------------|
| (a) Single LLM      | GPT-4o-mini (raw review 직접 입력 + Top-10 추천)                   | ✗       | ✗    | zero-shot            | Mac (OpenAI) |
| (b) Prompt-only     | GPT-4o-mini (Profile + 추천, 학습·gate 없음)                       | ✓       | ✗    | zero-shot            | Mac (OpenAI) |
| (c) Ours ★          | Qwen3-14B QLoRA (Profile + Gate + 578줄 SFT)                  | ✓       | ✓    | 578줄 SFT             | RunPod       |
| (d) w/o Gate        | Qwen3-14B QLoRA (Profile만, gate 비활성)                         | ✓       | ✗    | 578줄 SFT             | RunPod       |
| (e1) EMCDR (2017)   | Embedding mapping (Man et al., IJCAI)                        | —       | —    | matrix factorization | RunPod       |
| (e2) PTUPCDR (2022) | Personalized Transfer (Zhu et al., WSDM) — 최신 전통 CDR         | —       | —    | meta-learning        | RunPod       |
| (f) Raw Review      | Qwen3-14B (Profile 없이 raw review로 SFT)                       | ✗       | ✗    | 같은 데이터, raw 입력       | RunPod       |
| (g) TALLRec (2023)  | Bao et al. (RecSys) — LLM as recommender via instruction SFT | —       | ✗    | review-based SFT     | RunPod       |

#### baseline 강화 근거 (Codex 권장 반영)

이전 6 conditions는 (e) 1개 외엔 모두 본 연구의 변형 → 사실상 self-ablation에 가까웠음. 강화한 baseline 2개:

- **(e2) PTUPCDR**: 2017 EMCDR만으로는 최신성 부족. 2022 SOTA 전통 CDR로 spectrum 확장.
- **(g) TALLRec**: 본 연구도 LLM 기반인데 다른 LLM CDR 비교 없으면 심사 약함. 가장 인용 많은 LLM CDR (RecSys 2023).

추가 비용 +\$3, 시간 +2h. 본 연구 차별성(selective transfer)을 명확히 입증.

모든 조건은 **동일한 Test 100명 + 동일한 후보 50권 (seed=42)**에서 평가. 이는 BLOCK leakage-data leakage 사전 차단 + 비교 공정성 확보.

## 2. 평가 지표 (자세한 정의: docs/phase4/Phase4\_Metrics.md)

### 2.1 추천 정확도

| 지표            | 의미                | 본 연구 목표                              |
|---------------|-------------------|--------------------------------------|
| HR@1, @5, @10 | Top-k 안에 정답 포함 비율 | HR@10 $\geq$ 0.60 (Teacher 60.2% 기준) |
| NDCG@5, @10   | 순위 가중 정확도         | NDCG@10 $\geq$ 0.25                  |
| MRR           | 정답 역순위 평균         | $\geq$ 0.15                          |

### 2.2 출력 품질

| 지표             | 의미                  | 목표          |
|----------------|---------------------|-------------|
| JSONValid      | 유효 JSON 비율          | $\geq$ 0.95 |
| SchemaComplete | 스키마 충족 비율           | $\geq$ 0.95 |
| CandMembership | 후보 50권 내 추천 비율      | = 1.00      |
| BLOCKLeakage   | BLOCK 패턴이 추천 근거로 사용 | = 0.00      |

### 2.3 추론 품질 (신규 메트릭)

| 지표                              | 의미                                                       | 목표                     |
|---------------------------------|----------------------------------------------------------|------------------------|
| PDA (Pattern Decision Accuracy) | Judge의 transfer_decisions가 Teacher와 일치율                  | $\geq$ 0.80            |
| Decision JSD                    | Decision 분포가 Teacher와 얼마나 일치 (Jensen-Shannon Divergence) | $\leq$ 0.05            |
| BrandLoyaltyBLOCK               | brand_loyalty가 BLOCK으로 판정된 비율                            | $\geq$ 0.90 (가설 검증)    |
| SensoryTRANSFER                 | sensory_preference가 TRANSFER로 판정된 비율                     | 30~75% (subtype 분리 효과) |

## 3. 평가 흐름

### 3.1 입력 데이터

| 파일                                  | 역할                         |
|-------------------------------------|----------------------------|
| data/test_users.parquet             | Test 100명 user_id          |
| profiler_outputs/user_{id}.json     | 각 사용자의 7-pattern Profile   |
| data/books_reviews_filtered.parquet | GT 추출 (rating $\geq$ 4 최근) |
| data/books_meta_filtered.parquet    | 후보 도서 50권 sampling pool    |

### 3.2 각 조건의 추론 흐름

| 조건              | 입력                     | 출력                                            |
|-----------------|------------------------|-----------------------------------------------|
| (a) Single LLM  | raw 영화 리뷰 30개 + 후보 50권 | OpenAI API → Top-10 (JSON)                    |
| (b) Prompt-only | Profile JSON + 후보 50권  | OpenAI API → transfer_decisions + Top-10      |
| (c) Ours        | Profile JSON + 후보 50권  | Judge inference → transfer_decisions + Top-10 |
| (d) w/o Gate    | Profile JSON + 후보 50권  | Judge inference (gate 토큰 마스크 OFF) → Top-10    |
| (e) 전통 CDR      | Movies-Books 평점 행렬     | matrix factorization → 잠재 벡터 → Top-10         |
| (f) Raw Review  | raw 영화 리뷰 30개 + 후보 50권 | Qwen3-14B (Profile 없이 학습) → Top-10            |

### 3.3 산출물 파일 구조

```

results/
├─ ablation_a_single.json      # (a) Single LLM
├─ ablation_b_prompt.json     # (b) Prompt-only
├─ ablation_c_ours.json       # (c) Ours (메인 결과)
├─ ablation_d_no_gate.json    # (d) w/o Gate
├─ ablation_e_traditional.json # (e) 전통 CDR
├─ ablation_f_raw.json        # (f) Raw Review
├─ per_user_predictions.jsonl  # 사용자별 추천 결과
└─ comparison_table.csv       # 6개 조건 통합 표

```

## 4. 일정 + 비용

| 단계     | 조건              | 환경           | 시간            | 비용      |
|--------|-----------------|--------------|---------------|---------|
| 4a     | (c) Ours ★      | RunPod       | ~2h           | \$2~3   |
| 4b-i   | (a) Single LLM  | Mac (OpenAI) | ~2h           | \$1~2   |
| 4b-ii  | (b) Prompt-only | Mac (OpenAI) | ~2h           | \$2~3   |
| 4b-iii | (d) w/o Gate    | RunPod       | ~2h           | \$2~3   |
| 4b-iv  | (f) Raw Review  | RunPod       | ~2h           | \$2~3   |
| 4c-i   | (e1) EMCDR      | RunPod       | ~2h           | \$1~2   |
| 4c-ii  | (e2) PTUPCDR    | RunPod       | ~2h           | \$1~2   |
| 4d     | (g) TALLRec     | RunPod       | ~3h (학습 + 평가) | \$2~3   |
| 총      | —               | —            | ~17h          | \$13~21 |

## 5. 코드 실행 명령어

### 5.1 (c) Ours 평가

```
python3 scripts/evaluate_judge.py \  
  --condition c_ours \  
  --adapter checkpoints/judge_v1/adapter \  
  --test-users data/test_users.parquet \  
  --profiles profiler_outputs/ \  
  --books-meta data/books_meta_filtered.parquet \  
  --books-reviews data/books_reviews_filtered.parquet \  
  --output results/ablation_c_ours.json
```

### 5.2 (a)(b) OpenAI API 기반

```
python3 scripts/run_ablation.py \  
  --condition a_single \  
  --test-users data/test_users.parquet \  
  --output results/ablation_a_single.json  
  
python3 scripts/run_ablation.py \  
  --condition b_prompt \  
  --profiles profiler_outputs/ \  
  --output results/ablation_b_prompt.json
```

### 5.3 6개 조건 모두 한번에

```
bash scripts/run_all_ablations.sh
# 또는 Makefile:
make ablation-all
```

## 6. 평가 완료 기준

| 기준                                                               | 판정                            |
|------------------------------------------------------------------|-------------------------------|
| 8개 결과 파일 모두 생성                                                   | 필수                            |
| HR@10 (c) > HR@10 (a), (b), (f)                                  | RQ3 부분 (단순 baseline)          |
| <b>HR@10 (c) &gt; HR@10 (g) TALLRec</b>                          | <b>RQ3 핵심 — LLM CDR 대비 우위</b> |
| NDCG@10 (c) > NDCG@10 (d)                                        | RQ2 — Gate 효과                 |
| NDCG@10 (c) > NDCG@10 (e1), (e2)                                 | RQ1 — Profile 효과 vs 전통 CDR    |
| Pattern Decision Accuracy $\geq 0.80$                            | Judge 학습 품질                   |
| paired t-test (c) vs (a) $p < 0.05$                              | 통계적 유의성 (vs 단순)               |
| <b>paired t-test (c) vs (g) TALLRec <math>p &lt; 0.05</math></b> | <b>통계적 유의성 (vs LLM SOTA)</b>  |

**Phase 4 통과 시 → Phase 5 진입:** Per-Pattern Ablation (7 패턴 각각 BLOCK 시 영향) + Cold-Start segment 분석 (Severe/Moderate/Warm).