

Phase 4 평가 계획

TransferJudge · 6 conditions Ablation + 평가 지표

2026.05.14 · 빅데이터학과 17기 박민아

한 줄 요약

학습된 Judge(Qwen3-14B QLoRA)와 5개 baseline을 Test set 100명에 대해 동일 조건으로 평가. HR@k·NDCG@k·MRR + Pattern Decision Accuracy 등 11개 지표로 본 연구의 3가지 핵심 가설을 검증.

0. 핵심 가설 (Research Questions)

RQ	가설	검증 조건
RQ1	구조화된 preference profile은 raw review 입력 및 전통 CDR baseline 대비 cold-start CDR 성능을 개선하는가?	(c) vs (f), (c) vs (e)
RQ2	Pattern-level Transfer Gate는 모든 preference signal을 균일하게 전이하는 방식보다 negative transfer를 줄이고 성능을 높이는가?	(c) vs (d)
RQ3	Profiler-Judge 구조와 Judge 파인튜닝은 single-prompt LLM / prompt-only / LLM-based CDR baseline 대비 더 효과적인가?	(c) vs (a)(b)(g)
RQ4	Movies-to-Books 전이에서 어떤 preference pattern이 transferable, partially transferable, domain-specific으로 작동하는가?	Phase 5a Per-Pattern Ablation

RQ 문장은 "비교 범주" 중심으로 기술 (특정 논문 이름 박지 않음). 구체적 baseline 모델은 아래 §1 8 conditions 표에서 명시.

1. 7개 평가 조건 (Conditions) — Codex 권장 현실 버전

조건	모델 방식	Profile	Gate	학습	환경
(a) Single LLM	GPT-4o-mini (raw review 직접 입력 + Top-10 추천)	✗	✗	zero-shot	Mac (OpenAI)
(b) Prompt-only	GPT-4o-mini (Profile + 추천, 학습·gate 없음)	✓	✗	zero-shot	Mac (OpenAI)
(c) Ours ★	Qwen3-14B QLoRA (Profile + Gate + 578줄 SFT)	✓	✓	578줄 SFT	RunPod
(d) w/o Gate	Qwen3-14B QLoRA (Profile만, gate 비활성)	✓	✗	578줄 SFT	RunPod
(e) EMCDR (2017)	Embedding mapping (Man et al., IJCAI) — 전통 CDR 대표	—	—	matrix factorization	RunPod
(f) Raw Review	Qwen3-14B (Profile 없이 raw review로 SFT)	✗	✗		RunPod

같은 데이터, raw
입력

(g) LLM4CDR-style	single-LLM cross-domain recommendation (Liu et al., arXiv 2503.07761)	—	✗	prompt-only LLM CDR	 RunPod
-------------------	--	---	---	------------------------	--

baseline 선정 근거 (Codex 3차 권장 — 현실 버전)

이전 6 conditions는 self-ablation 위주 → 외부 비교 부족. 이번엔 핵심만 1개씩 추가하여 7 conditions로 정리:

- (e) EMCDR (IJCAI 2017): 전통 CDR 대표. "LLM 기반 vs MF 기반" 검증 1개로 충분.
- (g) LLM4CDR-style (arXiv 2503.07761): LLM 기반 CDR 직접 비교. 본 연구 핵심 차별성 입증.

제외한 baseline (Related Work에서만 논의):

- PTUPCDR (WSDM 2022): meta-learning(MAML) 재현 부담 큼. 본 연구는 전통 CDR SOTA 재현이 목적 아님.
- TALLRec (RecSys 2023): single-domain LLM recommendation tuning. CDR 비교 대상 아님.

본 연구 핵심은 **selective transfer + pattern gate (RQ2, RQ4)**이므로 외부 비교는 "방어용으로 충분히"만 가져가고 에너지는 (c) vs (d), (c) vs (g), RQ4 분석에 집중.

모든 조건은 **동일한 Test 100명 + 동일한 후보 50권 (seed=42)**에서 평가. 이는 BLOCK leakage·data leakage 사전 차단 + 비교 공정성 확보.

2. 평가 지표 (자세한 정의: docs/phase4/Phase4_Metrics.md)

2.1 추천 정확도

지표	의미	본 연구 목표
HR@1, @5, @10	Top-k 안에 정답 포함 비율	HR@10 $\geq$ 0.60 (Teacher 60.2% 기준)
NDCG@5, @10	순위 가중 정확도	NDCG@10 $\geq$ 0.25
MRR	정답 역순위 평균	$\geq$ 0.15

2.2 출력 품질

지표	의미	목표
JSONValid	유효 JSON 비율	$\geq$ 0.95
SchemaComplete	스키마 충족 비율	$\geq$ 0.95
CandMembership	후보 50권 내 추천 비율	= 1.00
BLOCKLeakage	BLOCK 패턴이 추천 근거로 사용	= 0.00

2.3 추론 품질 (신규 메트릭)

지표	의미	목표
PDA (Pattern Decision Accuracy)	Judge의 transfer_decisions가 Teacher와 일치율	$\geq$ 0.80
Decision JSD	Decision 분포가 Teacher와 얼마나 일치 (Jensen-Shannon Divergence)	$\leq$ 0.05
BrandLoyaltyBLOCK	brand_loyalty가 BLOCK으로 판정된 비율	$\geq$ 0.90 (가설 검증)
SensoryTRANSFER	sensory_preference가 TRANSFER로 판정된 비율	30~75% (subtype 분리 효과)

3. 평가 흐름

3.1 입력 데이터

파일	역할
data/test_users.parquet	Test 100명 user_id
profiler_outputs/user_{id}.json	각 사용자의 7-pattern Profile
data/books_reviews_filtered.parquet	GT 추출 (rating $\geq$ 4 최근)
data/books_meta_filtered.parquet	후보 도서 50권 sampling pool

3.2 각 조건의 추론 흐름

조건	입력	출력
(a) Single LLM	raw 영화 리뷰 30개 + 후보 50권	OpenAI API → Top-10 (JSON)
(b) Prompt-only	Profile JSON + 후보 50권	OpenAI API → transfer_decisions + Top-10
(c) Ours	Profile JSON + 후보 50권	Judge inference → transfer_decisions + Top-10
(d) w/o Gate	Profile JSON + 후보 50권	Judge inference (gate 토큰 마스크 OFF) → Top-10
(e) 전통 CDR	Movies-Books 평점 행렬	matrix factorization → 잠재 벡터 → Top-10
(f) Raw Review	raw 영화 리뷰 30개 + 후보 50권	Qwen3-14B (Profile 없이 학습) → Top-10

3.3 산출물 파일 구조

```

results/
├─ ablation_a_single.json      # (a) Single LLM
├─ ablation_b_prompt.json     # (b) Prompt-only
├─ ablation_c_ours.json       # (c) Ours (메인 결과)
├─ ablation_d_no_gate.json    # (d) w/o Gate
├─ ablation_e_traditional.json # (e) 전통 CDR
├─ ablation_f_raw.json        # (f) Raw Review
├─ per_user_predictions.jsonl  # 사용자별 추천 결과
└─ comparison_table.csv       # 6개 조건 통합 표

```

4. 일정 + 비용

단계	조건	환경	시간	비용
4a	(c) Ours ★	RunPod	~2h	\$2~3
4b-i	(a) Single LLM	Mac (OpenAI)	~2h	\$1~2
4b-ii	(b) Prompt-only	Mac (OpenAI)	~2h	\$2~3
4b-iii	(d) w/o Gate	RunPod	~2h	\$2~3
4b-iv	(f) Raw Review	RunPod	~2h	\$2~3
4c	(e) EMCDR	RunPod	~2h	\$1~2
4d	(g) LLM4CDR-style	RunPod	~3h (학습 + 평가)	\$2~3
총	—	—	~15h	\$12~19

PTUPCDR 제거로 2-3일 구현 시간 절감. 절약된 에너지는 Phase 5a Per-Pattern (RQ4)와 (c) vs (g) LLM4CDR-style 비교 디버깅에 투입.

5. 코드 실행 명령어

5.1 (c) Ours 평가

```
python3 scripts/evaluate_judge.py \
  --condition c_ours \
  --adapter checkpoints/judge_v1/adapter \
  --test-users data/test_users.parquet \
  --profiles profiler_outputs/ \
  --books-meta data/books_meta_filtered.parquet \
  --books-reviews data/books_reviews_filtered.parquet \
  --output results/ablation_c_ours.json
```

5.2 (a)(b) OpenAI API 기반

```
python3 scripts/run_ablation.py \
  --condition a_single \
  --test-users data/test_users.parquet \
  --output results/ablation_a_single.json

python3 scripts/run_ablation.py \
  --condition b_prompt \
  --profiles profiler_outputs/ \
  --output results/ablation_b_prompt.json
```

5.3 6개 조건 모두 한번에

```
bash scripts/run_all_ablations.sh
# 또는 Makefile:
make ablation-all
```

6. 평가 완료 기준

기준	판정
7개 결과 파일 모두 생성	필수
HR@10 (c) > HR@10 (a), (b), (f)	RQ3 부분 (단순 baseline)
HR@10 (c) > HR@10 (g) LLM4CDR-style	RQ3 핵심 — LLM CDR 대비 우위
NDCG@10 (c) > NDCG@10 (d)	RQ2 — Gate 효과
NDCG@10 (c) > NDCG@10 (e)	RQ1 — Profile 효과 vs 전통 CDR
Pattern Decision Accuracy ≥ 0.80	Judge 학습 품질
paired t-test (c) vs (a) $p < 0.05$	통계적 유의성 (vs 단순)
paired t-test (c) vs (g) LLM4CDR-style $p < 0.05$	통계적 유의성 (vs LLM CDR)

Phase 4 통과 시 → Phase 5 진입: Per-Pattern Ablation (7 패턴 각각 BLOCK 시 영향) + Cold-Start segment 분석 (Severe/Moderate/Warm).