

Phase 6 결과 분석 + 시각화 계획

TransferJudge · 통계 검증 + 논문용 figure·table 생성

2026.05.14 · 빅데이터학과 17기 박민아

한 줄 요약

Phase 4·5에서 만들어진 모든 결과 파일을 통합 시각화하고 통계적 유의성 검증을 거쳐 논문 본문에 들어갈 5개 핵심 figure와 4개 table을 생성. 모든 분석은 Mac 로컬에서 진행 (추가 GPU 비용 없음).

1. 분석 대상 데이터

경로	내용	출처
results/ablation_*.json	6개 조건 평가 결과	Phase 4
results/per_pattern_*.json	7개 패턴 ablation 결과	Phase 5a
results/cold_start_analysis.json	3 segment × 6 조건	Phase 5b
results/per_user_predictions.jsonl	사용자별 추천 결과 (paired test용)	Phase 4
checkpoints/judge_v1/trainer_state.json	학습 loss 추이	Phase 3

2. 핵심 Figure 5개 (논문 본문용)

#	Figure	의미	도구
F1	학습 loss curve (train + eval, epoch별)	학습이 정상 수렴했음을 증명	matplotlib
F2	6 conditions × 3 metrics 막대그래프 (HR@10, NDCG@10, MRR)	Ours vs baseline 직관적 비교	matplotlib
F3	Pattern Importance Heatmap (7 × 3)	brand_loyalty BLOCK 검증 가시화	seaborn heatmap
F4	Cold-Start Segment 그래프 (Severe/Moderate/Warm)	cold-start 강건성 증명	matplotlib (clustered bar)
F5	Decision Distribution (Teacher vs Judge) — JSD 시각화	Judge가 Teacher의 reasoning 패턴을 학습했음	matplotlib stacked bar

3. 논문 Table 4개

#	Table	내용
T1	Dataset Statistics	1,000 cohort · 578 train · 100 valid · 100 test, leakage 0
T2	Main Results (6 conditions × metrics)	HR@1, HR@5, HR@10, NDCG@5, NDCG@10, MRR + paired t-test 결과

T3	Per-Pattern Ablation (7 패턴)	각 패턴 제거 시 Δ NDCG@10 + interpretation
T4	Cold-Start Segment Analysis	6 conditions $\times$ 3 segments $\times$ NDCG@10

4. 통계 검증

4.1 Paired t-test

비교	가설
(c) vs (a)	$NDCG@10(c) > NDCG@10(a), p < 0.05$
(c) vs (b)	같음 (prompt-only 대비 학습 효과)
(c) vs (d)	Gate 효과 입증
(c) vs (f)	Profile 효과 입증

4.2 Effect Size (Cohen's d)

비교	목표 d	해석
(c) vs (a)	$d \geq 0.5$	medium effect
(c) vs (b)	$d \geq 0.3$	small-medium effect
(c) vs (e)	$d \geq 0.8$	large effect (LLM vs 전통)

4.3 Bootstrap 95% Confidence Interval

1,000회 bootstrap resampling으로 각 metric의 95% CI 계산 → 표에 ± 표기.

예: $NDCG@10(c) Ours = 0.28 \pm 0.02$ (95% CI [0.26, 0.30])

5. Qualitative Analysis (정성 분석)

5.1 성공 사례 (Case Study)

분석 항목	방법
Ours가 정답 맞춘 사용자 3명	Profile 7-pattern + Judge transfer_decisions + 추천 근거 분석
Single LLM은 못 맞췄지만 Ours가 맞춘 사례	Gate의 명시적 효과 사례
brand_loyalty BLOCK의 효과 사례	Single LLM이 actor 이름 매칭으로 부정 추천한 사례

5.2 실패 사례 분석

분석 항목	방법
모든 조건이 못 맞춘 사용자	본 연구의 한계 영역 (Profile 신호 부족)
Ours만 못 맞춘 사용자	학습 데이터 분포 외 사례

6. 시각화 도구 (visualize_results.py)

6.1 사용법

```
python3 scripts/visualize_results.py \
  --results-dir results/ \
  --trainer-state checkpoints/judge_v1/trainer_state.json \
  --output docs/phase6/figures/
```

6.2 생성 파일

```
docs/phase6/figures/
├─ F1_loss_curve.png
├─ F2_main_comparison.png
├─ F3_pattern_heatmap.png
├─ F4_cold_start_segments.png
├─ F5_decision_distribution.png
└─ tables/
   ├─ T1_dataset_stats.csv
   ├─ T2_main_results.csv
   ├─ T3_pattern_ablation.csv
   └─ T4_cold_start.csv
```

7. 일정 + 비용

단계	내용	시간	비용
6.1	모든 결과 파일 로드 + 통합 표	1h	0
6.2	5개 Figure 생성	2h	0
6.3	Paired t-test + Cohen's d + Bootstrap CI	2h	0
6.4	Case study 사용자 3-5명 선정 + 정성 분석	3h	0
6.5	결과 종합 보고서 PDF 생성	2h	0
총	—	~10h (1.5일)	\$0

Phase 6 완료 시 → Phase 7 진입: 5 figure + 4 table 확보 → 논문 본문 작성.