

Pilot Study Report v5

TransferJudge — 7개 Core Pattern 도출 과정 (4단계 프로세스 상세)

자유 추출의 한계 → 이론 anchor → Pilot 검증 → emotional 추가

2026.05 · 빅데이터학과 17기 곽민아

💡 이 보고서가 답하는 4가지 질문

- Q1. LLM에게 그냥 패턴을 자유롭게 뽑게 하면 안 되나? → §1
 - Q2. 이론으로부터 어떻게 6개 후보를 도출했나? → §3
 - Q3. Pilot 100명에 자유 추출은 왜? 391개는 어떻게 만들었나? → §4
 - Q4. 6개와 391개를 임베딩 매칭한 이유와 결과의 의미? → §5
- + emotional_resonance를 7번째로 추가한 근거 → §6

1. 왜 자유 추출만으로는 부족한가

본 Pilot Study를 진행한 가장 큰 이유는 "LLM에게 패턴을 자유롭게 추출시키면 어떤 결과가 나오는지"를 데이터로 확인하기 위함이다. 결론부터 말하면, **자유 추출 결과의 90.8%가 Cross-Domain 추천에 부적합**했다.

1.1 가설 — "자유 추출이면 충분할까?"

본 연구는 영화 리뷰에서 사용자 선호 패턴을 추출하여 책 추천에 활용한다. 가장 단순한 접근은 LLM에게 다음과 같이 묻는 것이다:

"이 사용자의 리뷰를 보고, 어떤 선호 패턴이든 자유롭게 추출하세요. (개수 제한 없음)"

이 접근의 장점은 **편향 없는 발견**이지만, 단점은 **매체-특화·표층·메타 신호가 우세**해질 가능성이 있다.

1.2 Pilot 100명 실제 자유 추출 결과 (391 canonical 패턴)

391개를 4가지 카테고리로 자동 분류한 결과:

카테고리	의미	예시	수	비율
CDR 적합	책 추천에 쓸 만한 패턴	"narrative_complexity"	36	9.2%
표층 신호	구체 장르명·감정 단어	"nostalgic_preference"	79	20.2%
매체-종속	영화 전용 키워드 보유	"IMAX_visuals"	268	68.5%
메타 정보	패턴이 아닌 표현	"high_recommendation"	8	2.0%
비-CDR-적합 합계			355	90.8%

1.3 자유 추출 단독으로 본 연구가 안 되는 6가지 이유

측면	자유 추출의 한계
1) Cross-Domain 부적합	90.8%가 책 추천에 무관 — "IMAX 영상미"는 책에 매핑 불가
2) Transfer Gate 작동 불가	사용자마다 패턴 셋이 달라 TRANSFER/PARTIAL/BLOCK 사전 라벨 불가능 — 본 연구 핵심 contribution 무력화
3) 사용자 간 비교 불가	User A의 5개 패턴 vs User B의 8개 패턴 — 공통 키 없음
4) Teacher 학습 불일관	QLoRA 입력·출력 JSON 스키마가 사용자마다 달라 학습 효과 ↓
5) 재현성·비용 가변	같은 사용자 두 번 호출 시 다른 결과 가능
6) 선행연구 비교 불가	LLM4CDR·TALLRec 등 모두 명시 attribute 사용 → 자유 추출 단독은 비교군 없음

핵심 발견: 자유 추출은 풍부한 신호를 주지만 그중 9%만 책 추천에 유용하다. 따라서 본 연구는 명시적 prompt로 7개 패턴을 강제 추출하는 구조화 접근을 채택한다. 단, additional_patterns 최대 3개를 자유롭게 추가하여 long-tail 발견 가능성도 보존한다.

💡 쉬운 설명 — 자유 추출의 직관

"하고 싶은 말 다 해 봐"라고 하면 사용자는 영화 관련 얘기를 100% 쏟아낸다. 그중 책 추천에도 쓸 수 있는 것은 약 10% 뿐이다. 본 연구는 이 사실을 데이터로 보이고, 명시 prompt(7개 패턴 강제 추출)의 정당성을 확보한다.

2. 4단계 프로세스 한눈에



💡 쉬운 설명 — 왜 4단계인가

1단계는 "이론에서 출발"(밖에서 빌려옴), 2단계는 "데이터로 검증"(데이터 진실 측정), 3단계는 "매칭으로 정합 확인"(이론이 데이터에 실재하나?), 4단계는 "데이터 신호로 보완"(이론에 없지만 데이터가 말하는 것). 이렇게 이론과 데이터를 양 방향으로 사용했다.

3. Step 1 — 이론으로부터 6개 후보 도출

3.1 이론 anchor (참고 학술)

본 연구가 6개 후보 패턴을 도출하기 위해 참고한 학술 출처와 각각으로부터 정확히 무엇을 가져왔는지:

인용	해당 논문이 제시한 것	본 연구가 차용한 것
Thet, Na & Khoo (2010) Aspect-based sentiment analysis of movie reviews on discussion boards	영화 리뷰를 7개 aspect로 분해: storyline, characters, screenplay, acting, direction, scene, music	① 7개 aspect를 본 연구 6개 후보 패턴의 기반으로 사용 (§3.2 매핑) ② "리뷰를 aspect 단위로 분해"라는 접근법 차용 ③ 영화 도메인 특화 표현 (scene·music)을 BLOCK 시연 후보로 활용
Liu, B. (2012) Sentiment Analysis and Opinion Mining	Aspect-Based Sentiment Analysis (ABSA) 일반 프레임워크 — 리뷰를 4~6개 aspect 로 분해하는 표준 정립	① "5±1 aspect 분해"라는 표준 개수 정당화 ② Aspect 기반 분해를 sentiment가 아닌 사용자 선호 추출 로 확장
(보조) Oliver (1999) "Whence Consumer Loyalty?"	마케팅 분야의 "brand loyalty" 표준 개념 — 반복 구매·추천 경향	brand_loyalty 패턴 명칭과 정의를 차용 (단, 영화 감독·배우로 도메인 확장)
(보조) Ricci, Rokach & Shapira (2015) Recommender Systems Handbook	추천시스템 사용자 모델링 표준 attribute (rating sensitivity, user bias 등)	quality_sensitivity 패턴 개념 차용 (제작 품질 민감도)
(보조) He et al. (2017) NCF · Bao et al. (2023) TALLRec	LLM·신경망 기반 추천 모델에서 genre/category attribute 의 표준 사용	genre_preference 패턴 명칭 차용 (추천시스템 관행)

요약: Thet 2010이 본 연구의 가장 직접적 이론 anchor (6개 후보 중 5개의 출처). Liu 2012는 "리뷰를 5±1 aspect로 분해"라는 표준을 제공. 나머지 보조 인용은 개별 패턴의 명칭·개념 차용에 기여.

💡 쉬운 설명 — ABSA가 뭐야?

ABSA (Aspect-Based Sentiment Analysis, 측면 기반 감성 분석) 는 리뷰를 "**측면(aspect)**"이라는 작은 단위로 쪼개는 표준 방법. 예를 들어 영화 리뷰 "스토리는 좋는데 연기가 별로"는 [스토리=긍정, 연기=부정]으로 분해된다. 본 연구는 이 분해 단위(aspect)를 **사용자 선호 패턴**으로 재해석했다.

3.2 Thet 2010의 7개 영화 aspect → 본 연구의 6개 후보 (재구성)

한글	변환 논리	본 연구 후보
----	-------	---------

Thet 2010 영화 aspect				Cross-Domain
storyline + characters + screenplay	줄거리 + 인물 + 각본	3개를 "서사 복잡도"로 통합 (책에도 적용)	narrative_complexity	TRANSFER
pace (storytelling)	전개 속도	Thet은 보조 attribute, 본 연구는 독립 패턴으로 격상 (책에서도 page-turner ↔ slow-burn 명확)	pacing_preference	TRANSFER
acting + direction	연기 + 연출	"제작 품질"로 일반화 (책 도메인에서는 문체·편집·번역으로 변환)	quality_sensitivity	PARTIAL
director + cast (창작자 차원)	감독·출연진	"창작자 충성도"로 일반화 + Oliver (1999) brand loyalty 차용. 영화 감독은 책에 부재 → BLOCK 후보	brand_loyalty	BLOCK 후보
scene + music + visual	장면·음악·영상	"감각적 경험"으로 통합. 영화 매체 특화 → BLOCK 시연 목적	sensory_preference	BLOCK 후보
(영화 category)	장르	Thet에 명시되지 않으나 추천시스템 표준 attribute (NCF, TALLRec 등)에 항상 등장	genre_preference	TRANSFER

3.3 도출 논리 정리

1. Thet 2010의 7개 영화 aspect를 출발점으로 삼되, 본 연구는 Cross-Domain (영화 → 책) 추천이므로 책 도메인에도 적용 가능한 형태로 재구성한다.
2. 3개 서사 관련 aspect(storyline·characters·screenplay)는 "narrative_complexity"로 통합 — 책에서도 자연스럽게 적용.
3. 2개 창작자 관련 aspect(acting·direction)는 "quality_sensitivity"로 일반화 — 매체별 지표는 다르지만 품질 민감도 자체는 도메인 독립.
4. 창작자 충성도(director·cast)는 "brand_loyalty"로 일반화 — 영화 감독은 책 작가가 아니라 BLOCK 시연 후보로 의도적 채택.
5. 감각 차원(scene·music)은 "sensory_preference"로 통합. 책에 거의 적용 불가능한 영화 특화 패턴이지만 **의도적으로** 채택 (아래 박스 참조).
6. genre는 Thet 외에 NCF·TALLRec 등 추천시스템 표준 attribute에서 차용.

왜 영화 한정 패턴(sensory)을 일부러 포함시켰나?

본 연구의 핵심 contribution은 **Transfer Gate** — "어떤 패턴은 책 추천에 가져가고, 어떤 패턴은 차단해야 한다"는 자동 판정 메커니즘이다. 이 메커니즘이 의미를 가지려면 **"실제로 차단되어야 마땅한 패턴"**이 데이터에 존재해야 한다.

sensory_preference("IMAX 영상미", "사운드트랙", "액션 안무" 등)는 영화에선 강한 신호이지만 책에는 매핑이 거의 불가능하다. Transfer Gate가 없다면 LLM이 이 패턴을 보고 책을 추천하려다 **엉뚱한 책**(예: 영화 화보집)을 추천할 위험이 있다 — 본 연구가 풀려는 **Negative Transfer**의 전형적 사례.

sensory_preference를 일부러 후보에 넣는 이유:

- ① **"문제가 있는 패턴"의 데이터 표본 확보** — Gate가 차단해야 할 대상이 데이터에 실제 등장해야 Gate 효과 측정 가능
- ② **BLOCK 메커니즘의 정당성 실증** — "sensory_preference는 책 추천에서 BLOCK으로 판정된다"는 사실을 데이터로 입증
- ③ **Ablation 비교 도구** — Gate ON vs OFF 비교 실험의 핵심 패턴 (차단 대상이 없으면 Ablation 비교 무의미)

요컨대 "차단되어야 마땅한 패턴"을 의도적으로 포함해서 Gate가 실제로 작동함을 데이터로 증명하기 위한 설계 결정이다.

Step 1 산출: 6개 후보 패턴

genre · narrative_complexity · pacing · quality · brand · sensory (모두 영문 표기)

Cross-Domain 라벨 사전 분류: **TRANSFER 3 + PARTIAL 1 + BLOCK 후보 2** → Transfer Gate 3-level 검증 가능한 구성.

3.4 6개 후보 패턴 정의서 (영문 + 국문 + 예시)

각 후보 패턴의 정확한 정의. 이 텍스트가 \$5 임베딩 매칭의 "후보 정의 텍스트" 입력으로 사용된다.

1. genre_preference

English: The user's preference for specific content genres or categories (e.g., sci-fi, thriller, romance, biography). Includes both preferred and disliked genres.

국문: 사용자가 선호·회피하는 장르·카테고리.

Movies 예시: "Another brilliant Nolan sci-fi epic" → sci-fi(positive)

Books 예시: categories=[Mystery, Thriller] 매핑

2. narrative_complexity

English: The user's preference for complex versus simple narrative structures, including multi-layered plots, non-linear timelines, unreliable narrators, and depth of character development.

국문: 복잡한 서사(다중 시간선·비선형 플롯·다층 캐릭터) vs 단순 서사 선호.

예시: "Time-loop structure was genius" → complex

3. pacing_preference

English: The user's preference for narrative pacing — fast-paced action versus slow-burn, character-driven, contemplative storytelling.

국문: 빠른 전개(액션·긴장) vs 느린 전개(인물 중심·여운) 선호.

예시: "Slow-burn but rewarding character study" → slow

4. quality_sensitivity

English: The user's sensitivity to production quality, technical execution, and overall craft. Includes attention to ratings and indicators of quality.

국문: 제작 품질·기술적 완성도·장인정신에 대한 민감도.

예시: "Cinematography alone makes this a masterpiece" → high

5. brand_loyalty

6. sensory_preference

English: The user's loyalty to specific creators (directors, actors, authors), franchises, series, or production brands.

국문: 특정 감독·배우·작가·프랜차이즈 충성도.

예시: "Nolan never disappoints" → Nolan(positive)

English: The user's preference for sensory experiences in media — visual spectacle, auditory immersion, action choreography, atmospheric mood, cinematography.

국문: 영상미·음향·액션 안무·분위기 등 감각적 경험 선호.

예시: "IMAX visuals were breathtaking" → visual(positive)

💡 쉬운 설명 — 이 정의서가 왜 중요한가

이 6개의 "정의 텍스트"가 §5 임베딩 매칭의 입력으로 들어간다. 즉 영어 정의 문장(예: "The user's preference for narrative pacing...")이 384차원 벡터로 변환되어, Pilot 391개 canonical 패턴의 정의 텍스트 벡터와 코사인 유사도가 비교된다. 정의가 명확할수록 매칭 품질이 좋아진다.

4. Step 2 — Pilot 100명 자유 추출 + 391 canonical 도출

4.1 왜 자유 추출을 했는가

목적	설명
1) 편향 없는 데이터 진 실 측정	본 연구가 6개 후보를 미리 정해두었지만, 데이터에 실제로 무엇이 있는지는 모름. 명시 prompt 없 이 자유 추출하면 "사용자 리뷰에 실제 등장하는 패턴 분포"를 알 수 있음.
2) 6개 후보의 데이터 정합성 검증	이론에서 도출한 6개가 실제 데이터에 등장하는가? Step 3 임베딩 매칭의 검증 자료가 됨.
3) 자유 추출의 한계 정량화	본 연구의 명시 prompt 설계가 정당화되려면 "자유 추출만으로는 부족하다"는 증거가 필요. §1의 90.8% 결과가 이로부터 도출.
4) emergent 패턴 발 견	이론에 없지만 데이터에 강하게 등장하는 패턴이 있다면? — Step 4에서 emotional_resonance 발 견.

4.2 자유 추출 방법

1. 샘플: 1,000명 overlapping users 中 Train 800명의 첫 100명 (seed=42, deterministic)
2. 입력: 사용자별 영화 리뷰 15~30개 (최신순)
3. 프롬프트: prompts/pilot_profiler_prompt.md — "이 사용자의 선호 패턴을 자유롭게 추출하라. 개
수 제한 없음. 패턴마다 이름·값·근거·신뢰도를 포함."
4. LLM: GPT-4o-mini (temperature=0.0, seed=42)
5. 비용: \$0.081 (100명 × ~\$0.0008)
6. Raw 출력: 100명 × 평균 8개 패턴 = 806개 raw 패턴

4.3 806 raw → 391 canonical 정규화 (HDBSCAN 클러스터링)

806개 raw 패턴 중에는 같은 의미인데 이름만 다른 것이 많다 (예: "genre_taste"와 "genre_preference"). 의미적으
로 같은 것을 묶어주는 정규화가 필요하다.

💡 쉬운 설명 — HDBSCAN이 뭐야? (원리)

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise) 은 "비슷한 의미를 가진 것
끼리 자동으로 묶는 기법".

핵심 원리 3가지:

- ① 밀도 기반: 점들이 뭉뭉하게 모인 영역을 하나의 군집(cluster)으로 인식. "비슷한 것끼리 공간상 가까이 모인다"는 직관
활용.
- ② 군집 수 자동 결정: K-Means처럼 "몇 개로 묶을지" 미리 지정 안 함. 데이터가 알아서 군집 수를 결정.
- ③ 노이즈 처리: 어디에도 속하지 않는 외톨이 점은 "노이즈"로 분류 — 억지로 묶지 않음.

HDBSCAN 작동 예시 — 본 연구의 실제 사례

Pilot 100명에서 추출된 806개 raw 패턴 중 일부 (이름 + 설명 페어):

"genre_preference": "The user shows a strong preference for thriller and sci-fi..."

"genre_taste": "User's taste leans toward genre-specific films like horror and..."

"complex_narrative": "User enjoys multi-layered storytelling with non-linear..."

"slow_pacing": "User appreciates slow-burn narratives that unfold gradually..."

1단계 — 임베딩 (이름 + 설명 결합): 각 패턴의 "이름 + ':' + 설명" 텍스트를 384차원 벡터로 변환.

예: "genre preference: The user shows a strong preference for thriller..." → [0.21, -0.45, ..., 0.13]

예: "genre taste: User's taste leans toward genre-specific films..." → [0.19, -0.42, ..., 0.15] ← 위와 매우 가까움

예: "complex narrative: User enjoys multi-layered storytelling..." → [-0.67, 0.33, ..., 0.55] ← 멀리 떨어져짐

왜 이름만이 아니라 설명까지 합치나? 같은 이름이라도 설명에 따라 다른 의미일 수 있음 (예: "quality_preference"가 제작 품질 vs 대사 품질). 이름+설명을 합쳐서 임베딩하면 **의미적 모호성**을 해결하고 더 정확한 군집화 가능.

2단계 — 밀도 영역 탐지: HDBSCAN이 벡터 공간을 스캔하며 밀도가 높은 영역을 찾음

영역 A (장르 관련): genre_preference, genre_taste, genre_diversity, preferred_genres → **하나의 군집**

영역 B (서사 복잡도): narrative_complexity, complex_narrative, multi_layered_storytelling → **다른 군집**

영역 C (느린 전개): slow_pacing, tolerance_for_slow_pacing, slow_burn → **또 다른 군집**

3단계 — 대표 이름 추출: 각 군집에서 가장 빈도(n_users)가 높은 이름을 canonical로 자동 선정

영역 A → genre_diversity (canonical)

영역 B → narrative_complexity (canonical)

영역 C → tolerance_for_slow_pacing (canonical)

최종: 806개 raw → **391개 canonical 패턴**으로 자연스럽게 정리됨.

💡 K-Means와의 차이

K-Means: "5개로 묶어줘"라고 지정해야 함 → 적절한 K를 모르면 곤란.

HDBSCAN: "비슷한 것끼리 알아서 묶어줘" → 데이터가 자연스러운 군집 수 결정. 본 연구는 391로 결정됨.

정규화 절차 (실제 코드 scripts/normalize_patterns.py):

1. 각 패턴의 "이름 + ':' + 설명" 텍스트를 sentence-transformers all-MiniLM-L6-v2로 임베딩 (각 패턴이 384차원 벡터, L2 normalized)
2. HDBSCAN으로 의미 군집화 (파라미터: min_cluster_size=3, min_samples=1, cluster_selection_epsilon=0.15, normalized 벡터에 대해 euclidean = cosine 거리)
3. 각 군집에서 **가장 빈도(n_users) 높은 이름을 canonical로 자동 선정**
4. HDBSCAN이 군집으로 묶지 않은 단독 패턴(노이즈, label=-1)은 개별 canonical로 보존

5. 결과: 391 canonical 패턴

왜 이름만이 아니라 설명까지 함께 임베딩하는가

이름만 임베딩하면 의미 정보가 부족하다. 예를 들어 "quality_preference"가 어떤 사용자에선 "제작 품질", 다른 사용자에선 "대사 품질"을 의미할 수 있는데, 이름만 보면 같은 군집으로 묶임. **이름 + 설명**을 합치면 LLM이 작성한 description의 의미가 임베딩에 반영되어, 같은 이름이라도 의미가 다르면 다른 군집으로 분리된다 — 본 연구의 robust한 정규화 핵심.

4.4 391 canonical의 분포 (Pareto chart)




Figure 1. Pilot 391 canonical 패턴 빈도 상위 25개 — long-tail 분포 (대부분 1~2명 등장)

💡 그래프 읽는 법

Pareto chart는 2개의 정보를 한 그래프에 보여준다:

① 파란색 막대 (왼쪽 Y축): 각 패턴이 몇 명의 사용자에게서 등장했는지.

예: 가장 왼쪽 막대 (nostalgic_preference)는 약 45명에서 등장 (100명 중 45%) — 가장 빈번한 패턴.
오른쪽으로 갈수록 막대 높이가 빠르게 감소 → 빈도가 낮은 패턴.

② 빨간색 선 (오른쪽 Y축): 누적 커버리지. 상위 N개 패턴이 전체 등장 횟수의 몇 %를 차지하는지.

예: 상위 10개 누적이 ~40%, 상위 25개 누적이 ~50% → 25개 외 나머지 366개가 50% 차지 (long-tail).

③ 초록색 점선: elbow point N=7 — 빈도가 가파르게 감소하기 시작하는 지점을 알고리즘이 자동 검출.

그래프 관찰 + 의미 풀이:

관찰 1. 상위 1~2개가 특히 두드러짐 (nostalgic ~45명, family_friendly ~38명).

→ 의미: 사용자들이 영화 리뷰에서 "그리움·향수"나 "가족적 분위기" 같은 **표층 감정**을 가장 자주 언급. 본 연구의 Core Pattern 7개에는 포함되지 않은 표면적 표현.

관찰 2. elbow가 N=7에서 떨어짐.

→ **의미:** 7개를 기점으로 빈도 감소 속도가 완만해짐. **중요한 함정:** 이 N=7은 **빈도 기준**이며, 본 연구가 채택한 7개 Core Pattern과 **구성이 다름**. 빈도 상위 7개는 표층 감정·매체 특화 패턴이 섞여 있어 Cross-Domain 추천에 부적합.

관찰 3. 꼬리가 매우 김 (long-tail).

→ **의미:** 391개 중 70%+ 패턴이 1~2명에서만 등장. 즉 **대부분이 개인 특수 표현**이라 통계적으로 의미가 약함. 추천에 활용하려면 표면 표현이 아닌 **의미적 그룹화**가 필요 — 본 연구가 §4.3 HDBSCAN으로 정규화한 이유.

핵심 교훈: "빈도가 높다 = 좋은 패턴"이 **아님**. 가장 빈번한 nostalgic·family_friendly는 책 추천에 거의 무용하다. **빈도 ≠ Cross-Domain 적합성**. 따라서 본 연구는 빈도만으로 패턴을 정하지 않고, 4가지 측면(이론·Pilot·CDR·직교)을 종합한다.

Step 2 산출: **391 canonical 패턴** (806 raw → HDBSCAN 정규화)

이 391개가 "**데이터 진실**"이며, Step 3에서 6개 후보와 매칭된다.

5. Step 3 — 6 후보 ↔ 391 canonical 임베딩 매칭

5.1 왜 임베딩 매칭을 하는가

목적	설명
1) 데이터 실재 확인	본 연구가 도출한 6개 후보가 실제 데이터(391 canonical) 에 존재하는가? 만약 6개 중 하나가 데이터에 전혀 등장하지 않으면 그 후보는 무의미한 임의 정의.
2) 자기참조 회피	본 연구가 직접 "이 후보가 좋다"고 판정하면 자기참조(짜맞춤). 대신 임베딩 모델이 자동으로 매칭 하면 객관적 검증.
3) 후보별 발현 강도 측정	후보가 데이터에 얼마나 강하게 등장하는가? cosine similarity 값으로 정량.

5.2 임베딩 매칭의 방법

💡 쉬운 설명 — 임베딩 cosine similarity가 뭐야?

임베딩(embedding)은 단어/문장의 의미를 숫자 벡터로 변환하는 기법. 예: "happy" → [0.21, -0.45, 0.78, ...] (384개 숫자)

코사인 유사도(cosine similarity)는 두 벡터의 방향이 얼마나 비슷한지를 -1 ~ 1 사이 값으로 측정.

- sim = 1.0 → 정확히 같은 의미
- sim = 0.7+ → 강한 유사
- sim = 0.5+ → 중간 유사 (본 연구의 통과 기준)
- sim ≤ 0.3 → 거의 무관

매칭에 사용되는 두 텍스트의 출처

텍스트	어떻게 만들어졌나	예시
6 후보 정의 텍스트 (본 연구가 작성)	§3.4에 명시된 각 후보 패턴의 영문 정의 문장 . 본 연구자가 Thet 2010 등의 이론 anchor를 참고하여 1~2 문장으로 직접 작성. 파일: prompts/core_patterns_definition.md	"The user's preference for narrative pacing — fast-paced action versus slow-burn, character-driven, contemplative storytelling."
391 canonical 정의 텍스트 (LLM이 생성)	Pilot 자유 추출 시 GPT-4o-mini가 각 패턴에 부여한 이름 + 설명(description) 필드. HDBSCAN 군집 후 대표 description 사용 (군집 내 평균 임베딩과 가장 가까운 것). 파일: data/pilot_patterns_canonical.parquet	"User shows a preference for narratives that unfold slowly, allowing for a gradual reveal of plot..." (tolerance_for_slow_pacing)

매칭 절차:

1. 각 6 후보의 영문 정의 텍스트를 sentence-transformers all-MiniLM-L6-v2로 384차원 벡터화

2. 각 391 canonical의 description 텍스트도 동일 모델로 벡터화
3. $6 \times 391 = 2,346$ 쌍의 cosine similarity 계산 → 행렬 형성
4. 각 후보별로 sim이 가장 높은 canonical을 Top-1 매칭 → §5.3 결과표

💡 비유로 이해

6 후보는 "본 연구가 쓴 한국어 정의서", 391 canonical은 "LLM이 자유롭게 쓴 영어 일기"라고 비유할 수 있다. 두 텍스트는 표현 방식이 다르지만 의미가 같으면 임베딩 공간에서 가깝게 위치한다. 코사인 유사도가 이 거리를 측정한다.

5.3 매칭 결과

후보 패턴	Top-1 Pilot 매칭	Sim	강도	의미
genre_preference	genre_diversity	0.699	MEDIUM	장르 다양성 신호 존재
narrative_complexity	narrative_complexity	0.803	STRONG (직접)	같은 이름으로 발현 — 가장 강한 매칭
pacing_preference	tolerance_for_slow_pacing	0.807	STRONG	"느린 전개 허용" 패턴이 강하게 발현
quality_sensitivity	variable_rating_on_quality	0.552	MEDIUM	품질 민감도 신호 존재
brand_loyalty	franchise_loyalty	0.696	MEDIUM	프랜차이즈 충성도로 발현
sensory_preference	enjoyment_of_action_movies	0.591	MEDIUM	액션 영화 즐길 → 감각 차원

5.4 결과의 의미

✅ 6/6 모두 sim ≥ 0.5로 발현 — 본 연구의 6개 후보가 모두 데이터에 실재함이 확인됨.

의미	해석
narrative_complexity (sim 0.80)	본 연구가 정의한 이름 그대로 사용자가 자연스럽게 표현 → 가장 강력한 검증
pacing_preference (sim 0.81)	"tolerance_for_slow_pacing"으로 변형 등장 — 본 연구의 "느린 전개 선호"와 의미 일치
4개 MEDIUM (sim 0.55~0.70)	이름은 다르나 의미는 본 연구 후보와 부합 — 자유 추출의 표면 표현 차이일 뿐 본질 동일
최저 sim 0.55 (quality_sensitivity)	데이터에서 가장 약한 발현이나 임계값 통과 — Cross-Domain에선 PARTIAL 라벨로 적합

주의: 매칭이 sim 0.5 이상이지만 1.0은 아니다. 즉 본 연구의 6개와 데이터 391은 **완전 일치**가 아닌 **의미적 정합**이다. 이는 자연스러운 결과 — 자유 추출 데이터에는 "표면 표현"이 다양하기 때문.

6. Step 4 — emotional_resonance 7번째 추가 정당화

6.1 발견 — 이론에 없으나 데이터에 강하게 등장

어떻게 발견했나 (절차)

emotional_resonance는 Step 3의 매칭 작업에서 **의도치 않게** 발견되었다. 발견 경위:

1. **Pilot 391 canonical 패턴 빈도 표 작성**: HDBSCAN 정규화 후 각 canonical 패턴이 100명 중 몇 명에서 등장했는지 집계 (data/pilot_pattern_frequency.parquet).
2. **상위 패턴 확인**: nostalgic_preference (45명), family_friendly (38명), **emotional_resonance (14명)** 순. — emotional_resonance가 본 연구가 정한 6개 후보가 아닌데 빈도 상위에 등장.
3. **이름 정확 일치 확인**: Pilot LLM이 자유 추출에서 사용한 이름이 emotional_resonance — 영문 underscore 표기까지 우연히 동일. 일반적으로 LLM은 비슷한 의미라도 다양한 표현(예: emotional_impact, emotional_depth)을 쓰는데, 같은 이름 14번 등장은 이례적.
4. **6 후보와의 임베딩 매칭**: emotional_resonance를 6개 후보 정의 텍스트와 매칭 → 6개 중 어느 것과도 sim ≥ 0.5가 아님 (즉 기존 6개 중 어디에도 속하지 않는 독립 신호).
5. **자기 자신과의 매칭**: 만약 emotional_resonance를 7번째 후보로 추가하고 자신의 정의 텍스트로 매칭하면 sim 0.816 (같은 이름끼리의 정합).

발견 결과:

- 이름 그대로 emotional_resonance로 14% 빈도 등장 (사용자 100명 중 14명)
- 기존 6개 후보와 의미적으로 독립 (max sim < 0.5)
- 자기 정의와의 매칭 시 sim 0.816
- 의미: "콘텐츠가 깊은 감정·여운·개인적 의미를 남기는지 중시"

💡 왜 LLM이 같은 이름을 14번이나 썼나?

GPT-4o-mini는 자유 추출 시 패턴 이름을 자유롭게 만든다. 보통 "emotional_impact", "emotional_engagement", "feels_resonant" 등 다양한 표현이 나온다. 그런데 본 연구의 100명 중 14명에서 **정확히** emotional_resonance라는 동일한 이름이 등장했다는 것은:

- ① 이 개념이 영화 리뷰에 매우 자주 나타남 (LLM이 가장 자연스러운 명명을 일관되게 선택)
- ② 사용자의 정서 반응이 일관된 의미적 cluster를 형성
→ HDBSCAN 군집화도 이 14개를 하나의 canonical로 묶음.

6.2 emotional_resonance가 7번째로 추가된 이유

기준	평가	판정
이론 정합성 (C1)	Thet 2010·Liu 2012에 직접 등재 없음. affective recommendation 분야에 일반 개념은 있으나 약함	△

Pilot 발현 (C2)	14% 사용자에서 등장, sim 0.82로 직접 매칭 — 이론 후보 6개 중 어느 것보다 강한 단독 신호	○
Cross-Domain 적합성 (C3)	Movies-only 키워드 0개, 책에도 적용 가능 (책 "감동적인 작품 선호" 자연스러움)	○
직교성 (C4)	다른 6개와 max sim 0.38 (vs sensory) — 매우 안전	○

6.3 추가의 의미 — 방법론의 보완 절차

본 연구의 접근:

- 이론에서 출발한 6개 후보(Step 1)
- 데이터로 검증(Step 2-3)하면서
- 이론에 없으나 데이터가 강하게 말하는 패턴은 추가(Step 4)

이렇게 이론 + 데이터의 양방향 검증이 본 방법론의 핵심.

emotional_resonance는 "방법론이 담혀있지 않고 데이터 신호에 열려있음"을 시연하는 사례.

💡 쉬운 설명 — 왜 이게 학술적으로 중요한가

보통 연구는 두 방향 중 하나만 한다:

- 이론 중심: 학술적 정의에서 출발 → 단점: 데이터에 안 맞을 수 있음
- 데이터 중심: 데이터에서 발견 → 단점: 임의로 보임, 학술 근거 약함

본 연구는 둘 다 사용한다. 6개는 이론 anchor에서 시작, 1개(emotional)는 데이터에서 추가. 이렇게 "이론 + 데이터 = 더 단단한 정당화"가 본 연구의 강점.

7. 4가지 측면 종합 검토 + 최종 7개 채택

7.1 4가지 측면 (C1~C4)

측면	측정 방법	○ 기준	△ 기준	x 기준
C1 이론 정합성	aspect mining 차용 강도	직접 차용	일반화 차용	차용 약함
C2 Pilot 발현	391과의 max cosine sim	≥ 0.7	≥ 0.5	< 0.5
C3 Cross-Domain	Movies-only 키워드 검출 수	0개	1개	≥ 2 개
C4 직교성	다른 패턴과의 max sim	≤ 0.6	≤ 0.7	> 0.7

💡 쉬운 설명 — 4가지 측면이 왜 필요한가

패턴이 추천에 쓸 만한지 판단하려면 한 가지 잣대로는 부족하다.

C1 (이론) — 학술적 근거가 있나? "있어 보이는데 학술 출처가 없으면 임의 정의"

C2 (Pilot) — 데이터에 실제 등장하나? "이론에만 있고 데이터엔 없으면 의미 없음"

C3 (CDR) — 영화·책 양 도메인에 적용 가능한가? "영화 전용이면 책 추천에 BLOCK 처리 필요"

C4 (직교성) — 다른 패턴과 의미적으로 독립적인가? "두 패턴이 너무 비슷하면 중복 정보"

이 4가지를 종합해야 **"학술적이면서, 데이터에 있고, 도메인 적합하며, 독립적인"** 패턴이 선정된다.

각 측면을 어떻게 측정했는가

측면	측정 도구·방법
C1 이론 정합성	본 연구자가 §3.2 매핑 표에서 정성 평가. "직접 차용"은 Thet 2010에 명시된 aspect와 직접 대응 (예: narrative_complexity). "일반화 차용"은 일반 개념만 빌림 (예: brand_loyalty의 Oliver 1999). "차용 약함"은 명시적 학술 출처 부재.
C2 Pilot 발현	\$5 임베딩 매칭에서 산출된 cosine similarity 값 그대로 사용. scripts/match_pilot_to_predefined.py
C3 Cross-Domain	각 후보의 영문 정의 텍스트를 lowercase 후, Movies-only 키워드 사전(acting, actor, director, cinematograph 등 13개)에 포함되는 단어 자동 검출. scripts/check_predefined_orthogonality.py
C4 직교성	7개 후보 정의 텍스트끼리 7×7 cosine similarity 행렬 계산. 자기 자신 제외한 max 값. scripts/check_predefined_orthogonality.py

7.2 7개 패턴별 종합 결과

Pattern	C1 이론	C2 Pilot	C3 CDR	C4 직교	결정
genre_preference	○	△ 0.70	○ TRANSFER	○ 0.47	ACCEPT

narrative_complexity	○	○ 0.80	○ TRANSFER	△ 0.67	ACCEPT
pacing_preference	○	○ 0.81	○ TRANSFER	△ 0.67	ACCEPT
quality_sensitivity	○	△ 0.55	△ PARTIAL	○ 0.37	ACCEPT (조건부)
brand_loyalty	△	△ 0.70	✗ BLOCK	○ 0.33	ACCEPT (BLOCK 후보)
sensory_preference	△	△ 0.59	△ PARTIAL	○ 0.47	ACCEPT (보완 필요)
emotional_resonance	△	○ 0.82	○ TRANSFER	○ 0.38	ACCEPT

💡 각 결정의 의미 풀이

일반 ACCEPT (4개: genre, narrative, pacing, emotional) — 4기준 모두 ○ 또는 △. 깨끗하게 채택 → Profiler가 무조건 추출, Judge가 그대로 사용.

ACCEPT (조건부) — **quality_sensitivity** — C2(0.55)와 C3(△)에서 약함. "매체별 변환 로직 필요" 의미. 영화에선 연기·연출 품질, 책에선 문체·편집·번역 품질로 변환해서 사용.

ACCEPT (BLOCK 후보) — **brand_loyalty** — C3에서 ✗ (actor·director 키워드 검출). "Transfer Gate가 BLOCK 처리해야 정상". 이게 본 연구 Gate 가치의 시연 사례.

ACCEPT (보완 필요) — **sensory_preference** — 학술 인용·데이터 모두 약함. 그러나 BLOCK 시연 목적으로 의도적으로 유지 (§3.3 박스 참조).

최종 7/7 ACCEPT (REJECT 0) — 모든 패턴이 채택 기준 통과.

7.3 사전 검토 5항목 (Pilot 결과 보기 전 등록)

💡 사전 검토가 왜 중요한가

"결과 본 후 가설을 만들면" 짜맞춰지므로 자기참조가 된다. **결과 보기 전에 "이런 결과가 나와야 방법이 맞다"고 미리 정해 두면, 실제 결과로 검증 가능** — 사회과학·의학에서 쓰는 **사전 등록(pre-registration)** 개념을 차용.

본 연구의 5항목은 **방법이 작동하는지 확인하는 5가지 조건**:

① 후보가 데이터에 발현하나? / ② 자유 추출만으로 부족한가? / ③ 후보들이 서로 독립인가? / ④ BLOCK 후보가 자동 식별되나? / ⑤ 데이터에서 새 패턴이 emerge하나?

5/5 통과 → 방법의 모든 메커니즘이 의도대로 작동함을 데이터로 입증.

1 ✓ Pilot 발현 7/7 (sim ≥ 0.5)	2 ✓ 자유 추출 한계 90.8% 비-CDR-적합	3 ✓ 직교성 max 0.669 (≤0.7)	4 ✓ BLOCK 식별 sensory cinematograph	5 ✓ emotional 매칭 sim 0.820 (직접)
---	--	---	---	--

7.4 직교성 검증 (보조)

💡 직교성이 뭐고 왜 중요한가

직교성(orthogonality) — 두 패턴이 의미적으로 "독립적"이라는 것. 수학적으로는 벡터가 직각(orthogonal)이면 $\text{sim}=0$, 같으면 $\text{sim}=1$.

패턴들이 너무 비슷하면($\text{sim} \geq 0.7$) "**중복 정보**"가 되어 추천에 도움이 안 된다. 예를 들어 "narrative_complexity"와 "story_depth"가 $\text{sim} 0.95$ 면 사실상 같은 패턴 — 둘 중 하나만 있어도 됨.

본 연구는 $\text{sim} \leq 0.7$ 을 통과 기준으로 정함 — 모든 패턴 쌍이 이 기준 미만이어야 7개가 의미적으로 독립적이라 인정.




Figure 2. 7개 패턴 정의 텍스트의 7×7 cosine similarity (max off-diagonal 0.669, threshold 0.7 미달)

Heatmap 읽는 법:

- **대각선 (1.00):** 자기 자신과의 유사도 (항상 1)
- **off-diagonal (대각선 밖):** 다른 패턴과의 유사도. 본 연구의 검증 대상.
- **색상:** 초록 = 낮은 유사도 (안전), 빨강 = 높은 유사도 (중복 위험)

주요 관찰:

- 가장 높은 쌍: **narrative_complexity** ↔ **pacing_preference (0.67)** — 둘 다 서사 차원이라 자연스럽게 가까움. 임계값 0.7 직전이지만 통과.
- 가장 낮은 쌍: **brand_loyalty** ↔ **narrative_complexity (0.16)** — 서로 매우 독립적
- 전체 평균: 0.31 — 충분히 분산됨
- 0.7 이상 위반 쌍: **0건** — 모든 쌍이 안전 범위 통과 

8. 결론

8.1 4단계 프로세스 요약

1. **Step 1:** Thet 2010 영화 aspect 7개 + Liu 2012 ABSA 표준 + 추천시스템 관행 → Cross-Domain 재구성 → **6개 후보 도출**
2. **Step 2:** Pilot 100명 자유 추출 → 806 raw → HDBSCAN 정규화 → **391 canonical 패턴**
3. **Step 3:** 6 후보 ↔ 391 canonical 임베딩 매칭 → **6/6 모두 sim ≥ 0.5로 발현 확인**
4. **Step 4:** Pilot에서 emerge한 emotional_resonance (sim 0.82, 14% 빈도)를 데이터 기반으로 추가 → **최종 7개 확정**

8.2 본 Pilot Study가 입증한 것

입증 항목	결과
자유 추출만으로는 부족함	90.8% 비-CDR-적합 → 명시 prompt 설계 정당화
6개 후보의 데이터 실재성	6/6 모두 sim ≥ 0.5 발현
BLOCK 메커니즘 정당성	brand-sensory가 Movies-only 키워드 자동 검출
방법론의 보완 절차	emotional_resonance를 데이터 기반 추가 시연
7개 패턴의 의미적 독립성	직교성 max 0.669 ≤ 0.7

8.3 논문에 쓸 수 있는 핵심 표현

"본 연구는 Cross-Domain 추천에 적합한 7개 Core Pattern을 4단계 프로세스로 도출하였다. (1) Thet et al. (2010) 영화 리뷰 aspect mining과 Liu (2012) ABSA 표준에서 6개 후보 패턴을 Cross-Domain 적용 가능 형태로 재구성하였다. (2) Pilot Study (n=100)에서 자유 추출 prompt로 806개 raw 패턴을 도출하고 HDBSCAN 임베딩 클러스터링으로 391 canonical 패턴으로 정규화하였다. (3) 6개 후보와 391 canonical 사이 cosine similarity 매칭에서 6/6 모두 sim ≥ 0.5로 발현됨이 확인되었다. (4) Pilot에서 강하게 emerge한 emotional_resonance (sim **0.82**, 14% 빈도)를 데이터 기반으로 추가하여 최종 7개 패턴으로 확정하였다. 자유 추출 결과의 **90.8%** 가 매체-종속·표층-메타 신호로 분류되어 명시 prompt 설계의 정당성이 데이터로 입증되었으며, brand_loyalty와 sensory_preference는 Movies-only 키워드 (actor·director·cinematograph) 자동 검출로 Transfer Gate의 BLOCK 후보로 식별되었다."

8.4 한계 및 향후 작업

한계	대응
Pilot 100명 (LLM4CDR 수준)	본 실험 1,000명에서 통계적 일반화
emotional_resonance 이론 anchor 약함	Pilot 데이터로 보완 (sim 0.82, 14% 빈도)
medium_specific 분류의 보수성	결론은 50~60%만 매체-종속이어도 동일

본 연구의 contribution

- **메인**: Profiler-Judge 구조의 LLM 기반 CDR 프레임워크
 - **서브**: Pilot 기반 패턴 선정 절차 (자기참조 회피, 이론+데이터 양방향 검증)
- 7개 패턴은 본 도메인(Movies&TV → Books)에 적용한 결과물이며, 본 방법론은 다른 CDR 시나리오에도 재적용 가능.

— 본 보고서 v4의 핵심 메시지: 본 연구의 7개 Core Pattern은 **이론 anchor + Pilot 검증 + 데이터 기반 보완**의 4단계 프로세스로 도출되었다 —